Mašinsko učenje
Akademska god. 2026/2027.
Specifikacija projekta I dio
Ukupno bodova: 25 bod.
Rok za finalnu predaju: 18.12.2026.
Diskusija o specifikaciji projekta: 27.10.2026. na predavanjima i na vježbama od 27.10.2026.

Opšte informacije
Prvi dio projektnog zadatka nosi 25 bodova i završava se finalnom predajom dokumentacije i koda. Dio bodova osvaja se kontinuirano, kroz prezentacije na vježbama, a ostatak kroz kvalitet dokumentacije i koda.

Rezultat projekta
1. PDF Dokument - sa detaljno dokumentovanim svim koracima
2. Google Colab notebook
3. Kontinuirane prezentacije na vježbama

Specifikacija projektnog zadatka

Projekat se radi u timu. Svaki tim se sastoji od 3-5 studenta. Sastavi timova određeni su u koordinaciji sa predmetnim asistentom.
Implementacija: korištenjem Python googlecolab okruženja.

Prije početka rada na projektu u potpunosti pročitati specifikaciju projekta. Specifikacija projekta prati gradivo predmeta (predavanja i vježbe).

1. Zadatak (5 bodova): Radi se grupno.
1.1 Odabrati temu (za početak bez detaljne specifikacije) i odgovarajući skup podataka. Skup podataka mora sadržavati broj instanci veći ili jednak 1000, broj atributa mora biti veći ili jednak od 15, podaci moraju biti mješovitog tipa, tj. potrebno je da skup podataka sadrži i numeričke i kategoričke tipove atributa. Osnovni zadatak nad odabranim skupom podataka bit će klasifikacija, pa je potrebno unaprijed odrediti koji atribut predstavlja klasu (labelu) i to jasno naglasiti u opisu skupa podataka. Predmetni asistent ima pravo odbiti skup podataka, ako smatra da nije adekvatan, ili tražiti od studenata modifikaciju inicijalnog skupa podataka.

1.2. Svaki član tima treba pronaći barem 1 relevantni naučnoistraživački rad na odabranu temu. Za svaki rad u tabeli navesti: problem, skup podataka, korištene metode, metrike i najbolji rezultat. Formulisati očekivanja: koji algoritmi obično daju dobre rezultate i koje metrike su uobičajene za ovaj problem. Postaviti hipotezu.

1.3. Analizirati skup podataka 1.2. primjenom odgovarajućih metoda potrebno je analizirati pojedinačno sve varijable: tipove varijabli, distribuciju, deskriptivnu statistiku (srednju vrijednost, standardnu devijaciju,...), korelaciju između parova varijabli,... Vizualizirajte proces istraživanja podataka za svaku varijablu i jasno argumentujte zapažanja i zaključke o svakoj varijabli.

1.4. Izvršiti odgovarajuće transformacije podataka, te uklanjanje nepodobnih vrijednosti da bi dobili podatke koji su spremni za korištenje u većini metoda klasifikacije.

Korake 1.1.-1.4. je potrebno jasno i u potpunosti dokumentovati. Prezentacija i diskusija urađenog se provodi na vježbama.

2. Zadatak (10 bodova): Radi se grupno i individualno. Potrebno je izgraditi klasifikacijski model na osnovu odabranog seta podataka.
2.1. Radi se grupno. (1 bod) Upoznali smo se sa metodama mašinskog učenja za klasifikaciju/predikciju podataka: stablo odlučivanja, Bayes, SVM mašina, neuronske mreže, k-nn, regresija,... Odaberite skup algoritama (broj algoritama treba da odgovara broju članova tima) pogodan za izgradnju navedenog klasifikacijskog modela. U grupnom dogovoru svakom članu tima se dodjeljuje po jedan algoritam. .

2.2. Radi se individualno. (6 bod) Za svaki algoritam, odgovorni član tima (iz tačke 2.1.) vrši izgradnju klasifikacijskog modela što uključuje sljedeće:

- Analizirajte ponovo podatke i odlučite da li treba dodatna priprema seta podataka za primjenu konkretnog algoritma.
- Opišite i implementirajte proces izgradnje klasifikacijskog modela za odgovarajući problem (podjelu seta podataka na trening, testni i validacijski set podataka).
- Evaluirajte model pomoću konfuzijske matrice (tačnost, specifičnost, osjetljivost, kappa statistika, Mean Absolute Error za regresiju, itd). Koristiti metode unakrsne validacije za dodatnu evaluaciju modela.
- Analizirajte potencijalni uticaj nebalansiranosti podataka na izgrađeni model i na osnovu toga primijeniti metode za *oversampling* i/ili *undersampling.*
- Uradite *tuning* hiperparametara.
  Detaljno dokumentovati urađeno u zadatku 2.2.

2.3. Radi se grupno. (3 bod) Analizirajte i diskutujte performanse svakog modela (zašto je neki model dao bolje rezultate na osnovu neke metrike). Nakon toga predložite i implementirajte *ensamble* model klasifikacije koji će doprinijeti boljim performansama. Validirajte predloženi *ensamble* model klasifikacije.
Napomena: Prilikom izgradnje modela formirati odgovarajući *pipeline.*
U cilju poboljšanja performansi nemojte zaboraviti da je proces izgradnje modela mašinskog učenja iterativan proces.
Prezentacija i diskusija urađenog za 2.1-2.3. se provodi na vježbama.

Napomena za predaju projekta 1:
Potrebno je predate pdf dokument koji ima sljedeće elemente:

- Opšti podaci: članovi tima, projekat, datum, opis teme.
- Za svaku stavku projekta treba dati kratak sažetak. Primjeri:
  - Za stavku 1, je potrebno dokumentovati rezultate istraživanja o podacima, koje su se metode koristile za pripremu podataka i sažetu tabelu šta se uradilo za koju karakteristiku uz referenciranje na kod. Potrebno ukratko opisati temu odabranog naučnoistraživačkog rada i njegove rezultate u tabelarnom obliku.
  - Za implementaciju modela, dodati referencu na kod uz naznaku u dokumentu šta se sve uradilo za procjenu i poboljšanje modela.
  - Za stavku *ensemble* metode potrebno je napisati u dokumentu koja metoda je odabrana uz diskusiju o dobijenim rezultatima i referencom na kod.
- Dokument treba da prikaže put izgradnje modela sa stavkama šta je urađeno zašto i diskusijama rezultata bez koda (na njega se treba referencirati).

Kontinuirane prezentacije na vježbama (7 bodova)
Član tima koji ne prisustvuje nekoj od prezentacija, gubi bodove na ovaj dio projekta. Bodovanje je individualno. Toleriše se do jedan izostanak.

Za neke zadatke je predviđeno više vremena da se urade. U tom slučaju tim može birati na kojoj vježbi će uraditi prezentaciju, ovisnosti da li su uradili zadatak. Studenti istog tima moraju prezentovati u isto vrijeme.

Za navedeni projekti zadatak očekivane su četiri prezentacije na vježbama. Plan rada i prezentacija na projektu je:

Zadatak 1.1 i 1.2. Potrebno prezentovati na vježbama u periodu 2.11. - 6.11.
Zadatak 1.3 i 1.4 Potrebno prezentovati na vježbama u periodu . 9.11 - 20.11.
Zadatak 2.1 Potrebno prezentovati na vježbama u periodu 30.11. - 4.12.
Zadatak 2.2 i 2.3 Potrebno prezentovati na vježbama u periodu 7.12. - 18.12. - finalna prezentacija

Diskusija na vježbama (3 boda)
Tri boda se ostvaruje slušanjem prezentacija drugih studenata (ne nužno svih) i postavljanjem pitanja drugim članovima tima. Na kraju projekta, studenti trebaju napisati kratki izvještaj sa pozitivnim i negativnim stranama svih projekata svoje grupe. Bodovanje je individualno i studenti mogu ostaviti ili 0 ili 3 boda.