Univerzitet u Sarajevu
Elektrotehnički fakultet

Mašinsko učenje

Akademska godina 2026/2027.

Detekcija prevarnih finansijskih transakcija

Projektni zadatak – I dio

Članovi tima:

1. Aldin Velić
2. Bakir Činjarević
3. Danijal Alibegović
4. Haris Macić
5. Kerim Hajdar

Kod i podaci:

https://github.com/bakir004/mu

Sarajevo, 18. decembar 2026.

Sadržaj

1 Odabir, analiza i priprema podataka **1**

1.1 Odabir teme i skupa podataka 1

1.2 Pregled naučnoistraživačkih radova 4

1.3 Istraživačka analiza podataka 16

1.4 Priprema i transformacija podataka 30

2 Izgradnja klasifikacijskih modela **37**

2.1 Odabir algoritama i raspodjela rada 37

2.2 Izgradnja i evaluacija pojedinačnih modela 38

2.2.1 Model 1: *[odabrati algoritam]*– Aldin Velić 38

2.2.2 Model 2: *[odabrati algoritam]*– Bakir Činjarević 38

2.2.3 Model 3: *[odabrati algoritam]*– Danijal Alibegović 39

2.2.4 Model 4: *[odabrati algoritam]*– Haris Macić 40

2.2.5 Model 5: *[odabrati algoritam]*– Kerim Hajdar 40

2.3 Poređenje i ansambl-model 41

Literatura **43**

1. Odabir, analiza i priprema podataka

1.1. Odabir teme i skupa podataka

Tema. Predmet projekta je prepoznavanje prevarnih finansijskih transakcija na osnovu karakteristika pojedinačnih transakcija. Zadatak se posmatra kao **nadzirana binarna klasifikacija**, jer je za treniranje poznata ciljna klasa.

Izvor. Kao polazni skup koristi se *Credit Card Transactions Fraud Detection Dataset* sa platforme Kaggle [1]. Skup je simuliran alatom *Sparkov Data Generation* i obuhvata transakcije približno 1 000 korisnika kod oko 800 trgovaca u periodu od 1. januara 2019. do 31. decembra 2020. godine. Objavljen je u dvije datoteke: `fraudTrain.csv` (1 296 675 transakcija) i `fraudTest.csv` (555 719 transakcija). Ciljni atribut je `is_fraud`: vrijednost 0 označava legitimnu, a 1 prevarnu transakciju.

Formiranje korištenog skupa. Originalni skup je izrazito nebalansiran – u `fraudTrain.csv` je samo 7 506 prevarnih transakcija (približno 0,58 %). Zbog veličine originalnih datoteka i potrebe da sve faze rada (analiza, više modela, unakrsna validacija i podešavanje hiperparametara) budu izvodive u razumnom vremenu, iz `fraudTrain.csv` su izvedene tri manje verzije skupa:

- `fraud_balanced.csv` – **osnovni radni skup**: sve 7 506 prevarnih transakcija i isto toliko nasumično odabranih legitimnih transakcija (*random undersampling*, `random_state=42`), odnos klasa 50/50;
- `fraud_15k.csv` i `fraud_50k.csv` – stratifikovani uzorci od 15 000 i 50 000 transakcija koji zadržavaju originalni udio prevara (0,58 %). Ovi skupovi služe za analizu podataka s realističnim, nebalansiranim odnosom klasa, a iz `fraud_50k.csv` su formirani skupovi za modeliranje.

Sve tri verzije zadržavaju svih 22 kolone originalnog skupa (prva, indeksna kolona originalne datoteke je izostavljena).

Datoteke se djelimično preklapaju i ne predstavljaju nezavisne trening, validacijske i testne skupove. Za modeliranje su zato iz `fraud_50k.csv`, prije balansiranja, izdvojeni odvojeni trening, validacijski i testni dio, bez zajedničkih oznaka `trans_num` (odjeljak 1.4). Balansiranje se primjenjuje samo na trening dijelu, dok validacijski i testni dio zadržavaju izvorni odnos klasa. Tipovi atributa u tabeli 1 navedeni su prema značenju podataka.

Tabela 1: Osnovne karakteristike korištenog skupa podataka

Karakteristika	Podatak
Naziv datoteke	`fraud_balanced.csv` (dodatno `fraud_15k.csv` i `fraud_50k.csv`)
Broj instanci	15 012 (odnosno 15 000 i 50 000)
Broj atributa	21 ulazni atribut + ciljna varijabla `is_fraud` (ukupno 22 kolone)
Numerički atributi	7: `amt`, `lat`, `long`, `merch_lat`, `merch_long`, `city_pop`, `unix_time`
Kategorički, tekstualni i identifikatorski atributi	12: `category`, `gender`, `state`, `city`, `job`, `merchant`, `first`, `last`, `street`, `trans_num`, `cc_num`, `zip`
Datumski atributi	2: `trans_date_trans_time`, `dob`
Ciljna varijabla	`is_fraud` (0 – legitimna; 1 – prevarna)
Udio klase 1	50,00 % u `fraud_balanced.csv`; 0,58 % u `fraud_15k.csv` (87 prevara) i `fraud_50k.csv` (289 prevara)
Nedostajuće vrijednosti / duplikati	nema / nema
Vremenski raspon (radni skup)	1. 1. 2019. – 21. 6. 2020.

Tabela 2: Opis atributa skupa podataka

Atribut	Tip	Značenje
`trans_date_trans_time`	datum/vrijeme	datum i vrijeme transakcije
`cc_num`	identifikator	broj kartice (977 različitih kartica)
`merchant`	kategorički	naziv trgovca (693 vrijednosti)
`category`	kategorički	kategorija kupovine (14 vrijednosti, npr. `grocery_pos`, `shopping_net`)
`amt`	numerički	iznos transakcije u USD
`first`, `last`	tekstualni	ime i prezime vlasnika kartice
`gender`	kategorički	spol vlasnika kartice (F/M)
`street`, `city`, `state`, `zip`	kategorički	adresa vlasnika kartice (50 saveznih država i District of Columbia)
`lat`, `long`	numerički	geografske koordinate vlasnika kartice
`city_pop`	numerički	broj stanovnika grada vlasnika kartice
`job`	kategorički	zanimanje vlasnika kartice (493 vrijednosti)
`dob`	datum	datum rođenja vlasnika kartice
`trans_num`	identifikator	jedinstveni identifikator transakcije
`unix_time`	numerički	vrijeme transakcije u UNIX formatu
`merch_lat`, `merch_long`	numerički	geografske koordinate trgovca
`is_fraud`	binarni (klasa)	0 – legitimna, 1 – prevarna transakcija

Provjera uslova specifikacije. Radni skup ima 15 012 instanci (≥ 1000) i 21 ulazni atribut (≥ 15). Sadrži i numeričke atribute (npr. iznos, koordinate, broj stanovnika) i kategoričke atribute (npr. kategorija kupovine, spol, država, zanimanje), pa je mješovitog tipa. Ciljna varijabla `is_fraud` je unaprijed određena i binarna.

Ograničenja podataka. Podaci su simulirani, pa uočeni obrasci ne moraju u potpunosti odgovarati stvarnom finansijskom poslovanju. Dio kolona su identifikatori ili lični podaci (`trans_num`, `cc_num`, `first`, `last`, `street`) koji mogu navesti model da pamti korisnike i dovesti do pretjeranog prilagođavanja. Svi nazivi trgovaca imaju prefiks `fraud_` koji je artefakt generatora, a ne indikator prevare. Datumske kolone je potrebno transformisati (npr. sat transakcije, starost korisnika) da bi bile upotrebljive. Konačno, balansirani skup ne odražava stvarni udio prevara, pa se metrike poput preciznosti dobijene na njemu ne mogu direktno prenijeti na realističnu raspodjelu. Za takvu evaluaciju potrebno je koristiti odvojeni testni skup s izvornim odnosom klasa.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.1 Odabir i učitavanje skupa podataka“*.

1.2. Pregled naučnoistraživačkih radova

Svaki od pet članova analizira najmanje jedan relevantan naučnoistraživački rad. Za svaki rad navode se **problem, skup podataka, metode, metrike i najbolji rezultat**. Tri rada ([2, 3, 4]) koriste isti Sparkov skup podataka kao naš projekat, a dva ([5, 6]) najčešće korišteni stvarni evropski skup transakcija, što omogućava poređenje nalaza na simuliranim i stvarnim podacima.

Naučnoistraživački rad – Aldin Velić

Naslov rada: *A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions.*

Autori: Jonathan Kwaku Afriyie, Kassim Tawiah, Wilhemina Adoma Pels, Sandra Addai-Henne, Harriet Achiaa Dwamena, Emmanuel Odame Owiredu, Samuel Amening Ayeh i John Eshun.

Izvor: *Decision Analytics Journal*, vol. 6, članak 100163, 2023. [2]

Tabela 3: Sažeti pregled naučnoistraživačkog rada Afriyie i saradnika (2023)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama kao problem binarne klasifikacije, pri čemu se razlikuju legitimne i prevarne transakcije.
Skup podataka	*Credit Card Transactions Fraud Detection Dataset* (Kaggle), simuliran pomoću alata Sparkov. U radu se navodi 555 719 transakcija i 23 kolone u početnom skupu podataka.
Korištene metode	Logistička regresija (Logistic Regression), stablo odlučivanja (Decision Tree) i slučajna šuma (Random Forest). Priprema podataka uključuje skaliranje i nasumično smanjivanje većinske klase (undersampling).
Metrike	Tačnost (accuracy), preciznost (precision), osjetljivost (recall/sensitivity), specifičnost, F1-mjera i ROC-AUC.
Najbolji rezultat	**Random Forest**: tačnost **96%**, ROC-AUC **98,9%**. Prijavljene vrijednosti: recall 0,97, precision 0,09 i F1-mjera 0,17.

Cilj i istraživački problem.

Autori istražuju koliko uspješno različiti algoritmi nadziranog mašinskog učenja razlikuju prevarne od legitimnih transakcija. Osnovni cilj jeste uporediti performanse tri

klasifikacijska algoritma i utvrditi koji je najpogodniji za analizirani skup podataka.

Dodatno istražuju obrasce povezane s iznosom i vremenom transakcije, kategorijom trgovca te pojedinim karakteristikama korisnika.

Skup podataka i njegova nebalansiranost.

Rad koristi javno dostupan Kaggle skup simuliranih transakcija, obavljenih tokom 2020. godine u Sjedinjenim Američkim Državama.

Skup obuhvata numeričke i kategoričke atribute, a ciljna varijabla predstavlja status prevare.

Nakon postupaka obrade, u Tabeli 4 rada prikazano je 482 672 legitimnih i 2 135 prevarnih transakcija, odnosno približno 99,6% i 0,4%.

Takva raspodjela predstavlja izraženu nebalansiranost klasa, pa sama ukupna tačnost nije dovoljna za procjenu uspješnosti klasifikatora.

Priprema podataka i korištene metode.

Autori navode čišćenje podataka, transformaciju numeričkih atributa na raspon od 0 do 1 i primjenu metode *random undersampling*.

Ova metoda smanjuje broj primjera većinske klase kako bi se ublažila pristrasnost modela prema legitimnim transakcijama.

Na Slici 1 rada prikazan je uravnotežen uzorak s 1 708 prevarnih i 1 707 legitimnih transakcija.

Za klasifikaciju se zatim koriste logistička regresija, jedno stablo odlučivanja i Random Forest, koji kombinuje veći broj stabala.

Poređenje eksperimentalnih rezultata.

U Tabeli 4 prikazane su vrijednosti koje su autori objavili u Tabeli 11 i uz ROC krive (Slika 16).

Tabela 4: Poređenje rezultata klasifikacijskih algoritama iz rada

Model	**Acc.**	**Prec.**	**Recall**	**F1**	**Spec.**	**AUC**
Decision Tree	0,92	0,05	0,93	0,09	0,92	0,945
Logistic Regression	0,92	0,04	0,76	0,08	0,92	0,872
Random Forest	**0,96**	**0,09**	**0,97**	**0,17**	**0,96**	**0,989**

Tumačenje rezultata.

Random Forest je postigao najveće vrijednosti svih prikazanih metrika.

Njegov ROC-AUC od 0,989 ukazuje na veoma dobru sposobnost razlikovanja klasa pri

promjeni klasifikacijskog praga.

Međutim, precision od samo 0,09 znači da je tek približno 9% transakcija označenih kao prevarne zaista bilo prevarno.

Iz objavljene konfuzijske matrice (Tabela 7 rada) vidi se da je model prepoznao 409 prevara i propustio 18, ali je 4 052 legitimne transakcije pogrešno označio kao prevarne.

Zato visoka tačnost i ROC-AUC ne znače da model proizvodi malo lažnih alarma.

Niska F1-mjera (0,17) dodatno ukazuje na neravnotežu između preciznosti i osjetljivosti modela.

Dodatna zapažanja iz istraživačke analize.

Autori izvještavaju da se veći broj prevarnih transakcija u njihovom skupu javlja između 22:00 i 04:00 GMT te posebno razmatraju starosnu grupu korisnika iznad 60 godina i kategoriju kupovine.

Budući da su podaci simulirani, ova zapažanja predstavljaju obrasce uočene u posmatranom skupu, a ne dokazane zakonitosti stvarnog finansijskog poslovanja.

Zaključak i značaj za istraživanje.

Istraživanje upućuje na to da Random Forest može biti uspješan izbor za detekciju prevarnih transakcija, posebno prema ROC-AUC i osjetljivosti.

Istovremeno pokazuje da izrazita nebalansiranost klasa zahtijeva pažljivu evaluaciju i praćenje lažnih alarma.

Nalazi rada predstavljaju osnovu za očekivanje da će metode zasnovane na stablima ostvarivati konkurentne rezultate, ali i da će precision, recall i F1-mjera biti važnije za praktičnu interpretaciju nego sama ukupna tačnost.

Naučnoistraživački rad – Bakir Činjarević

Naslov rada: *Applying supervised machine learning algorithms and ensemble models to enhance credit card fraud detection.*

Autori: Abrar Al-Bulushi, Abdul K. Shaikh i Naresh Adhikari.

Izvor: *Frontiers in Artificial Intelligence*, vol. 9, članak 1813728, 2026. [3]

Tabela 5: Sažeti pregled naučnoistraživačkog rada Al-Bulushi i saradnika (2026)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama kao binarna klasifikacija na izrazito nebalansiranim podacima, uz provjeru generalizacije modela na neviđenim skupovima podataka.
Skup podataka	Glavni skup za treniranje i testiranje je *isti Sparkov skup* koji koristi naš tim (približno 1,3 miliona transakcija, 0,5 % prevara, 22 atributa). Skup od 555 719 transakcija iz iste kolekcije i još četiri javna skupa (među njima evropski skup od 284 807 transakcija i PaySim) služe kao neviđeni skupovi.
Korištene metode	Logistička regresija, Naive Bayes, stablo odlučivanja, Random Forest, neuronska mreža (ANN) i XGBoost; uravnotežavanje metodama RUS, ROS i SMOTE; selekcija atributa (korelacija, ANOVA, RFE, unaprijedna selekcija); novi atributi ponašanja korisnika; pomjeranje praga odlučivanja; ansambli *bagging*, *boosting* i *stacking*.
Metrike	Tačnost, preciznost, osjetljivost (recall), F1-mjera i AUC, uz konfuzijsku matricu; 4-struka unakrsna validacija.
Najbolji rezultat	Pojedinačno: **XGBoost** bez uravnotežavanja, F1 **0,84** (AUC 0,99). Konačni model **Bagging 1** (10 modela): F1 **0,795**, recall 0,864, AUC 0,99; uz nove atribute ponašanja F1 raste na **0,83** (recall 0,89).

Cilj i istraživački problem. Autori razvijaju cjelovit okvir za detekciju prevara koji objedinjuje izbor algoritma, uravnotežavanje klasa, selekciju i konstrukciju atributa te ansambl modele. Posebno ih zanima da li model treniran na jednom skupu zadržava performanse na drugim, neviđenim skupovima podataka.

Skup podataka i priprema. Rad je za nas posebno relevantan jer kao glavni skup koristi upravo Sparkov podatke sa Kaggle platforme, sa 12 kategoričkih i 11 numeričkih atributa i bez nedostajućih vrijednosti. Podaci su standardizovani (*z-score*), a podjela je urađena 4-strukom unakrsnom validacijom (75 % podataka za treniranje). Autori su konstruisali i nove atribute ponašanja: oznaku da li je transakcija izvan uobičajenog vremenskog prozora korisnika (izvan 10.–90. percentila sati transakcija) i *anomaly score* dobijen metodom Isolation Forest.

Poređenje eksperimentalnih rezultata. Tabela 6 prikazuje izdvojene rezultate iz Tabela 1, 8 i 9 rada (pojedinačni modeli, pomjeranje praga i ansambli).

Tabela 6: Izdvojeni rezultati iz rada Al-Bulushi i saradnika (Sparkov skup)

Model	**Acc.**	**F1**	**Prec.**	**Recall**	**AUC**
Logistička regresija – RUS	0,87	0,06	0,03	0,76	0,96
Naive Bayes – bez uravnoteženja	0,90	0,07	0,04	0,68	0,82
Stablo odlučivanja – ROS	0,99	0,78	0,79	0,77	0,88
Random Forest – bez uravnoteženja	0,99	0,82	0,88	0,76	0,97
Random Forest – RUS	0,97	0,30	0,17	0,97	0,99
ANN – bez uravnoteženja	0,99	0,83	0,93	0,76	0,99
XGBoost – bez uravnoteženja	**0,99**	**0,84**	**0,91**	**0,79**	**0,99**
XGBoost – SMOTE, prag 0,7	0,99	0,70	0,67	0,85	0,99
Bagging 1 (10 modela)	0,99	0,79	0,73	0,86	0,99
Stacking 1 (RF baza, ANN meta)	0,99	0,80	0,79	0,80	0,93
Boosting 2 (LR + AdaBoost)	0,99	0,00	0,00	0,00	0,82

Tumačenje rezultata. Logistička regresija i Naive Bayes daju vrlo nisku F1-mjeru (ispod 0,1) bez obzira na metodu uravnotežavanja, dok modeli zasnovani na stablima (Random Forest, XGBoost) i neuronska mreža postižu F1 oko 0,8. Rezultati jasno pokazuju kompromis između preciznosti i osjetljivosti: *random undersampling* podiže recall Random Foresta na 0,97, ali preciznost pada na 0,17, jer model treniran na uravnoteženim podacima na realističnoj raspodjeli generiše mnogo lažnih alarma. Tačnost je za gotovo sve modele 0,99 i zato nije informativna. Ansambl Bagging 1 nije postigao najveći F1, ali su ga autori izabrali kao konačni model zbog stabilnosti i visokog recall-a, a na neviđenom Sparkov skupu postiže F1 0,61, odnosno 0,66 uz nove atribute ponašanja.

Zaključak i značaj za istraživanje. Rad potvrđuje da su na našem skupu podataka metode zasnovane na stablima i *boosting* najperspektivnije, a da su linearni modeli i Naive Bayes slabi. Za naš projekat su posebno korisna tri zapažanja: (1) uravnotežavanje treba primjenjivati samo na skupu za treniranje i pratiti njegov uticaj na preciznost, (2) pomjeranje praga odlučivanja je jednostavan način da se podesi odnos preciznosti i osjetljivosti, i (3) atributi izvedeni iz vremena transakcije i ponašanja korisnika mogu dodatno poboljšati detekciju.

Naučnoistraživački rad – Danijal Alibegović

Naslov rada: *Enhancing credit card fraud detection: highly imbalanced data case.*

Autori: Dalia Breskuvienė i Gintautas Dzemyda.

Izvor: *Journal of Big Data*, vol. 11, članak 182, 2024. [4]

Tabela 7: Sažeti pregled naučnoistraživačkog rada Breskuvienė i Dzemyde (2024)

Stavka	**Opis**
Problem	Selekcija atributa za detekciju prevara kreditnim karticama kada su podaci izrazito nebalansirani; uobičajene metode selekcije atributa zanemaruju manjinsku klasu.
Skup podataka	Tri skupa: sintetički skup transakcija (3 445 553 instanci, 0,14 % prevara), *Sparkov* skup – spojene datoteke `fraudTrain` i `fraudTest` (1 852 394 instanci, 0,52 % prevara) i stvarni evropski skup (284 807 instanci, 0,17 % prevara).
Korištene metode	Nova metoda selekcije atributa FID-SOM zasnovana na samoorganizujućim mapama (SOM), upoređena s univarijatnom selekcijom (F-test, χ^2, uzajamna informacija), RFE i važnošću atributa iz XGBoosta. Klasifikatori: Random Forest, XGBoost i CatBoost.
Metrike	F1-mjera, MCC, G-Mean, AUC-PR i AUC-ROC; svaki rezultat je prosjek pet ponavljanja s različitim *random seed* vrijednostima.
Najbolji rezultat	Na Sparkov skupu: **XGBoost + FID-SOM** (7 atributa), F1 **0,855**, AUC-PR 0,895, AUC-ROC 0,998, MCC 0,857 (bez selekcije atributa F1 je 0,543).

Cilj i istraživački problem. Autori polaze od toga da su podaci o prevarama nebalansirani, visoko dimenzionalni (posebno nakon kodiranja kategoričkih atributa) i podložni promjeni obrazaca kroz vrijeme (*concept drift*). Cilj rada je pokazati da pažljivo odabran, manji skup atributa poboljšava klasifikaciju više nego dodatni atributi.

Skup podataka i priprema. Za nas je posebno važno što je drugi skup u radu isti Sparkov skup, pri čemu su autori spojili datoteke za treniranje i testiranje i koristili 11 atributa. Umjesto nasumične podjele, podaci su podijeljeni *hronološki*: najranijih 80 % transakcija čini skup za treniranje, a kasnijih 20 % skup za testiranje. Autori naglašavaju da nasumična podjela vremenski zavisnih podataka daje previše optimistične rezultate. Kategorički atributi su kodirani *James-Stein* enkoderom, a numerički normalizovani na raspon [0, 1]. Namjerno nije korišteno uravnotežavanje klasa ni podešavanje

hiperparametara, kako bi se izolovao čist efekat selekcije atributa.

Poređenje eksperimentalnih rezultata. Tabela 8 prikazuje rezultate iz Tabele 6 rada za Sparkov skup, i to za model bez selekcije atributa (*baseline*) i za predloženu metodu FID-SOM.

Tabela 8: Rezultati na Sparkov skupu iz rada Breskuvienė i Dzemyde

Model	**F1**	**AUC-ROC**	**AUC-PR**	**MCC**	**G-Mean**
CatBoost – svi atributi	0,750	0,991	0,769	0,765	0,791
CatBoost – FID-SOM	0,828	0,997	0,866	0,831	0,870
Random Forest – svi atributi	0,622	0,967	0,767	0,660	0,682
Random Forest – FID-SOM	0,835	0,978	0,868	0,839	0,866
XGBoost – svi atributi	0,543	0,973	0,641	0,593	0,622
XGBoost – FID-SOM	**0,855**	**0,998**	**0,895**	**0,857**	**0,889**

Tumačenje rezultata. Na Sparkov skupu selekcija atributa ima veoma veliki efekat: F1-mjera XGBoosta raste s 0,543 na 0,855, a Random Foresta s 0,622 na 0,835. Istovremeno, AUC-ROC je visok (0,97–0,998) i za modele bez selekcije, što pokazuje da AUC-ROC na izrazito nebalansiranim podacima slabo razlikuje dobre i lošije modele. Zato autori stavljaju naglasak na AUC-PR, MCC i F1-mjeru. Na stvarnom evropskom skupu, čiji su atributi već dobijeni PCA transformacijom, efekat selekcije je mnogo manji (F1 0,796 naspram 0,801 za XGBoost). Ukupno je FID-SOM bio najbolja metoda u 32 od 45 poređenja (71 %).

Zaključak i značaj za istraživanje. Rad pokazuje da su na našem skupu ansambli stabala (XGBoost, CatBoost, Random Forest) uspješni, ali da njihove performanse snažno zavise od izbora atributa. To za naš projekat znači da treba ukloniti identifikatore i nebitne atribute, a kao metrike koristiti F1, AUC-PR i MCC, a ne samo tačnost i AUC-ROC. Rad upozorava i da nasumična podjela podataka može precijeniti performanse, pa je hronološka podjela vrijedna razmatranja.

Naučnoistraživački rad – Haris Macić

Naslov rada: *A machine learning based credit card fraud detection using the GA algorithm for feature selection.*

Autori: Emmanuel Ileberi, Yanxia Sun i Zenghui Wang.

Izvor: *Journal of Big Data*, vol. 9, članak 24, 2022. [5]

Tabela 9: Sažeti pregled naučnoistraživačkog rada Ileberija i saradnika (2022)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama uz izbor optimalnog podskupa atributa pomoću genetskog algoritma (GA).
Skup podataka	Evropski skup transakcija kreditnim karticama (Kaggle, septembar 2013.): 284 807 transakcija, 0,172 % prevara, 30 numeričkih atributa (V1–V28 dobijeni PCA transformacijom, `Time`, `Amount`). Dodatna provjera na sintetičkom skupu s oko 24,4 miliona transakcija.
Korištene metode	Genetski algoritam za selekciju atributa (funkcija prilagođenosti je tačnost Random Foresta); klasifikatori: stablo odlučivanja, Random Forest, logistička regresija, ANN i Naive Bayes; SMOTE za uravnotežavanje i *min-max* normalizacija.
Metrike	Tačnost (glavna metrika), osjetljivost (recall), preciznost, F1-mjera i AUC.
Najbolji rezultat	**GA-RF** s vektorom atributa v5 (13 atributa): tačnost **99,98 %**, preciznost 95,34 %, recall 72,56 %, F1-mjera 82,41 %.

Cilj i istraživački problem. Autori smatraju da veliki broj atributa može narušiti performanse klasifikatora i predlažu sistem u kojem genetski algoritam bira podskup atributa, a zatim se na tom podskupu trenira i upoređuje pet klasičnih algoritama mašinskog učenja.

Skup podataka i priprema. Korišten je najpoznatiji javni skup za ovaj problem: transakcije evropskih korisnika kartica tokom dva dana, sa samo 492 prevare. Za razliku od našeg skupa, svi atributi su numerički i anonimizovani. Klasna nebalansiranost je ublažena metodom SMOTE, a atributi su normalizovani *min-max* postupkom. Genetski algoritam je pronašao pet kandidatskih vektora atributa (v1–v5) dužine od 9 do 18 atributa, a atribut `Amount` se nalazi u svakom od njih.

Poređenje eksperimentalnih rezultata. Tabela 10 prikazuje rezultate za vektor v5 (Tabela 6 rada) i za vektor v1, na kojem je ostvarena najveća F1-mjera (Tabela 2 rada).

Tabela 10: Rezultati klasifikatora iz rada Ileberija i saradnika (u %)

Model (vektor atributa)	Acc.	Recall	Prec.	F1
Random Forest (v5)	**99,98**	**72,56**	**95,34**	**82,41**
Stablo odlučivanja (v5)	99,89	72,56	65,07	68,61
ANN (v5)	99,08	77,87	12,27	21,20
Naive Bayes (v5)	99,44	57,52	15,85	24,85
Logistička regresija (v5)	99,77	46,90	34,64	39,84
Random Forest (v1)	99,94	76,99	89,69	82,85
ANN (v1)	99,94	77,87	84,61	81,10
Naive Bayes (v1)	98,13	84,95	6,83	12,65

Tumačenje rezultata. Random Forest je najbolji ili među najboljima za svaki vektor atributa. Iako svi modeli imaju tačnost iznad 98 %, preciznost i F1-mjera se drastično razlikuju: Naive Bayes s vektorom v1 ima tačnost 98,13 %, a preciznost samo 6,83 %, što znači da je velika većina transakcija koje označi kao prevarne zapravo legitimna. Rezultati pokazuju i da izbor atributa snažno utiče na pojedine modele (npr. F1 ANN-a pada s 81,10 % na 21,20 % između vektora v1 i v5). Treba imati na umu da autori kao glavnu metriku koriste tačnost, koja je na skupu s 0,172 % prevara slabo informativna.

Zaključak i značaj za istraživanje. Rad potvrđuje da je Random Forest pouzdan izbor za detekciju prevara i da Naive Bayes ima najlošiji odnos preciznosti i osjetljivosti. Za naš projekat je važna i pouka o evaluaciji: kod nebalansiranih podataka rezultate treba prikazivati kroz preciznost, recall i F1-mjeru za klasu prevare, a ne samo kroz tačnost.

Naučnoistraživački rad – Kerim Hajdar

Naslov rada: *Credit Card Fraud Detection Using Improved Deep Learning Models.*

Autori: Sumaya S. Sulaiman, Ibraheem Nadher i Sarab M. Hameed.

Izvor: *Computers, Materials & Continua*, vol. 78, br. 1, str. 1049–1069, 2024. [6]

Tabela 11: Sažeti pregled naučnoistraživačkog rada Sulaiman i saradnika (2024)

Stavka	**Opis**
Problem	Detekcija prevara kreditnim karticama pomoću modela dubokog učenja i ispitivanje uticaja podešavanja hiperparametara i metoda uravnotežavanja na njihove performanse.
Skup podataka	Evropski skup transakcija kreditnim karticama (Kaggle, septembar 2013.): 284 807 transakcija, od kojih su 492 prevarne (0,172 %).
Korištene metode	Autoenkoder (AE), konvolucijska neuronska mreža (CNN) i LSTM mreža; podešavanje hiperparametara metodama *random search* i Bayesovom optimizacijom (cilj: F1-mjera); uravnotežavanje metodama RUS, SMOTE i ADASYN; stratifikovana unakrsna validacija.
Metrike	Tačnost, stopa detekcije (*detection rate*, tj. recall) i AUC; F1-mjera kao funkcija cilja pri podešavanju hiperparametara.
Najbolji rezultat	**LSTM + SMOTE** (*random search*): tačnost **99,2 %**, stopa detekcije **93,3 %**, AUC **96,3 %**.

Cilj i istraživački problem. Autori polaze od toga da uspješnost modela dubokog učenja u velikoj mjeri zavisi od izbora hiperparametara. Cilj je ispitati kako sistematsko podešavanje (broj neurona, *dropout*, aktivacijska funkcija, veličina *batch*-a, optimizator, funkcija gubitka i stopa učenja) u kombinaciji s različitim metodama uravnotežavanja utiče na detekciju prevara.

Skup podataka i priprema. Korišten je javni evropski skup sa 30 numeričkih atributa i izrazitom nebalansiranošću klasa. Podaci su podijeljeni na skup za treniranje, validaciju i testiranje stratifikovanom unakrsnom validacijom, a uravnotežavanje (RUS, SMOTE ili ADASYN) primijenjeno je *samo na skupu za treniranje*. Za svaki model izvedeno je osam pokretanja (četiri slučajnom pretragom i četiri Bayesovom optimizacijom), uz četiri scenarija: bez uravnotežavanja, RUS, SMOTE i ADASYN.

Poređenje eksperimentalnih rezultata. Tabela 12 prikazuje dio rezultata iz Tabele 3 rada (podešavanje hiperparametara slučajnom pretragom).

Tabela 12: Rezultati modela dubokog učenja iz rada Sulaiman i saradnika (u %)

Model – uravnotežavanje	**Acc.**	**Stopa detekcije**	**AUC**
AE – bez uravnotežavanja	95,0	90,0	92,7
AE – SMOTE	96,1	89,7	92,9
CNN – bez uravnotežavanja	99,7	83,0	91,4
CNN – SMOTE	99,8	89,7	94,7
LSTM – bez uravnotežavanja	99,9	80,8	90,4
LSTM – RUS	98,4	88,9	93,6
LSTM – SMOTE	**99,2**	**93,3**	**96,3**
LSTM – ADASYN	99,2	92,6	95,9

Tumačenje rezultata. Uravnotežavanje skupa za treniranje značajno povećava stopu detekcije: kod LSTM mreže ona raste s 80,8 % (bez uravnotežavanja) na 93,3 % uz SMOTE, uz mali pad tačnosti (s 99,9 % na 99,2 %). Metode koje generišu sintetičke primjere (SMOTE, ADASYN) bile su uspješnije od RUS-a, koji odbacuje dio podataka većinske klase. Autori LSTM i CNN modelima pripisuju prednost jer mogu naučiti sekvencijalne obrasce transakcija. Rad ne prikazuje preciznost, pa nije moguće procijeniti broj lažnih alarma koji prati visoku stopu detekcije.

Zaključak i značaj za istraživanje. Rad pokazuje da podešavanje hiperparametara i oversampling skupa za treniranje mogu značajno povećati osjetljivost modela, što je direktno povezano sa zadacima 2.2 našeg projekta (*tuning* i uravnotežavanje klasa). Istovremeno, potvrđuje važnost prikaza preciznosti uz recall: bez preciznosti visoka stopa detekcije ne govori koliko je model upotrebljiv u praksi.

Zbirni pregled radova

Tabela 13: Zbirni pregled analiziranih naučnoistraživačkih radova

Rad	Skup podataka	Metode	Metrike	Najbolji rezultat
Afriyie i sar. (2023) [2]	Sparkov	LR, DT, RF; RUS	Acc, Prec, Rec, F1, Spec, AUC	RF: AUC 0,989, recall 0,97, F1 0,17
Al-Bulushi i sar. (2026) [3]	Sparkov + 5 neviđenih skupova	LR, NB, DT, RF, ANN, XGBoost; RUS, ROS, SMOTE; ansambli	Acc, Prec, Rec, F1, AUC	XGBoost: F1 0,84; Bagging 1: F1 0,795, recall 0,864
Breskuvienė i Dzemyda (2024) [4]	Sparkov, sintetički i evropski skup	RF, XGBoost, CatBoost; selekcija atributa FID-SOM	F1, MCC, G-Mean, AUC-PR, AUC-ROC	XGBoost + FID-SOM (Sparkov): F1 0,855, AUC-PR 0,895
Ileberi i sar. (2022) [5]	Evropski skup	DT, RF, LR, ANN, NB; GA selekcija atributa; SMOTE	Acc, Prec, Rec, F1, AUC	GA-RF: Acc 99,98 %, F1 82,41 %
Sulaiman i sar. (2024) [6]	Evropski skup	AE, CNN, LSTM; tuning hiperparametara; RUS, SMOTE, ADASYN	Acc, stopa detekcije, AUC	LSTM + SMOTE: stopa detekcije 93,3 %, AUC 96,3 %

Očekivanja na osnovu literature

Algoritmi. U svim radovima koji ih porede najbolje rezultate daju ansambli zasnovani na stablima odlučivanja. Random Forest je najbolji model kod Afriyie i saradnika [2] i Ileberija i saradnika [5], a XGBoost i Random Forest kod Al-Bulushi i saradnika [3] i Breskuvienė i Dzemyde [4]. Ovi modeli dobro rade s mješovitim tipovima atributa, nelinearnim odnosima i atributima različitih skala. Neuronske mreže postižu konkurentne rezultate [3, 6], ali zahtijevaju pažljivo podešavanje hiperparametara. Logistička regresija i Naive Bayes dosljedno daju najslabije rezultate: na Sparkov skupu F1-mjera im je ispod 0,1 [3], a Naive Bayes ima preciznost svega 7–16 % i na evropskom skupu [5]. Ove modele zato očekujemo kao donju granicu (*baseline*) za poređenje. Kombinovanje modela u ansambl (*bagging*, *stacking*) daje stabilne rezultate i visok recall, ali ne nadmašuje uvijek najbolji pojedinačni model [3].

Uravnotežavanje klasa. Uravnotežavanje skupa za treniranje (RUS, ROS, SMOTE) povećava osjetljivost modela [6, 3], ali na realističnoj raspodjeli klasa značajno smanjuje preciznost [2, 3]. Primjer je Random Forest treniran na *undersampling* uzorku: recall 0,97 uz preciznost 0,09–0,17. Za naš projekat to znači da prije balansiranja treba iz polaznih podataka izdvojiti odvojene trening, validacijske i testne dijelove. Uravnotežavanje se primjenjuje isključivo na trening dijelu, a učinak provjerava na

izdvojenim podacima s originalnim udjelom prevara (oko 0,58 %). Postojeći CSV uzorci se preklapaju (odjeljak 1.3), pa se ne mogu neposredno koristiti kao nezavisni trening i testni skupovi.

Metrike. Ukupna tačnost nije pouzdana mjera jer model koji sve transakcije proglasi legitimnim postiže tačnost od oko 99,4 %. Gotovo svi radovi koriste preciznost, osjetljivost (recall) i F1-mjeru za klasu prevare, te AUC-ROC. Breskuvienė i Dzemyda [4] pokazuju da je AUC-ROC na nebalansiranim podacima visok (0,97–0,998) i za osjetno slabije modele, pa preporučuju AUC-PR i MCC. Kao glavne metrike projekta zato planiramo koristiti **F1-mjeru, preciznost i recall za klasu prevare, AUC-PR i MCC**, a dodatno tačnost, specifičnost, kappa statistiku i AUC-ROC, u skladu sa specifikacijom zadatka 2.2.

Atributi. Na Sparkov skupu uočeni su obrasci prevara povezani s iznosom transakcije, dobom dana i kategorijom kupovine [2], dok selekcija atributa i atributi izvedeni iz ponašanja korisnika dodatno poboljšavaju rezultate [4, 3]. Očekujemo da će izvedeni atributi (sat transakcije, starost korisnika, udaljenost korisnika od trgovca) biti korisniji od identifikatora i ličnih podataka, koje treba ukloniti.

Istraživačka hipoteza

Radna hipoteza: *Na korištenom Sparkov skupu podataka modeli zasnovani na ansamblima stabala odlučivanja (Random Forest, gradient boosting) postići će veću F1-mjeru i AUC-PR za klasu prevare od linearnih i probabilističkih modela (logistička regresija, Naive Bayes). Uravnotežavanje skupa za treniranje i podešavanje hiperparametara povećaće osjetljivost modela, ali uz pad preciznosti na skupu s realističnim udjelom prevara. Ansambl koji kombinuje različite klasifikatore postići će F1-mjeru najmanje jednaku najboljem pojedinačnom modelu, uz stabilnije rezultate kroz unakrsnu validaciju.*

Hipoteza će se provjeriti u zadacima 2.2 i 2.3 poređenjem metrika svih modela na istom testnom skupu i kroz unakrsnu validaciju.

1.3. Istraživačka analiza podataka

Analiza obuhvata sva 22 atributa osnovnog skupa `fraud_balanced.csv`, uključujući ciljnu klasu `is_fraud` (0 – legitimna, 1 – prevarna transakcija). Cilj je opisati raspodjele, provjeriti kvalitet podataka i izdvojiti obrasce važne za pripremu i modeliranje. Korištene su deskriptivne statistike, frekvencije kategorija, vremenske raspodjele te mjere povezanosti između atributa. Detaljni postupak i vizualizacije svih varijabli dostupni su u bilježnici.

Struktura skupa i kvalitet podataka

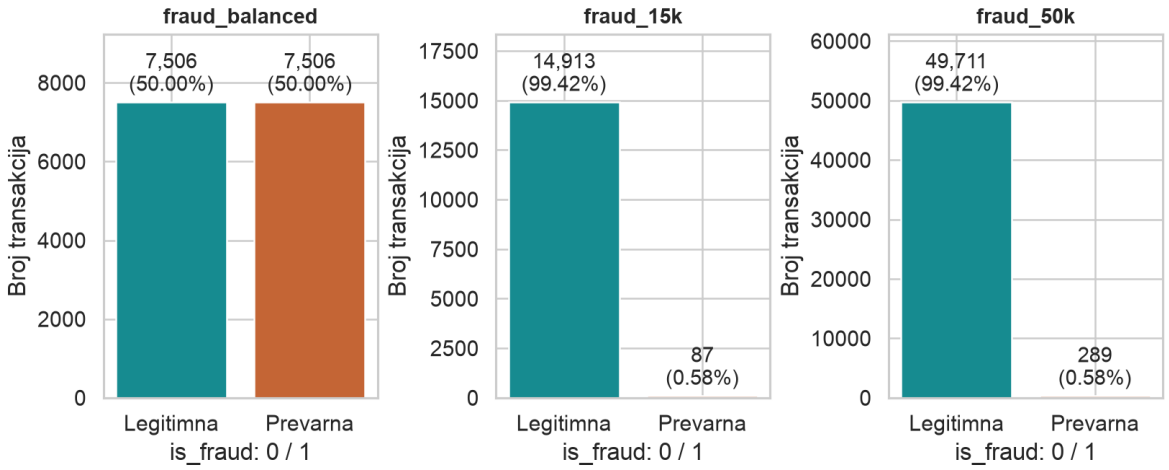
Radni skup ima **15 012 transakcija i 22 kolone**. Nema nedostajućih vrijednosti, praznih tekstova ni dupliranih redova. Svih 15 012 oznaka `trans_num` je jedinstveno. Datumi se uspješno parsiraju, iznosi su pozitivni, a koordinate u dopuštenim geografskim rasponima. Ponavljanja kartica i kupaca predstavljaju različite transakcije.

`cc_num` i `zip` posmatrani su kao tekstualne oznake, jer njihove aritmetičke sredine nemaju korisno značenje. U 919 redova poštanski broj ima četiri cifre, a u 14 093 pet; čitanje kao tekst čuva zatečeni zapis, ali ne vraća eventualno izgubljene vodeće nule.

Tabela 14: Raspodjela ciljne klase u tri sačuvana skupa

Skup	Ukupno	Legitimne	Prevare	Udio prevara
`fraud_balanced.csv`	15 012	7 506	7 506	50,00 %
`fraud_15k.csv`	15 000	14 913	87	0,58 %
`fraud_50k.csv`	50 000	49 711	289	0,58 %

Odnos klasa 50/50 posljedica je *undersamplinga*. Udjeli prevara iz glavnog skupa zato opisuju balansirani uzorak, a ne stvarnu učestalost prevara. Dodatni uzorci od 15 i 50 hiljada redova zadržavaju približno 0,58 % prevara.



Slika 1: Broj i udio legitimnih i prevarnih transakcija u sva tri CSV uzorka. Samo je osnovni EDA uzorak balansiran.

Analiza svih originalnih atributa

Tabela 15 daje pojedinačan pregled svih varijabli. Za kategoričke varijable broj različitih vrijednosti i najčešća vrijednost predstavljaju sažetak distribucije; potpune frekvencije izračunate su u bilježnici.

Tabela 15: Pojedinačna analiza svih 22 atributa

Atribut	Tip po značenju	Distribucija / statistika	Zapažanje i tumačenje
`trans_date_ trans_time`	Datum i vrijeme	15 006 različitih vremena; od 1. 1. 2019. do 21. 6. 2020.; 10 562 reda iz 2019. i 4 450 iz 2020.	Periodi nisu jednako dugi; sirovi mjesečni brojevi nisu direktno uporedivi. Sat i kalendarske komponente analiziraju se odvojeno.
`cc_num`	Identifikator	977 kartica; najviše 38 transakcija jedne kartice (0,25 %).	Ponavljanje je očekivano. Vrijednost nije numerička mjera; veze iste kartice važne su pri kasnijoj podjeli podataka.
`merchant`	Kategorički	693 trgovca; najčešći `fraud_Kilback LLC`: 72 transakcije (0,48 %).	Veliki broj kategorija i rijetki trgovci. Svi nazivi imaju prefiks `fraud_`, pa prefiks ne razdvaja klase.
`category`	Kategorički	14 kategorija; `grocery_pos`: 2 494 (16,61 %).	Raspodjela se razlikuje između klasa. Kategorije online i fizičke kupovine nisu podjednako zastupljene.
`amt`	Numerički, USD	Medijan 89,54; sredina 299,52; raspon 1,00–6 337,25.	Distribucija je asimetrična udesno; veliki iznosi su češći kod prevara, ali iznos sam ne razdvaja sve transakcije.
`first`	Tekst / kategorija	352 imena; Christopher: 330 redova (2,20 %).	Ime se ponavlja kod različitih osoba; nije jedinstven identifikator niti opravdano objašnjenje prevare.
`last`	Tekst / kategorija	480 prezimena; Smith: 301 red (2,01 %).	Frekvencije odražavaju sastav simuliranog uzorka i ponovljene kupce. Izbjegavati učenje identiteta umjesto ponašanja.
`gender`	Binarna kategorija	F: 7 835 (52,19 %); M: 7 177 (47,81 %).	Opisuje spol vlasnika kartice; sama ukupna frekvencija ne pokazuje koliko atribut pomaže razlikovanju klasa.

Atribut	Tip po značenju	Distribucija / statistika	Zapažanje i tumačenje
`street`	Tekst / adresa	977 adresa; najčešća adresa javlja se 38 puta (0,25 %).	Adrese se ponavljaju kroz transakcije istog korisnika. Veliki broj različitih adresa i veza s identitetom zahtijevaju oprez.
`city`	Kategorički	889 naziva; Warren: 57 redova (0,38 %).	Mnogo rijetkih gradova; isti naziv grada ne mora označavati istu lokaciju bez savezne države.
`state`	Kategorički	51 oznaka; TX: 1 024 reda (6,82 %).	Geografska zastupljenost nije jednaka. Udjeli u malim grupama nisu stabilni pokazatelji rizika.
`zip`	Poštanski kod	964 koda; najčešći `82514`: 45 redova (0,30 %).	Kategoričko značenje i neujednačena dužina zapisa. Razlika između dva koda nije geografska udaljenost.
`lat`	Numerički, stepeni	962 vrijednosti; sredina 38,62; raspon 20,03–66,69.	Koordinata korisnika; velika sličnost s geografskom širinom trgovca, slaba pojedinačna veza s klasom.
`long`	Numerički, stepeni	963 vrijednosti; sredina $-90,28$; raspon $-165,67$ do $-67,95$.	Zapadne dužine su negativne. Krajnje lokacije nisu automatski greške niti razlog za brisanje.
`city_pop`	Numerički, broj	875 vrijednosti; medijan 2 526; sredina 90 510,75; najviše 2 906 700.	Vrlo izražen desni rep; većina transakcija vezana je za manje gradove, uz nekoliko velikih populacija.
`job`	Kategorički	493 zanimanja; Materials engineer: 114 redova (0,76 %).	Mnoge rijetke kategorije i ponovljeni korisnici; opažena povezanost ne dokazuje uzrok prevare.
`dob`	Datum rođenja	962 datuma; od 30. 10. 1924. do 29. 1. 2005.	Starost se računa u trenutku transakcije. Ponavljanja odražavaju iste korisnike ili isti datum rođenja.

Atribut	Tip po značenju	Distribucija / statistika	Zapažanje i tumačenje
`trans_num`	Identifikator	15 012 različitih vrijednosti; svaka se pojavljuje jednom.	Potvrđuje jedinstvenost transakcija i služi provjeri preklapanja skupova; nema smisla računati numeričku statistiku oznake.
`unix_time`	Numerički zapis vremena	15 006 vrijednosti; pretvaranje standardnim Unix sekundama daje 2012–2013.	Ne slaže se s tekstualnim datumom: dodavanje sedam kalendarskih godina usklađuje svih 15 012 redova.
`merch_lat`	Numerički, stepeni	15 005 vrijednosti; sredina 38,61; raspon 19,04–67,51.	Geografska širina trgovca varira između transakcija; gotovo je linearno povezana s `lat`.
`merch_long`	Numerički, stepeni	15 010 vrijednosti; sredina $-90,28$; raspon $-166,55$ do $-67,03$.	Gotovo je linearno povezana s `long`; analizirana je i udaljenost između dvije lokacije.
`is_fraud`	Binarna ciljna klasa	0: 7 506 legitimnih; 1: 7 506 prevarnih transakcija.	Odnos 50/50 je namjerno formiran. Atribut je cilj predviđanja i ne smije postati ulaz modela.

Numeričke distribucije i izdvojene vrijednosti

Tabela 16 prikazuje osnovne statistike mjerenih numeričkih veličina: sredinu, uzoračku standardnu devijaciju s, minimum, kvartile i maksimum. Identifikatori i poštanski kodovi izostavljeni su iz numeričke statistike. `unix_time` izostavljen je iz ove tabele i numeričkih histograma jer se njegovo neslaganje s datumom provjerava u dijelu o vremenu. Izvorne vrijednosti nisu zaokružene; samo su prikazi statistika zaokruženi na dvije decimale.

Tabela 16: Deskriptivna statistika numeričkih atributa, zaokružena na dvije decimale

Atribut	Sredina	s	Min.	Q_1	Medijan	Q_3	Maks.
`amt`	299,52	373,92	1,00	20,50	89,54	477,10	6 337,25
`lat`	38,62	5,13	20,03	34,78	39,41	42,02	66,69
`long`	-90,28	14,08	-165,67	-96,98	-87,41	-80,13	-67,95
`city_pop`	90 510,75	303 554,43	23,00	743,00	2 526,00	21 125,00	2 906 700,00
`merch_lat`	38,61	5,17	19,04	34,90	39,40	41,99	67,51
`merch_long`	-90,28	14,11	-166,55	-96,99	-87,36	-80,17	-67,03

`amt` je asimetričan udesno: sredina 299,52 USD znatno je veća od medijana 89,54 USD,

uz standardnu devijaciju 373,92 USD i asimetriju 1,48. Manji broj velikih iznosa podiže prosjek. Za `city_pop` razlika je još izraženija: medijan je 2 526, a sredina 90 510,75 stanovnika, uz asimetriju 5,62.

Pravilo $[Q_1 - 1{,}5\,IQR,\ Q_3 + 1{,}5\,IQR]$, gdje je $IQR = Q_3 - Q_1$, izdvaja 118 iznosa i 2 774 vrijednosti populacije. Za `lat`, `long`, `merch_lat` i `merch_long` izdvaja 66, 491, 79 i 480 redova. To su statistički izdvojene vrijednosti, a ne dokazane greške; u ovoj fazi nijedna nije automatski uklonjena. Slika 2 pokazuje oblike raspodjela, uz logaritamsku osu za iznos i populaciju radi preglednosti njihovih dugih repova.

Razlika iznosa između klasa prikazana je na slici 3. Legitimne transakcije imaju sredinu 67,72 USD i medijan 47,92 USD, a prevare sredinu 531,32 USD i medijan 396,50 USD. Prevare češće imaju veće iznose, ali se raspodjele preklapaju. Najveći iznos u skupu, 6 337,25 USD, pripada legitimnoj transakciji; najveći iznos prevare je 1 376,04 USD. Zato visok iznos sam po sebi ne određuje klasu.

Datumi i vremenski obrasci

Transakcije obuhvataju period 1. 1. 2019.–21. 6. 2020. godine. Posljednji mjesec je nepotpun, a godišnji periodi različito dugi, pa sirovi mjesečni brojevi ne predstavljaju direktno poređenje rizika.

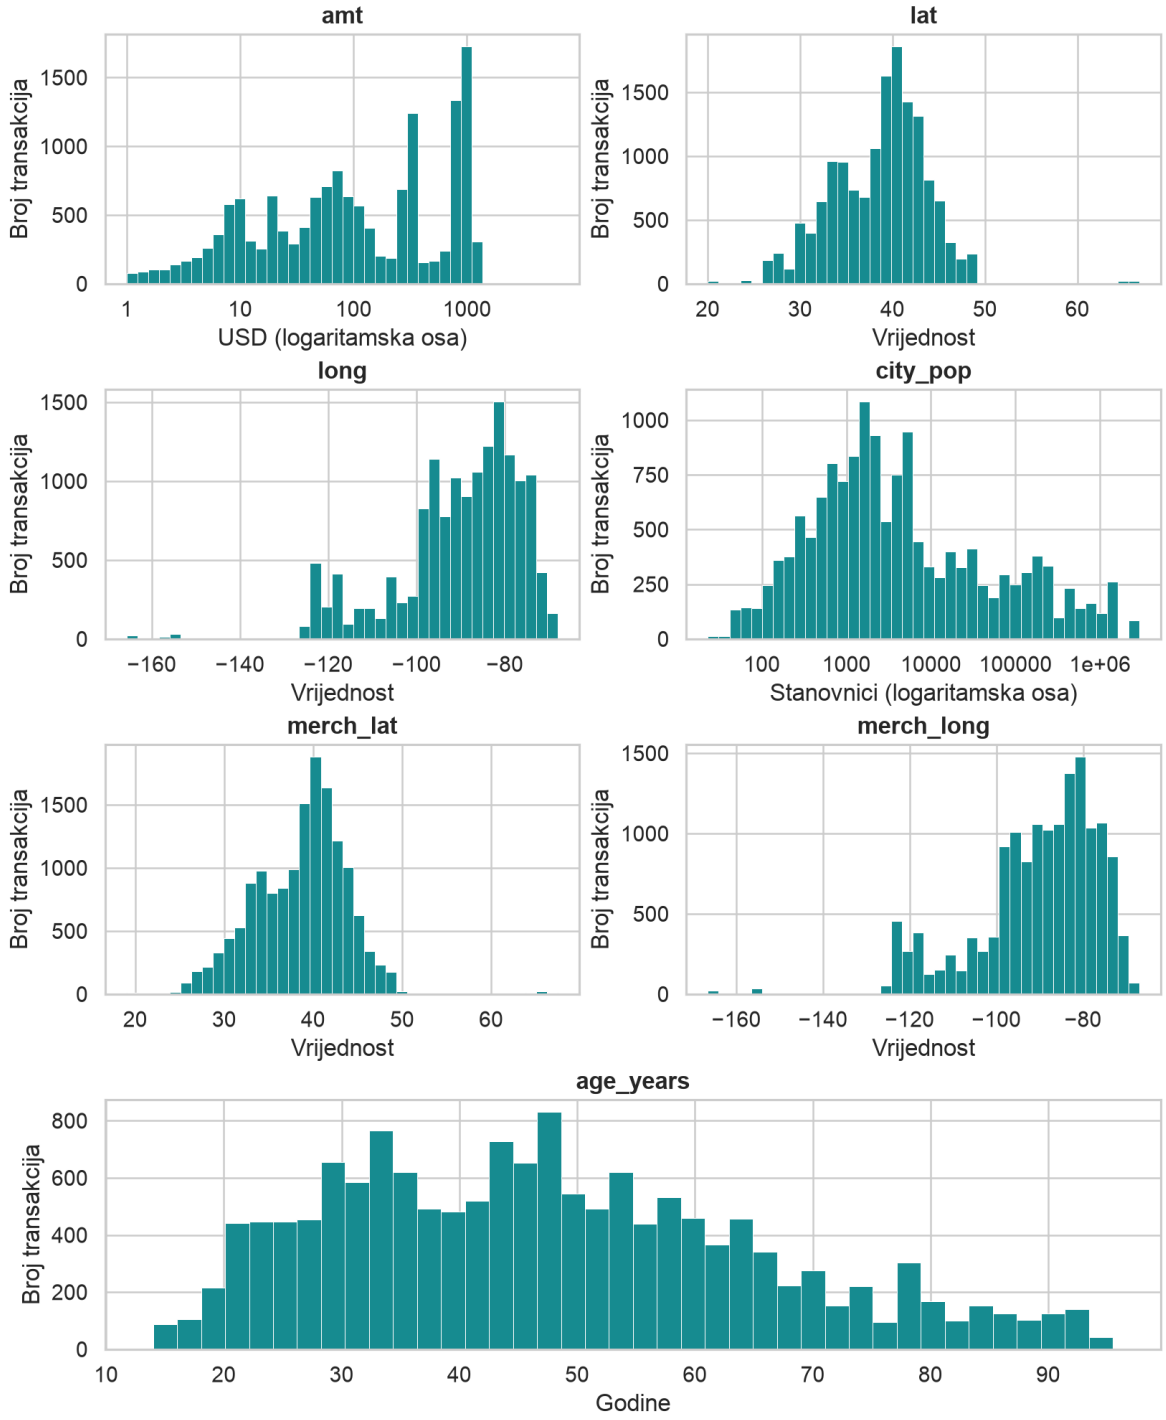
Potvrđena je **neusklađenost zapisa vremena**: standardno pretvaranje `unix_time` daje 2012–2013. godinu. Dodavanje sedam kalendarskih godina usklađuje svih 15 012 redova s tekstualnim datumom. Uzrok se ne može utvrditi iz dostupnih podataka. Vremenski obrasci i starost zato su izvedeni iz `trans_date_trans_time`, bez prepisivanja originalnog zapisa.

Približna starost korisnika u trenutku transakcije, izračunata iz `dob`, iznosi 14–95 godina; sredina je 47,57, standardna devijacija 18,06 i medijan 46,05 godina. Datumi rođenja nakon transakcije nisu pronađeni. Raspodjela je ponderisana brojem transakcija, pa korisnici s više kupovina imaju veću težinu.

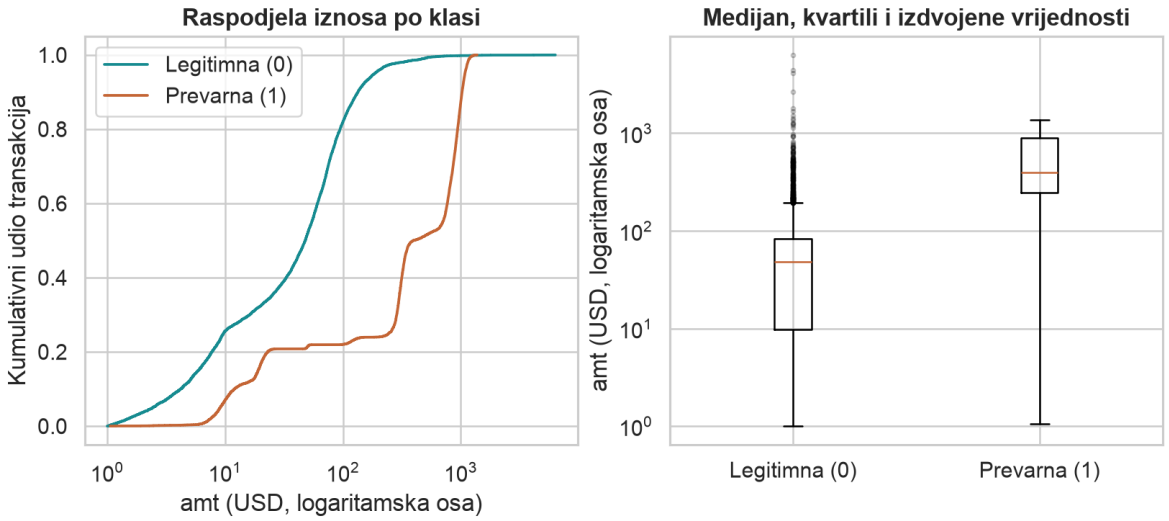
U periodu 22:00–03:59 obavljeno je **84,76 % prevara i 21,72 % legitimnih transakcija** (slika 5). Ovi procenti predstavljaju udio noćnih transakcija unutar svake klase, a ne udio prevara među svim noćnim kupovinama. Razlike po danu u sedmici manje su izražene. Sat je ciklična veličina, što treba uzeti u obzir pri kasnijoj pripremi podataka.

Kategoričke distribucije i razlike između klasa

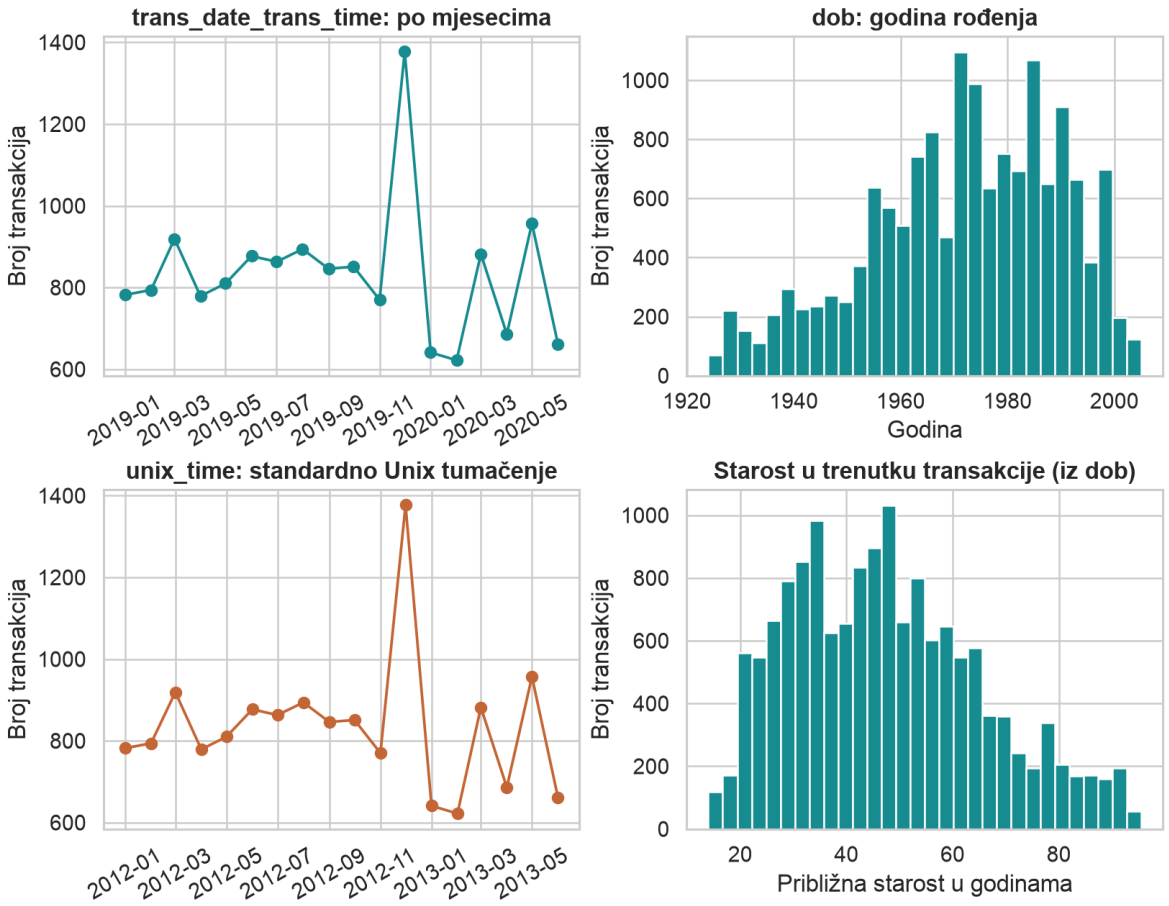
Za kategoričke atribute izračunati su broj različitih vrijednosti, frekvencije i udjeli klasa. Tabela 15 sažima raspodjele svih atributa, dok su njihovi pojedinačni grafikoni u bilježnici. Kartice, adrese, imena i prezimena ponavljaju se kroz transakcije; `trans_num` je jedinstven. Svi trgovci imaju prefiks `fraud_`, pa on ne razlikuje legitimne transakcije



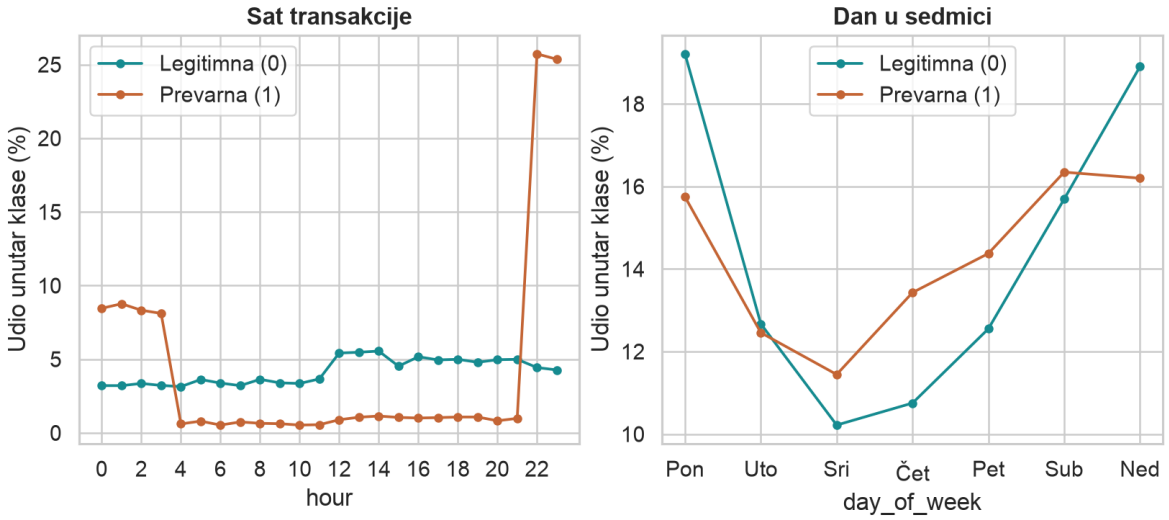
Slika 2: Distribucije šest originalnih numeričkih veličina i izvedene starosti, bez `unix_time`. Iznos i populacija prikazani su u originalnim jedinicama na logaritamskoj horizontalnoj osi. Visina stupca označava broj transakcija u intervalu.



Slika 3: Poređenje iznosa legitimnih i prevarnih transakcija pomoću empirijske kumulativne distribucije i kutijastog dijagrama. Logaritamska osa omogućava prikaz cijelog raspona.



Slika 4: Transakcije po mjesecima, godine rođenja, provjera Unix zapisa i starost u trenutku transakcije. Broje se transakcije, a ne jedinstveni korisnici.



Slika 5: Sat i dan u sedmici prema klasi. Procenti su normalizovani zasebno unutar svake klase, pa se porede raspodjele vremena izvršenja.

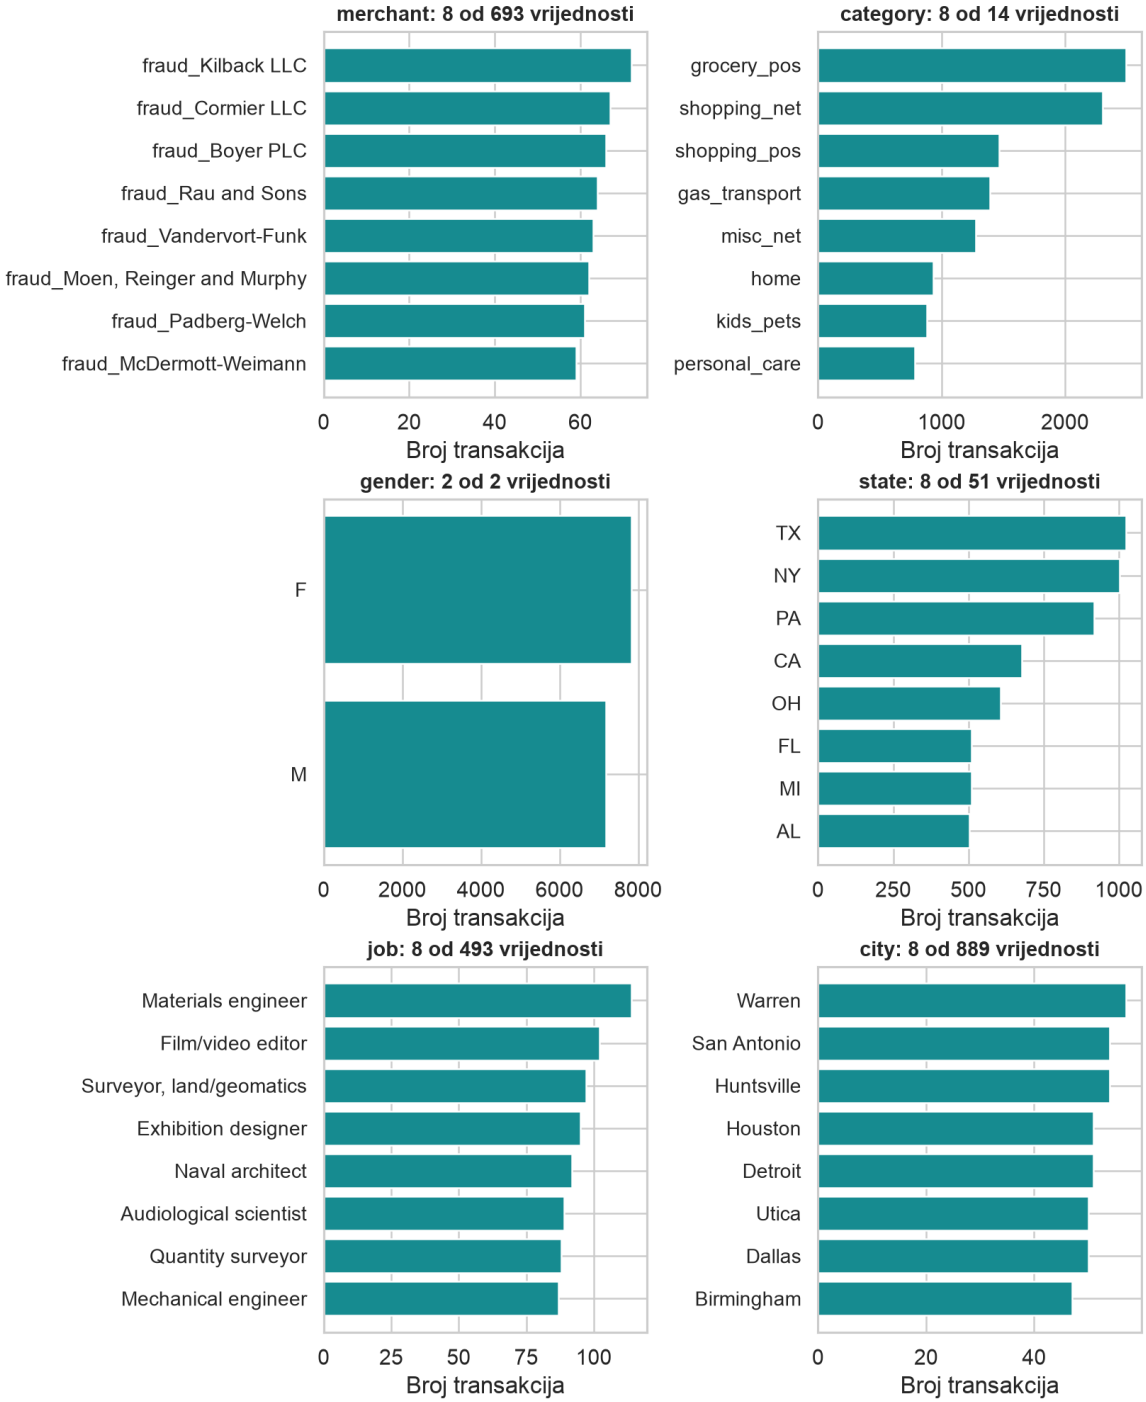
i prevare.

Vrsta kupovine pokazuje izražene razlike između klasa (slika 8). Grafikon svaku klasu zasebno normalizuje na 100 %: na primjer, 23,22 % svih prevara pripada kategoriji kupovine namirnica na prodajnom mjestu, a 22,82 % online kupovini. Tabela 17 koristi drugi nazivnik: broj prevara dijeli ukupnim brojem transakcija pojedine kategorije.

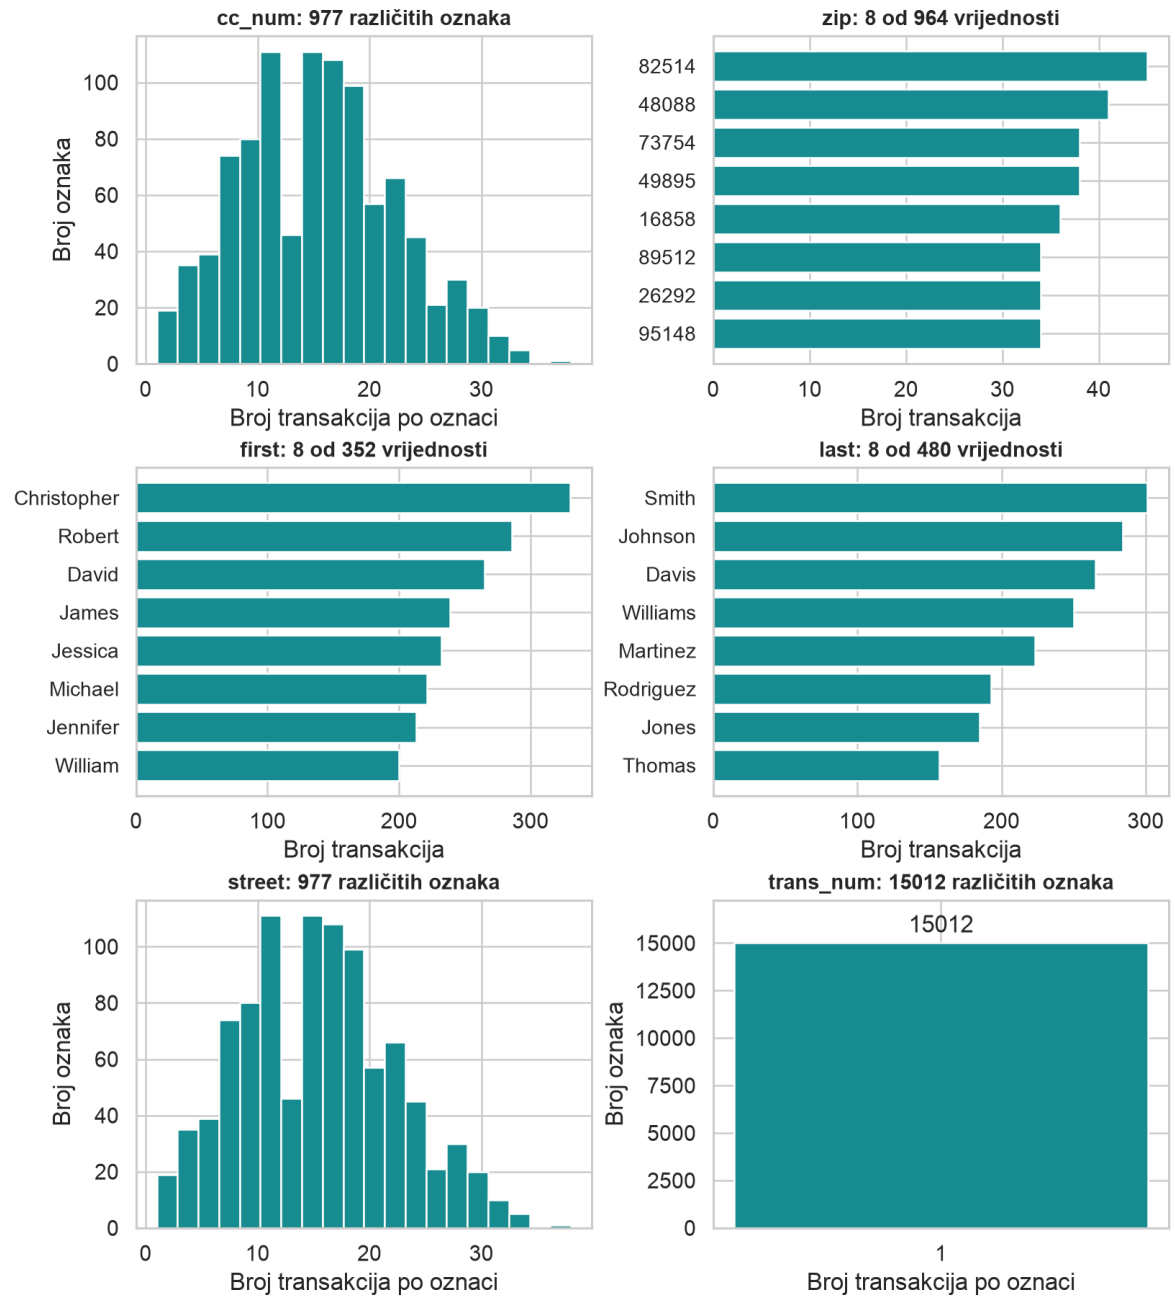
U balansiranom uzorku najviši udio prevara ima online kupovina (74,28 %), a najniži kategorija doma (21,24 %). Ovi udjeli nisu procjene stvarnog rizika jer je uzorak namjerno balansiran.

Tabela 17: Sastav pojedinačnih kategorija u balansiranom uzorku

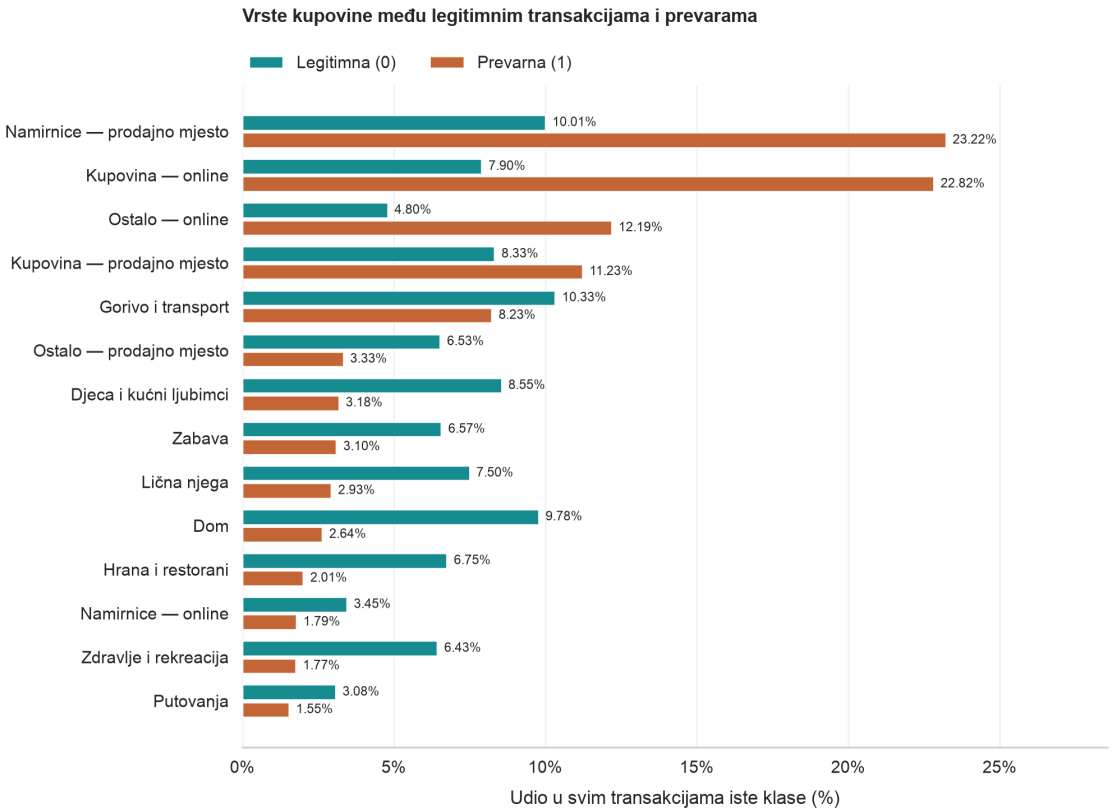
Vrsta kupovine	Ukupno	Legitimne	Prevare	Udio prevara
Kupovina — online	2 306	593	1 713	74,28 %
Ostalo — online	1 275	360	915	71,76 %
Namirnice — prodajno mjesto	2 494	751	1 743	69,89 %
Kupovina — prodajno mjesto	1 468	625	843	57,43 %
Gorivo i transport	1 393	775	618	44,36 %
Namirnice — online	393	259	134	34,10 %
Ostalo — prodajno mjesto	740	490	250	33,78 %
Putovanja	347	231	116	33,43 %
Zabava	726	493	233	32,09 %
Lična njega	783	563	220	28,10 %
Djeca i kućni ljubimci	881	642	239	27,13 %
Hrana i restorani	658	507	151	22,95 %
Zdravlje i rekreacija	616	483	133	21,59 %
Dom	932	734	198	21,24 %



Slika 6: Najčešće vrijednosti trgovca, kategorije, spola, savezne države, zanimanja i grada. Za svaki atribut prikazano je najviše osam vrijednosti.



Slika 7: Ponavljanje kartica i adresa te najčešći poštanski brojevi, imena i prezimena. Kod kartica i adresa histogram broji koliko oznaka ima broj transakcija u pojedinom intervalu; svaka oznaka transakcije pojavljuje se jednom.



Slika 8: Svih 14 kategorija prema klasi, izraženo procentom transakcija unutar svake klase. Ovaj prikaz poredi zastupljenost kategorija, a ne stvarnu vjerovatnoću prevare.

Povezanost atributa

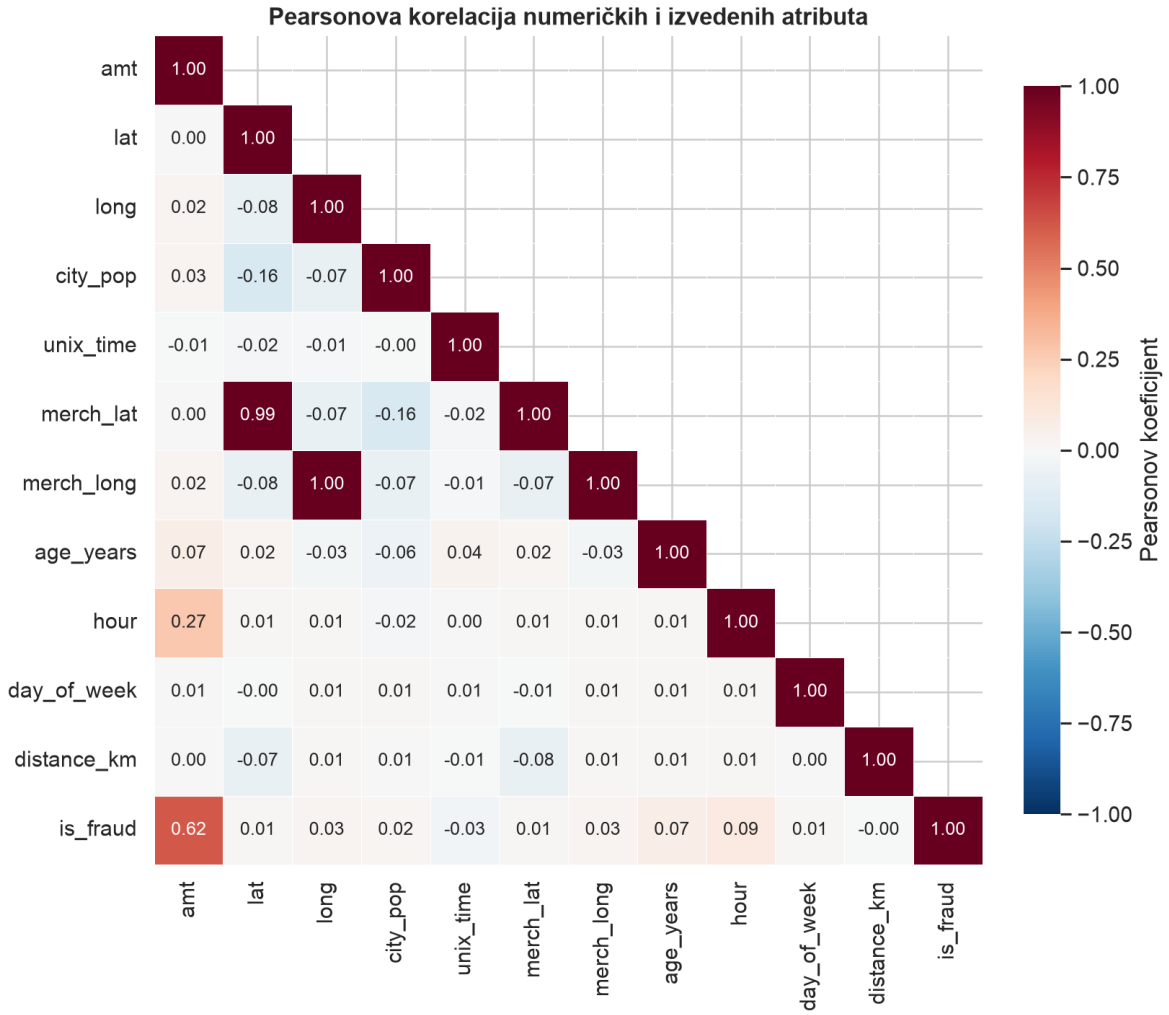
Pearsonova korelacija korištena je za linearnu, a Spearmanova za povezanost rangova. Korelacije numeričkih veličina s ciljem date su u tabeli 18, a povezanosti parova na slici 9. Identifikatori i kodovi nisu tretirani kao kontinuirana mjerenja.

Najjaču pojedinačnu numeričku vezu s klasom ima `amt` ($r = 0,62$, $\rho = 0,58$), što je saglasno razlikama iznosa po klasama. Veza nije dokaz uzročnosti niti mjera tačnosti modela. Koordinate korisnika i trgovca nose vrlo slične informacije: $r = 0,99$ za `lat`–`merch_lat` i $r = 1,00$ za `long`–`merch_long`. Prikaz 1,00 je posljedica zaokruživanja i ne znači da su koordinate identične. Njihova pojedinačna povezanost s klasom je slaba.

Iz četiri koordinate Haversineovom formulom izvedena je udaljenost zračnom linijom: sredina 76,38 km, standardna devijacija 28,85 km, medijan 78,39 km i raspon 0,74–144,52 km. Sredine klasa su gotovo iste (76,49 i 76,27 km), pa sama udaljenost ne razdvaja klase jasno. Ni mala linearna korelacija sata ne isključuje prethodno uočeni noćni obrazac, jer su 23 i 0 susjedni sati.

Tabela 18: Povezanost veličina s klasom `is_fraud`, zaokružena na dvije decimale

Veličina	Pearson r	Spearman ρ
`amt`	0,62	0,58
`lat`	0,01	0,00
`long`	0,03	0,04
`city_pop`	0,02	0,01
`unix_time`	-0,03	-0,03
`merch_lat`	0,01	0,00
`merch_long`	0,03	0,04
Starost	0,07	0,06
Sat transakcije	0,09	0,16
Dan u sedmici	0,01	0,01
Udaljenost	-0,00	-0,01



Slika 9: Pearsonova matrica korelacija originalnih numeričkih veličina, izvedene starosti, vremena, udaljenosti i ciljne klase. Polje na presjeku reda i kolone daje koeficijent tog para. Identifikatori i kategorički kodovi nisu tretirani kao kontinuirane mjere.

Zaključci analize i posljedice za nastavak rada

Najizraženije razlike između klasa vezane su za iznos, kategoriju kupovine i vrijeme tokom dana. Za pripremu podataka važni su asimetrija iznosa i populacije, sličnost koordinata, razlika dva zapisa vremena te razlikovanje identifikatora od mjerenih veličina. Kartice, imena i adrese ponavljaju se kroz transakcije; pri pripremi treba spriječiti da model pamti identitet korisnika umjesto obrazaca ponašanja. Nema praznih vrijednosti za popunjavanje. IQR izdvajanje ne opravdava automatsko brisanje redova. Priprema slijedi u odjeljku 1.4.

Tabela 19: Broj zajedničkih oznaka transakcija između CSV datoteka

Prvi skup	Drugi skup	Zajedničkih transakcija
`fraud_balanced.csv`	`fraud_15k.csv`	7 593
`fraud_balanced.csv`	`fraud_50k.csv`	7 795
`fraud_15k.csv`	`fraud_50k.csv`	15 000

Tri datoteke **nisu nezavisni skupovi**: balansirani skup dijeli 7 593 transakcije sa skupom 15k i 7 795 sa skupom 50k, dok se svih 15 000 transakcija iz 15k nalazi u 50k. Zato druga dva CSV-a nisu nezavisni testovi modela treniranog na cijelom balansiranom skupu. Zato su u odjeljku 1.4 trening, validacijski i testni skup izdvojeni iz `fraud_50k.csv`, a balansiranje i transformacije koje uče parametre provode se samo unutar trening dijela. Rezultati prikazani u ovom odjeljku pripadaju istraživačkoj analizi, a ne evaluaciji modela.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.3 Istraživačka analiza podataka“*.

1.4. Priprema i transformacija podataka

Polazni podaci i podjela. U odjeljku 1.3 skup `fraud_balanced.csv` korišten je za istraživačku analizu, jer omogućava pregled obrazaca obje klase. Za pripremu modeliranja odabran je `fraud_50k.csv`, koji zadržava izvorni, izrazito nebalansirani odnos klasa. Time se izbjegava da se konačna procjena zasniva na vještačkom odnosu od 50% prevara.

Podaci su stratifikovanom podjelom razdvojeni na trening (70%), validacijski (15%) i testni skup (15%), uz `random_state=42`. Dobijene veličine i raspodjela ciljne klase prikazane su u tabeli 20.

Tabela 20: Podjela podataka i sastav trening skupa nakon balansiranja

Skup	Redovi	Legitimne	Prevare	Udio prevara
Trening	34 999	34 796	203	0,580%
Trening nakon SMOTE 1:20 (samo pri treniranju)	36 535	34 796	1 739	4,760%
Validacija	7 501	7 458	43	0,573%
Test	7 500	7 457	43	0,573%

Nakon podjele provjereno je da između skupova nema zajedničkih vrijednosti `trans_num`, kao ni dupliranih redova ili dupliranih identifikatora unutar pojedinačnog skupa. Na taj način se ista transakcija ne može pojaviti u treningu i testu, čime se smanjuje rizik od curenja podataka.

Izbor i izvođenje atributa. Odluke o atributima slijede zaključke istraživačke analize (odjeljak 1.3):

- Uklonjeni su identifikatori i lični podaci `trans_num`, `cc_num`, `first`, `last` i `street`, kako model ne bi zapamtio konkretnog korisnika, karticu ili transakciju umjesto da nauči opšte obrasce prevare.
- Samo uklanjanje `cc_num` nije dovoljno: u `fraud_50k.csv` kombinacija `zip` i `job` jednoznačno određuje svaku od 929 kartica. Zato su uklonjeni i `zip`, `city` i `job`.
- Koordinate korisnika i trgovca gotovo su linearno povezane ($r \approx 0{,}99$) i pojedinačno slabo povezane s klasom. Zamijenjene su udaljenošću `distance_km`, izvedenom Haversine formulom.
- Sat transakcije je cikličan, pa je kodiran sinusom i kosinusom (`hour_sin`, `hour_cos`). Tako su 23 h i 0 h susjedne vrijednosti, što je važno zbog noćnog obrasca prevara.
- Iznos i populacija grada izrazito su asimetrični udesno, pa se koriste u obliku $\log(1+x)$. Ova transformacija nema parametara koji se uče, pa ne uzrokuje curenje informacija između skupova.

- Sirovi vremenski zapisi `trans_date_trans_time`, `dob` i `unix_time` zamijenjeni su starošću, satom i danom u sedmici.

Provjera izbora atributa. O preostalim atributima `merchant` (693 vrijednosti), `city_pop` i `state` odlučeno je unakrsnom validacijom. Sama populacija grada jednoznačno određuje 754 od 929 kartica, pa i ona može poslužiti za prepoznavanje korisnika. Upoređena su četiri skupa atributa: polazni izbor korišten prije dorade (17 atributa, uključujući `zip`, `city`, `job`, koordinate i `merchant`), skup usklađen s analizom, isti skup bez `merchant` te skup bez `merchant` i bez lokacije korisnika (`city_pop`, `state`). Poređenje je urađeno stratifikovanom unakrsnom validacijom s 5 foldova, isključivo na trening skupu. Kao referentni modeli korišteni su logistička regresija i Random Forest, a nebalansiranost je u ovom koraku tretirana samo težinama klasa. Kodiranje i skaliranje učeni su unutar svakog folda.

Tabela 21: Izbor atributa: prosjek 5-struke unakrsne validacije na trening skupu

Skup atributa	Atributa	AUC-PR (LR)	AUC-PR (RF)	F1 (RF)
Polazni izbor	17	0,099	0,542	0,377
Usklađen s analizom	11	0,055	0,618	0,596
Usklađen s analizom, bez `merchant`	10	0,118	0,712	0,634
Bez `merchant` i lokacije korisnika	**8**	**0,193**	**0,764**	**0,700**

Posljednji skup daje najveći AUC-PR za oba modela. Atribut `merchant` ima 693 vrijednosti, a trening skup samo 203 prevare, pa većina trgovaca nema dovoljno prevara da bi model iz njih naučio pouzdan obrazac. Slično važi za `state` (51 vrijednost). Kod Random Foresta razlika između posljednja dva skupa (0,052) manja je od standardne devijacije između foldova, pa je manji skup odabran i zato što je dosljedan principu da model ne treba prepoznavati korisnika. F1-mjera logističke regresije pri pragu 0,5 niska je u svim varijantama (0,044–0,167), jer uz težine klasa model mnogo legitimnih transakcija označava kao prevare. Zato je izbor zasnovan na AUC-PR, koji ne zavisi od praga.

Konačni skup ima **8 ulaznih atributa**, prikazanih u tabeli 22, i ciljnu varijablu `is_fraud`. Podjela je urađena po transakcijama, pa se isti korisnici pojavljuju i u treningu i u testu; procjena zato odgovara otkrivanju prevara kod postojećih korisnika. U pripremljenim skupovima nije bilo nedostajućih vrijednosti, ali je imputacija ipak uključena u pipeline kako bi obrada bila robusna i za buduće podatke.

Tabela 22: Izvedeni, zadržani i uklonjeni atributi

Atribut(i)	Postupak	Razlog / posljedica
`trans_num`, `cc_num`, `first`, `last`, `street`	Uklanjanje identifikatora i ličnih podataka	Smanjuje rizik od memorisanja korisnika i prevelikog prilagođavanja.
`zip`, `city`, `job`, `city_pop`, `state`	Uklanjanje atributa koji određuju ili lociraju korisnika	`zip` i `job` zajedno jednoznačno određuju svaku karticu; uklanjanje poboljšava AUC-PR u unakrsnoj validaciji.
`merchant`	Uklanjanje (693 vrijednosti)	Premalo prevara po trgovcu; uklanjanje poboljšava AUC-PR oba modela.
`trans_date_trans_time`, `dob`, `unix_time`	Uklanjanje sirovih vremenskih zapisa nakon izvođenja atributa	Model dobija interpretabilne vremenske karakteristike umjesto sirovih zapisa.
`age_years`	Starost korisnika u trenutku transakcije	Opisuje demografski kontekst transakcije; vrijednosti u pripremljenim skupovima su približno od 14 do 96 godina.
`hour_sin`, `hour_cos`, `day_of_week`	Ciklično kodiran sat i dan u sedmici iz datuma transakcije	Omogućava modelu da koristi noćni obrazac uočen u analizi.
`amt_log`	$\log(1+x)$ transformacija iznosa	Smanjuje asimetriju udesno; najvažniji pojedinačni atribut iz analize.
`lat`, `long`, `merch_lat`, `merch_long`	Izvođenje atributa `distance_km` Haversine formulom	Uklanja redundantne koordinate i sažima udaljenost korisnika od trgovca; raspon je približno 0,07–146,13 km.
`category`, `gender`	Zadržani kategorički atributi	Kategorija kupovine pokazuje izražene razlike između klasa.

Kodiranje i skaliranje. Numerički atributi obrađeni su imputacijom medijanom i standardizacijom, a kategorički atributi imputacijom najčešće vrijednosti. Kategorije `category` i `gender` pretvorene su u numerički oblik one-hot kodiranjem. Korišten je `handle_unknown=ignore`, pa kategorija koja se pojavi u validaciji ili testu, a nije bila prisutna u treningu, ne prekida obradu. Od 8 ulaznih atributa dobivena su 22 numerička atributa nakon kodiranja.

Koristi se jedna, skalirana varijanta transformacije za sve modele. Skaliranje ne mijenja podjele u stablima odlučivanja, ali je potrebno modelima osjetljivim na skalu (npr. logistička regresija) i metodama balansiranja koje traže najbliže susjede (SMOTE i njegove varijante). Parametri imputacije, kodiranja i skaliranja uče se samo na trening

skupu, a u unakrsnoj validaciji samo na trening dijelu svakog folda.

Izbor metode balansiranja klasa. U trening skupu prevare čine samo 0,58 % transakcija. Prva verzija pripreme koristila je samo random undersampling do odnosa 1:1, čime je trening skup sveden na 406 transakcija. Umjesto da se metoda odabere unaprijed, upoređeno je deset pristupa iz tri grupe: učenje s težinama klasa, undersampling i oversampling, uključujući metode koje dodaju sintetičke primjere (tabela 23).

Tabela 23: Upoređene metode balansiranja klasa

Metoda	Vrsta	Kako radi
Bez balansiranja	–	Polazna tačka za poređenje.
Težine klasa	učenje s težinama	Greška na prevari se jače kažnjava; podaci se ne mijenjaju.
RUS	undersampling	Nasumično uklanja legitimne transakcije.
ROS	oversampling	Nasumično ponavlja postojeće prevare.
SMOTE	sintetički oversampling	Pravi nove prevare interpolacijom između susjednih prevara.
SMOTENC	sintetički oversampling	Varijanta SMOTE-a za mješovite podatke; kategoriju novog primjera uzima od susjeda.
Borderline-SMOTE	sintetički oversampling	Generiše primjere samo uz granicu između klasa.
ADASYN	sintetički oversampling	Više primjera generiše tamo gdje je prevare teže naučiti.
SMOTE + Tomek	hibridna metoda	Nakon SMOTE-a uklanja Tomek parove na granici klasa.
SMOTE + ENN	hibridna metoda	Nakon SMOTE-a uklanja primjere koje susjedi pogrešno klasifikuju.

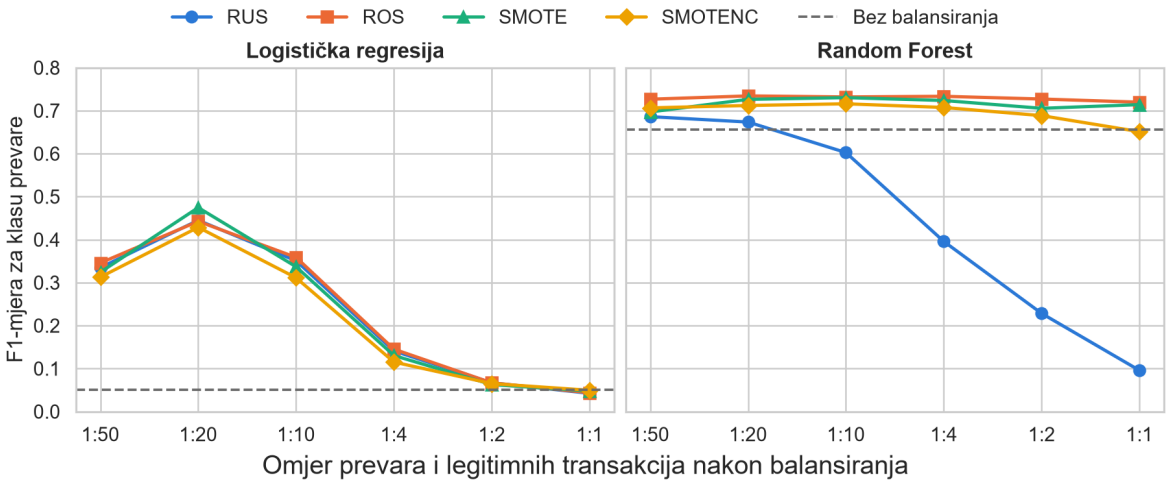
Balansiranje je ugrađeno kao korak `imblearn` pipelinea, pa se primjenjuje samo na trening dio svakog folda, dok fold za procjenu zadržava izvorni odnos klasa. Korištena je ponovljena stratifikovana unakrsna validacija na trening skupu (5 foldova × 2 ponavljanja), s istim foldovima za sve metode. Validacijski i testni skup nisu korišteni za izbor. Referentni modeli su logistička regresija i Random Forest. Prije pokretanja određen je kriterij izbora: najveća F1-mjera za klasu prevare, uprosječena kroz oba modela. F1 pri pragu 0,5 direktno pokazuje kako balansiranje mijenja odluke modela, a AUC-PR i MCC služe kao provjera. Prvo su sve metode upoređene uz potpuno balansiranje 1:1 (tabela 24).

Tabela 24: Poređenje metoda balansiranja uz omjer 1:1: prosjek unakrsne validacije za klasu prevare

	Logistička regresija			Random Forest		
Metoda	F1	Prec.	Recall	F1	Prec.	Recall
Bez balansiranja	0,050	0,480	0,027	0,656	0,968	0,500
Težine klasa	0,044	0,023	0,766	0,692	0,946	0,550
RUS (polazno rješenje)	0,042	0,022	0,795	0,096	0,051	0,901
ROS	0,044	0,023	0,763	**0,720**	0,902	0,604
SMOTE	0,048	0,025	0,775	0,714	0,860	0,614
SMOTENC	0,049	0,026	0,724	0,651	0,682	0,631
Borderline-SMOTE	**0,057**	0,030	0,670	0,682	0,883	0,559
ADASYN	0,044	0,023	0,800	0,704	0,845	0,609
SMOTE + Tomek	0,048	0,025	0,775	0,714	0,860	0,614
SMOTE + ENN	0,047	0,024	0,778	0,677	0,751	0,623

Polazno rješenje, RUS 1:1, najlošije je za oba modela. Kod Random Foresta F1 pada s 0,656 (bez balansiranja) na 0,096: recall raste na 0,901, ali preciznost pada na 0,051, jer model treniran na odnosu 50/50 na realističnom odnosu klasa mnogo legitimnih transakcija označava kao prevare. Isti obrazac opisuju Afriyie i saradnici [2]. Oversampling metode i težine klasa poboljšavaju Random Forest (ROS 0,720, SMOTE 0,714, ADASYN 0,704). Hibridne metode ne donose poboljšanje: SMOTE + Tomek daje iste rezultate kao SMOTE, jer Tomek parova gotovo nema, a SMOTE + ENN je slabiji. SMOTENC nije bolji od običnog SMOTE-a, jer postoje samo dva kategorička atributa. Kod logističke regresije sve metode uz omjer 1:1 daju F1 ispod 0,06, uz preciznost od samo 2–3 %, dok bez balansiranja model gotovo ne prepoznaje prevare (recall 0,027).

Uticaj omjera klasa. Zato je za RUS, ROS, SMOTE i SMOTENC ispitan i omjer prevara i legitimnih transakcija nakon balansiranja, od 1:50 do 1:1 (parametar `sampling_strategy`). Rezultati su na slici 10 i u tabeli 25.



Slika 10: F1-mjera za klasu prevare u zavisnosti od omjera klasa nakon balansiranja (prosjek ponovljene 5-struke unakrsne validacije). Isprekidana linija označava model bez balansiranja.

Tabela 25: F1-mjera za klasu prevare po metodi i omjeru klasa nakon balansiranja

Model	Metoda	1:50	1:20	1:10	1:4	1:2	1:1
Log. regresija	RUS	0,335	0,445	0,351	0,141	0,067	0,042
	ROS	0,346	0,442	0,359	0,145	0,067	0,044
	SMOTE	0,324	**0,474**	0,337	0,130	0,063	0,048
	SMOTENC	0,313	0,429	0,311	0,115	0,065	0,049
Random Forest	RUS	0,686	0,673	0,602	0,396	0,228	0,096
	ROS	0,727	**0,734**	0,732	0,733	0,727	0,720
	SMOTE	0,697	0,726	0,730	0,724	0,705	0,714
	SMOTENC	0,706	0,712	0,716	0,707	0,688	0,651

Kod logističke regresije omjer je presudan: F1 raste od 0,04–0,05 (1:1) do 0,43–0,47 (1:20). Potpuno balansiranje pomjera procijenjene vjerovatnoće toliko da pri pragu 0,5 previše legitimnih transakcija postaje prevara. Kod Random Foresta oversampling metode daju stabilne rezultate za sve omjere, dok RUS slabi s porastom omjera, jer odbacuje sve više legitimnih transakcija. Prema unaprijed određenom kriteriju najbolja je konfiguracija **SMOTE 1:20**, s prosječnom F1-mjerom 0,600 (logistička regresija 0,474, Random Forest 0,726). Slijede ROS 1:20 (0,588), SMOTENC 1:20 (0,570) i RUS 1:20 (0,559). Razlika između SMOTE 1:20 i ROS 1:20 manja je od standardne devijacije između foldova, pa su te dvije metode praktično ravnopravne. SMOTE ima prednost jer pravi nove primjere umjesto da ponavlja iste prevare, čime se smanjuje rizik da model zapamti pojedinačne transakcije. Uz omjer 1:20 broj prevara u treningu raste s 203 na 1 739, a sve legitimne transakcije ostaju sačuvane (tabela 20).

Provjera na validacijskom skupu. Modeli bez balansiranja, s polaznim RUS 1:1

i s odabranim SMOTE 1:20 trenirani su na cijelom trening skupu i provjereni na validacijskom skupu (tabela 26).

Tabela 26: Provjera metoda balansiranja na validacijskom skupu (43 prevare, 7 458 legitimnih transakcija)

Model	Balansiranje	TP	FN	FP	Prec.	Recall	F1
Log. regresija	Bez balansiranja	1	42	2	0,333	0,023	0,043
	RUS 1:1	42	1	1 584	0,026	0,977	0,050
	SMOTE 1:20	32	11	26	0,552	0,744	**0,634**
Random Forest	Bez balansiranja	30	13	1	0,968	0,698	**0,811**
	RUS 1:1	42	1	652	0,061	0,977	0,114
	SMOTE 1:20	31	12	3	0,912	0,721	0,805

RUS 1:1 i na validaciji daje velik broj lažnih uzbuna (1 584 i 652). Kod logističke regresije SMOTE 1:20 podiže F1 s 0,043 na 0,634. Kod Random Foresta SMOTE 1:20 i rad bez balansiranja daju praktično isti rezultat: razlika je jedna prepoznata prevara i dvije lažne uzbune. Random Forest je, dakle, manje osjetljiv na nebalansiranost od logističke regresije, a odabrana metoda mu ne šteti. Zbog samo 43 prevare u validaciji jedna transakcija mijenja recall za oko 2,3 procentna poena, pa je glavni oslonac izbora unakrsna validacija. Rezultati djelimično potvrđuju polaznu hipotezu (odjeljak 1.2): balansiranje povećava osjetljivost, a pad preciznosti je izražen samo kod potpunog balansiranja, dok umjereni oversampling zadržava visoku preciznost.

SMOTE do omjera 1:20 je zadana metoda balansiranja tima. U notebooku je dostupna kao funkcija `make_model_pipeline`, koja vraća pipeline sa skaliranjem, kodiranjem i balansiranjem. Balansiranje se izvršava samo pri treniranju, a validacijski i testni skup se ne mijenjaju. Zato se sprema nebalansirani trening skup, a ne unaprijed balansiran. Pošto efekat balansiranja zavisi od modela, u zadatku 2.2 svaki član za svoj algoritam ponovo provjerava uticaj nebalansiranosti istim postupkom. Alternativa promjeni omjera je pomjeranje praga odluke na validacijskom skupu, što se može razmotriti uz podešavanje hiperparametara.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„Izbor metode balansiranja klasa“*.

Posljedice pripreme. Pripremom je formiran reproduktivan postupak koji istovremeno čuva realističan odnos klasa za evaluaciju, sprečava preklapanje transakcija između skupova i omogućava primjenu algoritama na mješovitim numeričkim i kategoričkim podacima. Balansiranje je dio pipelinea i primjenjuje se samo na trening podatke, a validacija i test zadržavaju izvorni odnos klasa. Pripremljeni skupovi i pipeline koriste se u zadacima izgradnje i poređenja klasifikacijskih modela.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.4 Priprema*

Tabela 27: Primijenjeni postupci pripreme podataka

Atribut(i)	Postupak	Razlog / posljedica
`is_fraud`	Izdvajanje ciljne varijable prije transformacije ulaza	Sprječava da ciljna informacija bude korištena kao ulazni atribut.
Identifikujući i redundantni atributi	Uklanjanje uz provjeru unakrsnom validacijom	Otežava prepoznavanje korisnika; AUC-PR raste kod oba referentna modela.
Numerički atributi	$\log(1+x)$ za iznos, ciklično kodiran sat, medijalna imputacija i standardizacija	Pipeline je robustan na nedostajuće vrijednosti; skala odgovara i modelima i SMOTE-u.
Kategorički atributi	Imputacija najčešćom vrijednošću i one-hot kodiranje	Omogućava rad modela sa tekstualnim kategorijama i nepoznatim vrijednostima.
Trening skup	SMOTE do omjera 1:20 kao korak pipelinea, odabran poređenjem deset pristupa	Najveća prosječna F1-mjera u unakrsnoj validaciji; balansira se samo trening dio svakog folda.
Validacija i test	Bez balansiranja i bez ponovnog učenja transformacija	Metrike ostaju reprezentativne za izvorni odnos klasa.

podataka: podjela skupa“.

2. Izgradnja klasifikacijskih modela

2.1. Odabir algoritama i raspodjela rada

Tim bira pet klasifikacijskih algoritama, po jedan za svakog člana. Konačni odabir i raspodjelu unijeti nakon zajedničkog dogovora.

Tabela 28: Raspodjela algoritama među članovima tima

Član tima	Algoritam	Zašto je odabran
Aldin Velić	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Bakir Činjarević	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Danijal Alibegović	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Haris Macić	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Kerim Hajdar	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*

Pri izboru se mogu razmotriti, naprimjer, stablo odlučivanja, Naivni Bayes, logistička regresija, SVM, k-NN ili neuronska mreža. To su samo primjeri; **u tabeli navedite algoritme koje zaista budete izabrali**.

2.2. Izgradnja i evaluacija pojedinačnih modela

Status: izgradnja i evaluacija modela još nisu implementirane. Sljedeći dijelovi predstavljaju predloške koji će se popuniti stvarnim rezultatima.

Svaki član u svom dijelu dokumentuje dodatnu pripremu podataka, podjelu na trening, validacijski i testni skup, izgradnju *pipelinea*, evaluaciju (confusion matrix, tačnost, osjetljivost, specifičnost, kappa i druge opravdane metrike), unakrsnu validaciju, uticaj nebalansiranosti klasa, oversampling/undersampling i podešavanje hiperparametara.

2.2.1. Model 1: *[odabrati algoritam]*– Aldin Velić

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 29: Rezultati modela 1 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]* **Planirani odjeljak notebooka:** *2.2.1 Model 1: [odabrati algoritam].* Implementacija još slijedi.

2.2.2. Model 2: *[odabrati algoritam]*– Bakir Činjarević

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 30: Rezultati modela 2 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]* **Planirani odjeljak notebooka:** *2.2.2 Model 2: [odabrati algoritam].* Implementacija još slijedi.

2.2.3. Model 3: *[odabrati algoritam]*– Danijal Alibegović

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 31: Rezultati modela 3 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]* **Planirani odjeljak notebooka:** *2.2.3 Model 3: [odabrati algoritam].* Implementacija još slijedi.

2.2.4. Model 4: *[odabrati algoritam]*– Haris Macić

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 32: Rezultati modela 4 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]* **Planirani odjeljak notebooka:** *2.2.4 Model 4: [odabrati algoritam].* Implementacija još slijedi.

2.2.5. Model 5: *[odabrati algoritam]*– Kerim Hajdar

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 33: Rezultati modela 5 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]* **Planirani odjeljak notebooka:** *2.2.5 Model 5: [odabrati algoritam].* Implementacija još slijedi.

2.3. Poređenje i ansambl-model

Poređenje pojedinačnih modela

Uporediti svih pet modela na **istom testnom skupu i po istim metrikama**. Obrazložiti razlike u performansama; naročito komentarisati koliko koji model prepoznaje prevarne transakcije i koliko često pogrešno obilježava legitimne transakcije kao prevarne.

Tabela 34: Zajedničko poređenje pet klasifikacijskih modela

Model	Tačnost	Precision_1	Recall_1	F1_1	Kappa
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–

[Dopuniti: Navesti konkretne rezultate i objasniti razloge različitih performansi, uzimajući u obzir pripremu, balansiranje i podešavanje modela.]

Izbor i izgradnja ansambl-modela

[Dopuniti: Navesti odabranu metodu kombinovanja modela (npr. glasanje ili stacking), njeno obrazloženje, koje modele uključuje, način treniranja, validaciju i odgovarajući pipeline.]

Tabela 35: Poređenje ansambl-modela i najboljeg pojedinačnog modela

Model	Precision_1	Recall_1	F1_1
Najbolji pojedinačni model	–	–	–
Ansambl-model	–	–	–

Diskusija rezultata i zaključak

[Dopuniti: Objasniti je li ansambl postigao poboljšanje, prema kojoj metrici, koliko je pouzdan rezultat te da li je polazna hipoteza potvrđena. Navesti ograničenja rada i glavne zaključke bez dodavanja novog koda.] **Planirani odjeljak notebooka:** *2.3 Poređenje modela i ansambl.* Implementacija još slijedi.

Literatura

[1] kartik2112, "Credit card transactions fraud detection dataset." Kaggle, https://www.kaggle.com/datasets/kartik2112/fraud-detection. Pristupljeno: 29.10.2026.

[2] J. K. Afriyie, K. Tawiah, W. A. Pels, S. Addai-Henne, H. A. Dwamena, E. O. Owiredu, S. A. Ayeh, and J. Eshun, "A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions," *Decision Analytics Journal*, vol. 6, p. 100163, 2023. https://doi.org/10.1016/j.dajour.2023.100163.

[3] A. Al-Bulushi, A. K. Shaikh, and N. Adhikari, "Applying supervised machine learning algorithms and ensemble models to enhance credit card fraud detection," *Frontiers in Artificial Intelligence*, vol. 9, p. 1813728, 2026. https://doi.org/10.3389/frai.2026.1813728.

[4] D. Breskuvienė and G. Dzemyda, "Enhancing credit card fraud detection: highly imbalanced data case," *Journal of Big Data*, vol. 11, p. 182, 2024. https://doi.org/10.1186/s40537-024-01059-5.

[5] E. Ileberi, Y. Sun, and Z. Wang, "A machine learning based credit card fraud detection using the GA algorithm for feature selection," *Journal of Big Data*, vol. 9, p. 24, 2022. https://doi.org/10.1186/s40537-022-00573-8.

[6] S. S. Sulaiman, I. Nadher, and S. M. Hameed, "Credit card fraud detection using improved deep learning models," *Computers, Materials & Continua*, vol. 78, no. 1, pp. 1049–1069, 2024. https://doi.org/10.32604/cmc.2023.046051.