Univerzitet u Sarajevu
Elektrotehnički fakultet

Mašinsko učenje

Akademska godina 2026/2027.

Detekcija prevarnih finansijskih transakcija

Projektni zadatak – zadaci 1.1–1.4 i 2.1

Članovi tima:

1. Aldin Velić
2. Bakir Činjarević
3. Danijal Alibegović
4. Haris Macić
5. Kerim Hajdar

Kod i podaci:

https://github.com/bakir004/mu

Sarajevo, 12. novembar 2026.

Sadržaj

1 Odabir, analiza i priprema podataka **1**

1.1 Odabir teme i skupa podataka 1

1.2 Pregled naučnoistraživačkih radova 2

1.3 Istraživačka analiza podataka 7

1.4 Priprema i transformacija podataka 25

2 Odabir klasifikacijskih algoritama **30**

2.1 Odabir algoritama i raspodjela rada 30

Literatura **31**

1. Odabir, analiza i priprema podataka

1.1. Odabir teme i skupa podataka

Tema je prepoznavanje prevarnih finansijskih transakcija kao zadatak nadzirane binarne klasifikacije. Jedan red predstavlja jednu transakciju, a cilj `is_fraud` označava legitimnu (0) ili prevarnu (1) transakciju. Izvor je *Credit Card Transactions Fraud Detection Dataset* sa Kaggle platforme [1], sa simuliranim Sparkov transakcijama.

Formiranje i namjena dva skupa

Iz polazne datoteke `fraudTrain.csv` formiramo dvije verzije. Balansirani skup nastaje nasumičnim smanjivanjem većinske klase (*random undersampling*): zadržavamo svih 7 506 prevarnih transakcija i nasumično odabiremo isto toliko legitimnih, uz `random_state=42`. Dobijamo 15 012 redova sa odnosom klasa 50:50. Nebalansirani skup formiramo stratifikovanim uzorkovanjem 15 000 transakcija. Sadrži 87 prevara i zadržava približan izvorni odnos klasa.

Tabela 1: Struktura i namjena dva ulazna skupa

Datoteka	Redovi	Prevare	Namjena
`fraud_balanced.csv`	15 012	7 506	Pregled obrazaca podjednako zastupljenih klasa.
`fraud_15k.csv`	15 000	87	Očuvanje približnog izvornog udjela prevara, oko 0,58 %.

Obje verzije su potrebne: balansirani skup olakšava pregled obje klase, a nebalansirani čuva rijetkost prevare. Ista pravila pripreme primjenjujemo na oba cijela skupa, uz očuvanje broja redova i odnosa klasa. Balansirana verzija obuhvata više različitih prevara, pa razlika nije samo u procentu klase.

Datoteke dijele 7 593 transakcije, koje pratimo pomoću `trans_num`. Ne predstavljaju međusobno nezavisne skupove za provjeru. Simulirani karakter podataka i odnos klasa ograničavaju prenošenje uočenih učestalosti na stvarno poslovanje.

Struktura atributa i uslovi specifikacije

Obje verzije imaju 22 kolone: 21 ulaz i cilj. Sadrže sedam numeričkih, 12 kategoričkih, tekstualnih i identifikatorskih kolona te dva datumska zapisa. Ispunjeni su uslovi najmanje 1 000 instanci, 15 ulaznih atributa i mješovitih tipova. Sve varijable analiziramo u 1.3, a postupke pripreme sažimamo u tabeli u 1.4.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.1 Odabir i učitavanje skupa podataka“*.

1.2. Pregled naučnoistraživačkih radova

Svaki član tima obrađuje jedan rad. Tabele za svaki rad navode problem, podatke, metode, metrike i najbolji prijavljeni rezultat. Prva tri rada koriste Sparkov podatke, a preostala dva evropski skup transakcija. Rezultati potiču iz različitih eksperimentalnih uslova i nisu direktna rang-lista za naš skup.

Naučnoistraživački rad – Aldin Velić

Naslov rada: *A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions.*

Autori: Jonathan Kwaku Afriyie, Kassim Tawiah, Wilhemina Adoma Pels, Sandra Addai-Henne, Harriet Achiaa Dwamena, Emmanuel Odame Owiredu, Samuel Amening Ayeh i John Eshun.

Izvor: *Decision Analytics Journal*, vol. 6, članak 100163, 2023. [2]

Tabela 2: Sažeti pregled naučnoistraživačkog rada Afriyie i saradnika (2023)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama kao problem binarne klasifikacije, pri čemu se razlikuju legitimne i prevarne transakcije.
Skup podataka	*Credit Card Transactions Fraud Detection Dataset* (Kaggle), simuliran pomoću alata Sparkov. U radu se navodi 555 719 transakcija i 23 kolone u početnom skupu podataka.
Korištene metode	Logistička regresija (Logistic Regression), stablo odlučivanja (Decision Tree) i slučajna šuma (Random Forest). Priprema podataka uključuje skaliranje i nasumično smanjivanje većinske klase (undersampling).
Metrike	Tačnost (accuracy), preciznost (precision), osjetljivost (recall/sensitivity), specifičnost, F1-mjera i ROC-AUC.
Najbolji rezultat	**Random Forest**: tačnost **96%**, ROC-AUC **98,9%**. Prijavljene vrijednosti: recall 0,97, precision 0,09 i F1-mjera 0,17.

Naučnoistraživački rad – Bakir Činjarević

Naslov rada: *Applying supervised machine learning algorithms and ensemble models to enhance credit card fraud detection.*

Autori: Abrar Al-Bulushi, Abdul K. Shaikh i Naresh Adhikari.

Izvor: *Frontiers in Artificial Intelligence*, vol. 9, članak 1813728, 2026. [3]

Tabela 3: Sažeti pregled naučnoistraživačkog rada Al-Bulushi i saradnika (2026)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama kao binarna klasifikacija na izrazito nebalansiranim podacima, uz provjeru generalizacije modela na neviđenim skupovima podataka.
Skup podataka	Glavni skup za treniranje i testiranje je *isti Sparkov skup* koji koristi naš tim (približno 1,3 miliona transakcija, 0,5 % prevara, 22 atributa). Skup od 555 719 transakcija iz iste kolekcije i još četiri javna skupa (među njima evropski skup od 284 807 transakcija i PaySim) služe kao neviđeni skupovi.
Korištene metode	Logistička regresija, Naive Bayes, stablo odlučivanja, Random Forest, neuronska mreža (ANN) i XGBoost; uravnotežavanje metodama RUS, ROS i SMOTE; selekcija atributa (korelacija, ANOVA, RFE, unaprijedna selekcija); novi atributi ponašanja korisnika; pomjeranje praga odlučivanja; ansambli *bagging*, *boosting* i *stacking*.
Metrike	Tačnost, preciznost, osjetljivost (recall), F1-mjera i AUC, uz konfuzijsku matricu; 4-struka unakrsna validacija.
Najbolji rezultat	Pojedinačno: **XGBoost** bez uravnotežavanja, F1 **0,84** (AUC 0,99). Konačni model **Bagging 1** (10 modela): F1 **0,795**, recall 0,864, AUC 0,99; uz nove atribute ponašanja F1 raste na **0,83** (recall 0,89).

Naučnoistraživački rad – Danijal Alibegović

Naslov rada: *Enhancing credit card fraud detection: highly imbalanced data case.*

Autori: Dalia Breskuvienė i Gintautas Dzemyda.

Izvor: *Journal of Big Data*, vol. 11, članak 182, 2024. [4]

Tabela 4: Sažeti pregled naučnoistraživačkog rada Breskuvienė i Dzemyde (2024)

Stavka	**Opis**
Problem	Selekcija atributa za detekciju prevara kreditnim karticama kada su podaci izrazito nebalansirani; uobičajene metode selekcije atributa zanemaruju manjinsku klasu.
Skup podataka	Tri skupa: sintetički skup transakcija (3 445 553 instanci, 0,14 % prevara), *Sparkov* skup – spojene datoteke `fraudTrain` i `fraudTest` (1 852 394 instanci, 0,52 % prevara) i stvarni evropski skup (284 807 instanci, 0,17 % prevara).
Korištene metode	Nova metoda selekcije atributa FID-SOM zasnovana na samoorganizujućim mapama (SOM), upoređena s univarijatnom selekcijom (F-test, χ^2, uzajamna informacija), RFE i važnošću atributa iz XGBoosta. Klasifikatori: Random Forest, XGBoost i CatBoost.
Metrike	F1-mjera, MCC, G-Mean, AUC-PR i AUC-ROC; svaki rezultat je prosjek pet ponavljanja s različitim *random seed* vrijednostima.
Najbolji rezultat	Na Sparkov skupu (DataSet-B): **Random Forest + FID-SOM**, F1 **0,835**, u poređenju s 0,622 bez selekcije atributa. Rezultati su prosjeci pet izvođenja; rad prati F1, MCC, G-Mean, AUC-PR i AUC-ROC.

Naučnoistraživački rad – Haris Macić

Naslov rada: *A machine learning based credit card fraud detection using the GA algorithm for feature selection.*

Autori: Emmanuel Ileberi, Yanxia Sun i Zenghui Wang.

Izvor: *Journal of Big Data*, vol. 9, članak 24, 2022. [5]

Tabela 5: Sažeti pregled naučnoistraživačkog rada Ileberija i saradnika (2022)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama uz izbor optimalnog podskupa atributa pomoću genetskog algoritma (GA).
Skup podataka	Evropski skup transakcija kreditnim karticama (Kaggle, septembar 2013.): 284 807 transakcija, 0,172 % prevara, 30 numeričkih atributa (V1–V28 dobijeni PCA transformacijom, `Time`, `Amount`). Dodatna provjera na sintetičkom skupu s oko 24,4 miliona transakcija.
Korištene metode	Genetski algoritam za selekciju atributa (funkcija prilagođenosti je tačnost Random Foresta); klasifikatori: stablo odlučivanja, Random Forest, logistička regresija, ANN i Naive Bayes; SMOTE za uravnotežavanje i *min-max* normalizacija.
Metrike	Tačnost (glavna metrika), osjetljivost (recall), preciznost, F1-mjera i AUC.
Najbolji rezultat	**GA-RF** s vektorom atributa v5 (13 atributa): tačnost **99,98 %**, preciznost 95,34 %, recall 72,56 %, F1-mjera 82,41 %.

Naučnoistraživački rad – Kerim Hajdar

Naslov rada: *Credit Card Fraud Detection Using Improved Deep Learning Models.*

Autori: Sumaya S. Sulaiman, Ibraheem Nadher i Sarab M. Hameed.

Izvor: *Computers, Materials & Continua*, vol. 78, br. 1, str. 1049–1069, 2024. [6]

Tabela 6: Sažeti pregled naučnoistraživačkog rada Sulaiman i saradnika (2024)

Stavka	**Opis**
Problem	Detekcija prevara kreditnim karticama pomoću modela dubokog učenja i ispitivanje uticaja podešavanja hiperparametara i metoda uravnotežavanja na njihove performanse.
Skup podataka	Evropski skup transakcija kreditnim karticama (Kaggle, septembar 2013.): 284 807 transakcija, od kojih su 492 prevarne (0,172 %).
Korištene metode	Autoenkoder (AE), konvolucijska neuronska mreža (CNN) i LSTM mreža; podešavanje hiperparametara metodama *random search* i Bayesovom optimizacijom (cilj: F1-mjera); uravnotežavanje metodama RUS, SMOTE i ADASYN; stratifikovana unakrsna validacija.
Metrike	Tačnost, stopa detekcije (*detection rate*, tj. recall) i AUC; F1-mjera kao funkcija cilja pri podešavanju hiperparametara.
Najbolji rezultat	**LSTM + SMOTE** (*random search*): tačnost **99,2 %**, stopa detekcije **93,3 %**, AUC **96,3 %**.

Očekivanja i istraživačka hipoteza

Pregledani radovi upućuju na dobre rezultate Random Foresta i metoda boostinga, dok rezultati neuronskih mreža zavise od pripreme i podešavanja. Uobičajene metrike su preciznost, osjetljivost i F1-mjera za klasu prevare te AUC-ROC; AUC-PR i MCC dodatno opisuju uspješnost pri rijetkim prevarama. Sama tačnost ne daje potpunu sliku.

Uravnotežavanje u nekim eksperimentima povećava osjetljivost uz pad preciznosti. Zato unaprijed ne zaključujemo da je balansirana verzija bolja. **Hipoteza:** *Na pripremljenim karakteristikama nelinearni pristupi (stablo odlučivanja, SVM s radijalnom jezgrom i višeslojni perceptron) mogu postići veću F1-mjeru za klasu prevare od logističke regresije. Balansirani trening može povećati osjetljivost uz moguć pad preciznosti na nebalansiranim podacima.* Ovo su istraživačka očekivanja izvedena iz literature, a ne nalazi vlastitih eksperimenata.

1.3. Istraživačka analiza podataka

Obuhvat i način tumačenja analize

Detaljna analiza raspodjela provodi se na balansiranom skupu od 15 012 transakcija. Podjednaka zastupljenost klasa olakšava njihov opis, ali udio prevara od 50 % predstavlja posljedicu uzorkovanja. Sredine iznosa, udjeli kategorija i korelacije zato se odnose na balansirani uzorak. Za kvalitet zapisa i primjenu istih pravila pripreme provjeravaju se oba ulazna CSV-a.

Potpunost, duplikati i logička ispravnost

U oba skupa nema nedostajućih ćelija, praznih tekstova ni potpuno dupliranih redova. Oznaka `trans_num` jedinstvena je unutar pojedinačnog izvora. Ponavljanje kartice ili adrese ne znači dupliranu transakciju: jedna kartica prirodno može imati više različitih kupovina. Brisanje redova po ponavljanju kartice uklonilo bi ispravna posmatranja i promijenilo raspodjelu aktivnosti korisnika.

Provjereni su i pozitivnost iznosa, nenegativnost populacije, dozvoljeni rasponi geografskih koordinata te čitljivost datuma. Datumi rođenja ne dolaze nakon odgovarajuće transakcije. Odsustvo grešaka u ovim provjerama opisuje provjerene uslove; ono nije dokaz da je svaka poslovna činjenica u simuliranom zapisu realistična.

Tabela 7: Provjere kvaliteta oba ulazna CSV-a

Provjera	Balansirani	Nebalansirani
Nedostajuće ćelije	0	0
Prazni tekstovi	0	0
Duplirani redovi	0	0
Duplirani trans_num	0	0
Neispravna klasa	0	0
Nepozitivni iznosi	0	0
Negativna populacija	0	0
Neispravni datumi	0	0
Rođenje nakon transakcije	0	0
Neispravne koordinate	0	0

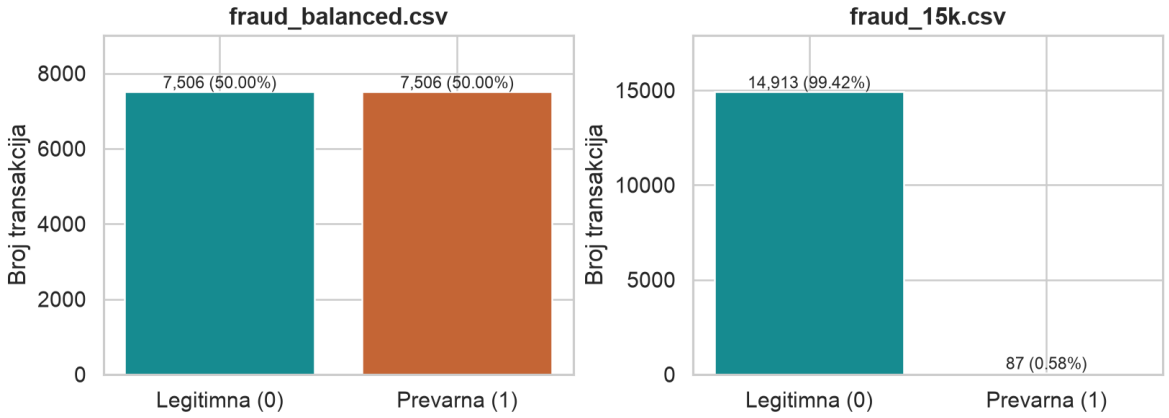
Poštanski broj se čuva kao tekst. U balansiranom uzorku 919 zapisa ima četiri cifre. Bez originalnog konteksta ne pretpostavljamo automatski da je svima potrebno dodati istu vodeću cifru. Ovaj atribut se u 1.4 izostavlja zbog detaljnosti geografskih oznaka i preklapanja s koordinatama; time se izbjegava i nametanje proizvoljne rekonstrukcije.

Raspodjela ciljne klase i značaj nazivnika

Balansirani izvor sadrži po 7 506 redova svake klase, dok uzorak 15k ima samo 87 prevara. Razlika u broju prevara utiče na ukupne raspodjele. Na primjer, veća ukupna

sredina iznosa u balansiranom skupu može nastati zato što su u njemu mnogo češće zastupljene transakcije s većim iznosima iz manjinske klase.

Kod grafikona po klasama koristimo normalizaciju unutar svake klase. Procenat svih prevara u nekom satu nije isto što i procenat prevara među svim transakcijama tog sata. Prvi opisuje raspodjelu vremena unutar prevara; drugi zavisi i od odnosa klasa u uzorku. To razlikovanje primjenjuje se i na kategorije kupovine i geografske grupe.



Slika 1: Broj i udio klasa u dva ulazna CSV-a. Balansirani odnos formira se nasumičnim smanjivanjem većinske klase.

Zbirni pregled svih izvornih atributa

Tabela sažima opis svih varijabli. U njoj su obuhvaćene i kolone koje će se kasnije izostaviti iz ulaza. Izostavljanje iz pripreme ne zamjenjuje analizu: odluka se zasniva na značenju, kvalitetu i zastupljenosti vrijednosti. Rasponi su prikazani u izvornim jedinicama, a potpune frekvencije ostaju dostupne u bilježnici.

Tabela 8: Pojedinačni pregled svih 22 atributa balansiranog skupa

Atribut	Tip	Raspon / sažetak	Zapažanje
`trans_date_ trans_time`	datum	01.01.2019.–21.06.2020.	Nepotpun posljednji mjesec; izražena koncentracija prevara u noćnim satima.
`cc_num`	oznaka	977 vrijednosti; najčešća 630451534402 (38)	Ista kartica se ponavlja kroz različite transakcije.
`merchant`	kategorički	693 vrijednosti; najčešća fraud_Kilback LLC (72)	Zajednički prefiks fraud_ ne razlikuje klase; mnogo rijetkih trgovaca.
`category`	kategorički	14 vrijednosti; najčešća grocery_pos (2494)	14 vrsta kupovine; različita zastupljenost po klasi.
`amt`	numerički	1,00 do 6 337,25	Desna asimetrija 1,48; najveći iznos pripada legitimnoj transakciji.

Atribut	Tip	Raspon / sažetak	Zapažanje
`first`	kategorički	352 vrijednosti; najčešća Christopher (330)	Ime se ponavlja i nije jedinstvena oznaka osobe.
`last`	kategorički	480 vrijednosti; najčešća Smith (301)	Prezime se ponavlja kroz transakcije i korisnike.
`gender`	kategorički	2 vrijednosti; najčešća F (7835)	Dvije nominalne kategorije; bez poretka.
`street`	kategorički	977 vrijednosti; najčešća 561 Little Plain Apt. 738 (38)	Adresa se ponavlja u kupovinama iste kartice.
`city`	kategorički	889 vrijednosti; najčešća Warren (57)	Mnogo različitih oznaka; naziv grada nije jednoznačan bez države.
`state`	kategorički	51 vrijednosti; najčešća TX (1024)	51 nominalna oznaka različite zastupljenosti.
`zip`	oznaka	964 vrijednosti; najčešća 82514 (45)	964 oznake; 919 četverocifrenih zapisa; broj nije udaljenost.
`lat`	numerički	20,03 do 66,69	Dopušten raspon; snažno prati širinu trgovca.
`long`	numerički	-165,67 do -67,95	Lijeva asimetrija odražava lokacije; vrijednosti su dopuštene.
`city_pop`	numerički	23,00 do 2 906 700,00	Izražen desni rep; veliki gradovi ostaju sačuvani.
`job`	kategorički	493 vrijednosti; najčešća Materials engineer (114)	Mnogo rijetkih zanimanja; broj transakcija nije broj osoba.
`dob`	datum	30.10.1924.–29.01.2005.	Sva rođenja prethode odgovarajućoj transakciji.
`trans_num`	oznaka	15 012 jedinstvenih oznaka	Sve oznake jedinstvene; provjera duplikata i podjele.
`unix_time`	numerički	1 325 401 915,00 do 1 371 813 091,00	Standardno tumačenje daje godine 2012–2013 umjesto 2019–2020.
`merch_lat`	numerički	19,04 do 67,51	Jaka povezanost sa geografskom širinom korisnika.
`merch_long`	numerički	-166,55 do -67,03	Jaka povezanost sa geografskom dužinom korisnika.
`is_fraud`	cilj	2 vrijednosti; najčešća 1 (7506)	Cilj 0/1; po 7.506 redova, odvojen od ulaza.

Kako čitamo numeričke raspodjele

Aritmetička sredina opisuje prosječnu vrijednost, ali je osjetljiva na velike vrijednosti u repu. Medijan dijeli posmatranja na dvije jednake polovine, a kvartili ograničavaju

središnjih 50 % podataka. Standardna devijacija opisuje rasipanje oko sredine. Zajedno daju više informacija nego pojedinačan pokazatelj, posebno za iznos i veličinu grada kod kojih se sredina i medijan znatno razlikuju.

Koeficijent asimetrije opisuje smjer i izraženost repa. Vrijednosti između $-0{,}5$ i $0{,}5$ ovdje označavaju približnu simetriju, apsolutne vrijednosti između 0,5 i 1 umjerenu asimetriju, a veće od 1 jaku asimetriju. Ova podjela služi opisu asimetrije, a ne kao test kojim se svaka raspodjela mora pretvoriti u normalnu. Približna simetrija također ne dokazuje normalnost raspodjele.

Box plot prikazuje medijan, kvartile i statistički izdvojene vrijednosti. Za $IQR = Q_3 - Q_1$ koristimo granice $Q_1 - 1{,}5IQR$ i $Q_3 + 1{,}5IQR$. Tačke izvan njih posmatraju se dodatno. Kod geografske širine ili populacije grada one mogu jednostavno predstavljati rjeđe lokacije. Zato IQR nije upotrijebljen kao automatsko pravilo za izbacivanje transakcija.

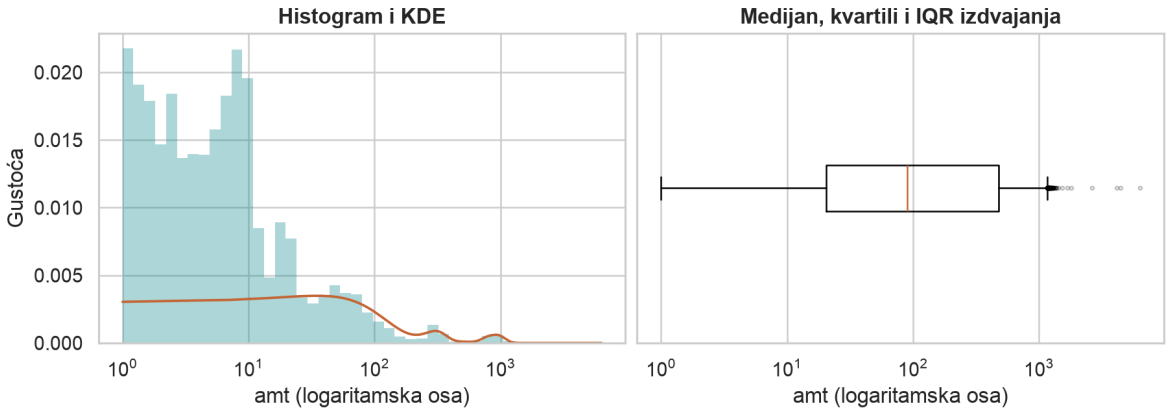
Histogram prikazuje koncentraciju vrijednosti po intervalima, dok KDE predstavlja izglađenu procjenu gustoće. Oblik KDE zavisi i od izglađivanja, pa male talase ne tumačimo kao dokaz zasebnih grupa. Za diskretne veličine, poput sata, frekvencije su neposredniji prikaz, a KDE je dopunski. Logaritamska osa samo mijenja prikaz izvornih vrijednosti; stvarna transformacija `log1p` provjerava se zasebno.

Tabela 9: Numerička statistika balansiranog skupa; n je broj IQR izdvajanja

Atribut	Sredina	s	Min.	Medijan	Maks.	Skew	n
amt	299,52	373,92	1,00	89,55	6 337,25	1,48	118
lat	38,62	5,13	20,03	39,41	66,69	0,03	66
long	-90,28	14,08	-165,67	-87,41	-67,95	-1,20	491
city_pop	90 510,75	303 554,43	23,00	2 526,00	2 906 700,00	5,62	2774
unix_time (10^9 s)	1,3488	0,0133	1,3254	1,3489	1,3718	0,00	0
merch_lat	38,61	5,17	19,04	39,40	67,51	0,03	79
merch_long	-90,28	14,11	-166,55	-87,36	-67,03	-1,19	480
age_years	47,57	18,06	13,99	46,05	95,48	0,48	0
distance_km	76,38	28,85	0,74	78,39	144,52	-0,24	0
hour	13,30	8,37	0,00	15,00	23,00	-0,30	0
day_of_week	3,10	2,13	0,00	3,00	6,00	-0,10	0
month	5,86	3,43	1,00	5,00	12,00	0,37	0

Iznos transakcije (`amt`)

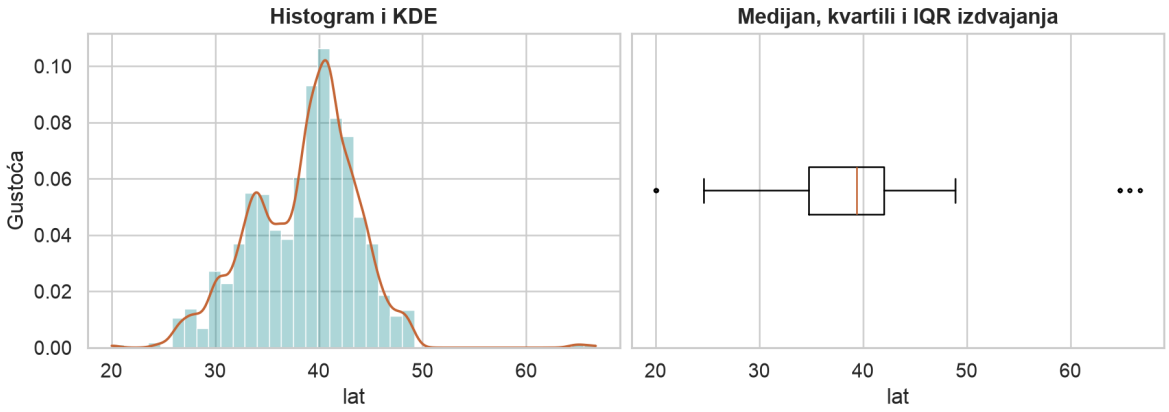
Iznos je pozitivna novčana veličina izražena u USD. Sredina je približno 299,52, a medijan 89,55 USD. Razlika pokazuje da desni rep znatno utiče na prosjek. Koeficijent asimetrije od oko 1,48 potvrđuje izraženu asimetriju udesno. Raspon do 6 337,25 USD obuhvata i ispravne velike transakcije.



Slika 2: Pojedinačni profil: amt. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Geografska širina korisnika (`lat`)

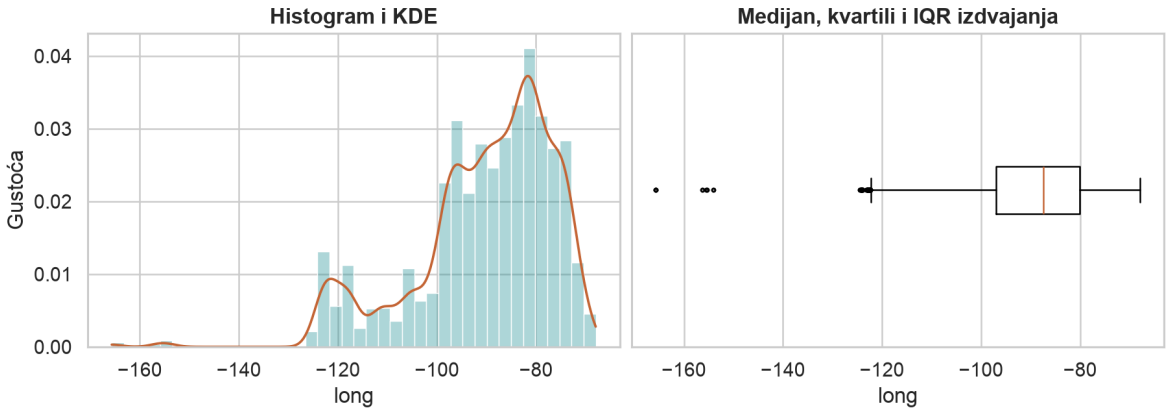
Širina opisuje lokaciju korisnika u stepenima. Raspon približno 20,03–66,69 nalazi se unutar dozvoljenog geografskog intervala. Sredina i medijan su bliski, a asimetrija je oko 0,03. Ipak, histogram ima više lokalnih koncentracija jer transakcije potiču s ponovljenih lokacija, a ne iz ravnomjerno naseljenog prostora.



Slika 3: Pojedinačni profil: lat. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Geografska dužina korisnika (`long`)

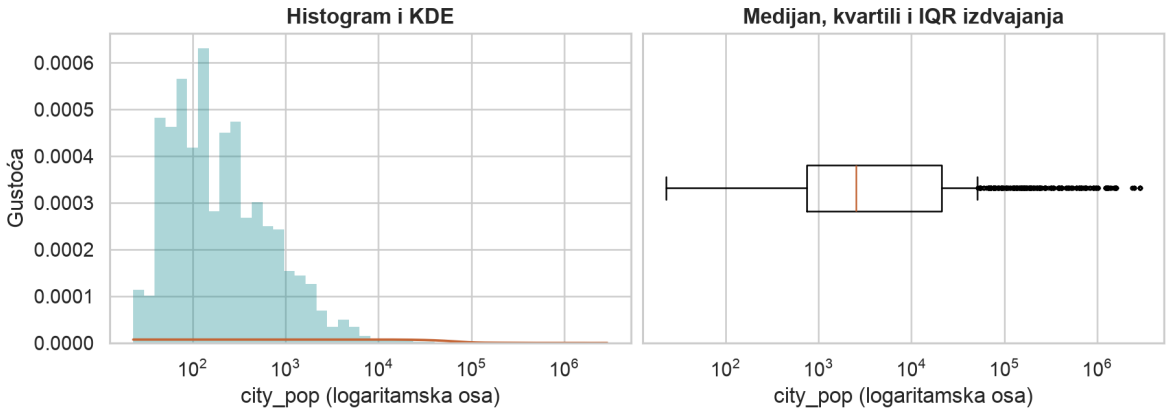
Dužina sadrži negativne vrijednosti zbog lokacija na zapadnoj hemisferi. Negativan predznak je dio geografskog značenja i nije greška koju treba ispravljati. Raspon je približno od $-165{,}67$ do $-67{,}95$ stepeni. Asimetrija oko $-1{,}20$ opisuje duži lijevi rep u rasporedu zastupljenih lokacija.



Slika 4: Pojedinačni profil: long. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Broj stanovnika grada (`city_pop`)

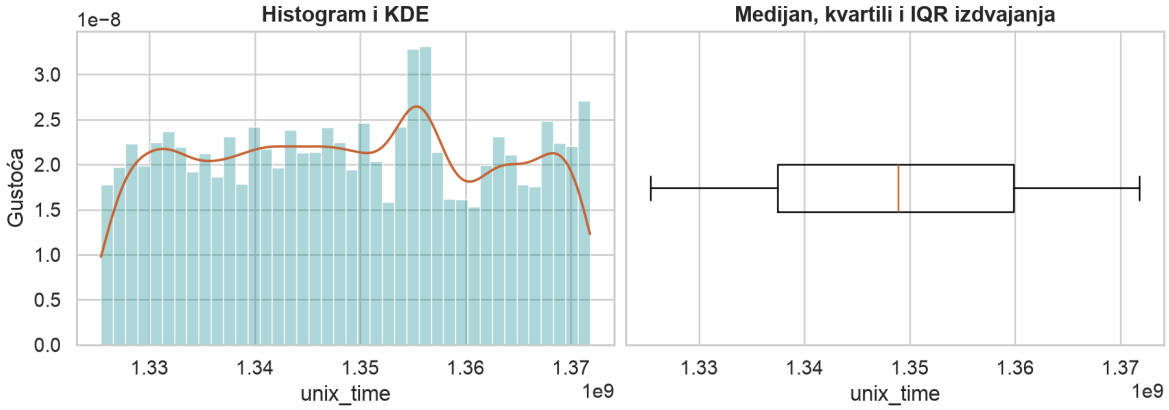
Populacija grada je nenegativna brojčana veličina s vrlo dugim desnim repom. Medijan je 2 526 stanovnika, dok je sredina oko 90 510,75. Maksimum iznosi 2 906 700. Razlika nije posljedica zaokruživanja: mali broj transakcija iz velikih gradova znatno podiže aritmetičku sredinu.



Slika 5: Pojedinačni profil: city_pop. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Numerički zapis vremena (`unix_time`)

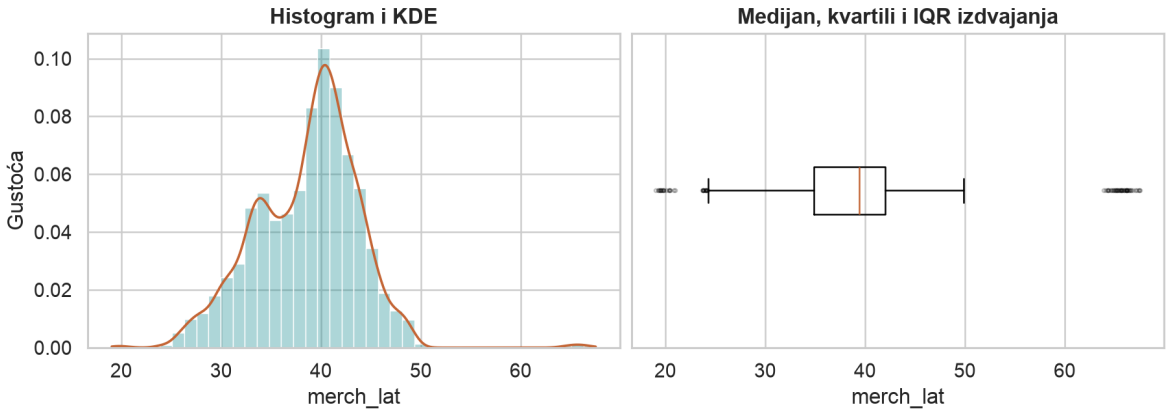
Ova kolona je numerička pohrana vremenske oznake. Zbog potpunosti analize uključena je u deskriptivnu statistiku, histogram, KDE i box plot, iako neće ostati u konačnim ulazima. Asimetrija je blizu nule, a IQR ne izdvaja redove. Takav rezultat sam po sebi ne potvrđuje da je vremenski zapis semantički ispravan.



Slika 6: Pojedinačni profil: unix_time. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Geografska širina trgovca (`merch_lat`)

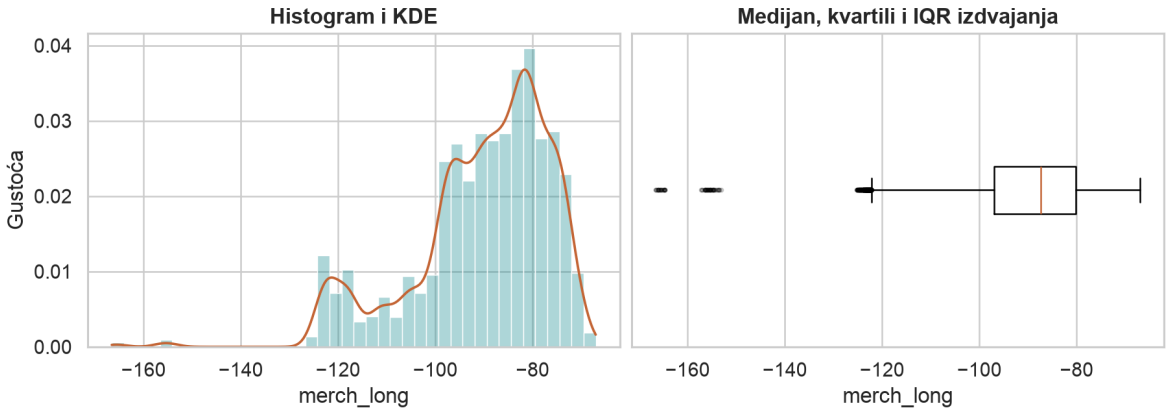
Širina trgovca ima raspodjelu vrlo sličnu širini korisnika. Sredina je približno 38,61 stepen, a asimetrija oko 0,03. Svi zapisi su unutar dopuštene geografske širine. IQR izdvaja 79 redova, ali ne ukazuje samostalno na pogrešno unesene lokacije. Broj izdvajanja zato se navodi kao opis raspodjele.



Slika 7: Pojedinačni profil: merch_lat. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Geografska dužina trgovca (`merch_long`)

Dužina trgovca prati dužinu korisnika i ima izražen lijevi rep, s asimetrijom oko $-1{,}19$. Negativne vrijednosti su dopuštene geografske koordinate. IQR pravilo izdvaja 480 transakcija. Razlika u broju izdvajanja u odnosu na dužinu korisnika očekivana je jer dvije lokacije nisu potpuno jednake.



Slika 8: Pojedinačni profil: merch_long. Histogram i KDE opisuju oblik raspodjele, a box plot kvartile i izdvojene vrijednosti.

Izdvojene vrijednosti i ciljna klasa

Zajedničke IQR granice računaju se iz cijelog balansiranog uzorka. Kada se takve granice primijene posebno na dvije klase, broj izdvojenih redova pokazuje koja klasa doprinosi repu raspodjele. To nije zamjena za logičku provjeru ispravnosti. Kod iznosa se posebno vidi da statistički ekstrem može biti legitimna kupovina.

Datumi transakcije i datumi rođenja

Tekstualni datum i vrijeme uspješno se pretvaraju u datumski tip. Najranije i najkasnije transakcije obuhvataju 1. 1. 2019.–21. 6. 2020. Posljednji mjesec je nepotpun. Broj transakcija po mjesecu zavisi od dužine posmatranog intervala i sastava uzorka, pa pad u posljednjem mjesecu ne tumačimo kao samostalnu promjenu intenziteta kupovine ili učestalosti prevare.

Godina rođenja i datum transakcije omogućavaju određivanje približne starosti u trenutku događaja. Time se izbjegava računanje starosti prema današnjem datumu, koje bi promijenilo značenje historijskih transakcija. Koristi se vremenska razlika u sekundama podijeljena sa 365,2425 dana po godini; vrijednosti se ne zaokružuju prije dalje obrade. Ovdje se radi o približnoj kontinuiranoj starosti, a ne broju navršenih godina.

Starost se kreće približno od 13,99 do 95,48 godina, sa sredinom 47,57 i medijanom 46,05. U simuliranom skupu nismo našli datum rođenja nakon transakcije. Iz same starosti ne izvodi se dodatno pravilo za uklanjanje redova. Histogram starosti ponderisan je brojem transakcija: osoba s većim brojem kupovina pojavljuje se češće.

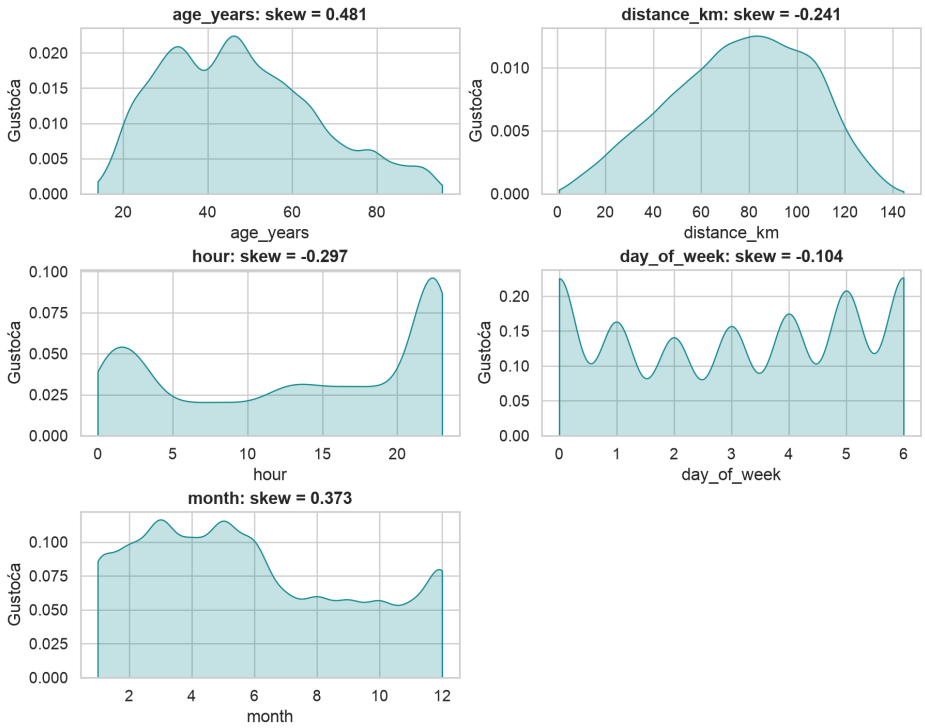


Slika 9: Vremenski obuhvat, godine rođenja, neslaganje Unix zapisa i približna starost po transakciji.

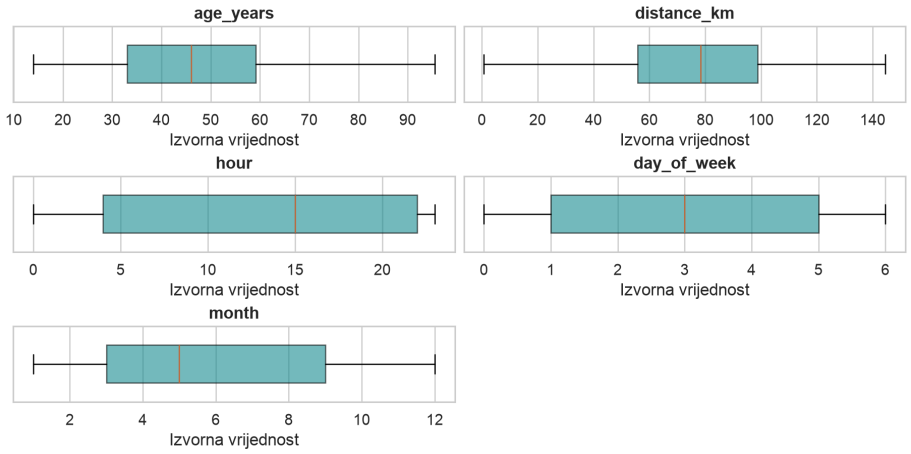
Izvedena starost i udaljenost

Izvedene veličine analiziraju se jednako kao izvorne: provjeravaju se raspon, rasipanje, asimetrija i IQR izdvajanja. Izračunavanje nove kolone samo po sebi ne opravdava njeno zadržavanje. Važno je utvrditi ima li ona razumljivo značenje, da li uvodi grešku i koju informaciju sažima iz početnog skupa.

Starost ima blagu desnu asimetriju i ne zahtijeva logaritamsku transformaciju. Udaljenost zračnom linijom ima sredinu približno 76,38 km, medijan 78,39 km i raspon 0,74–144,52 km u balansiranom uzorku. Njena raspodjela nije izrazito asimetrična. Sredine po klasama su slične, pa se samoj udaljenosti ne pripisuje snažno razdvajanje klasa. Njena vrijednost u pripremi je i sažimanje odnosa lokacija.



Slika 10: Gustoće svih izvedenih veličina. Sat, dan i mjesec su diskretne veličine; KDE je pomoćni prikaz.



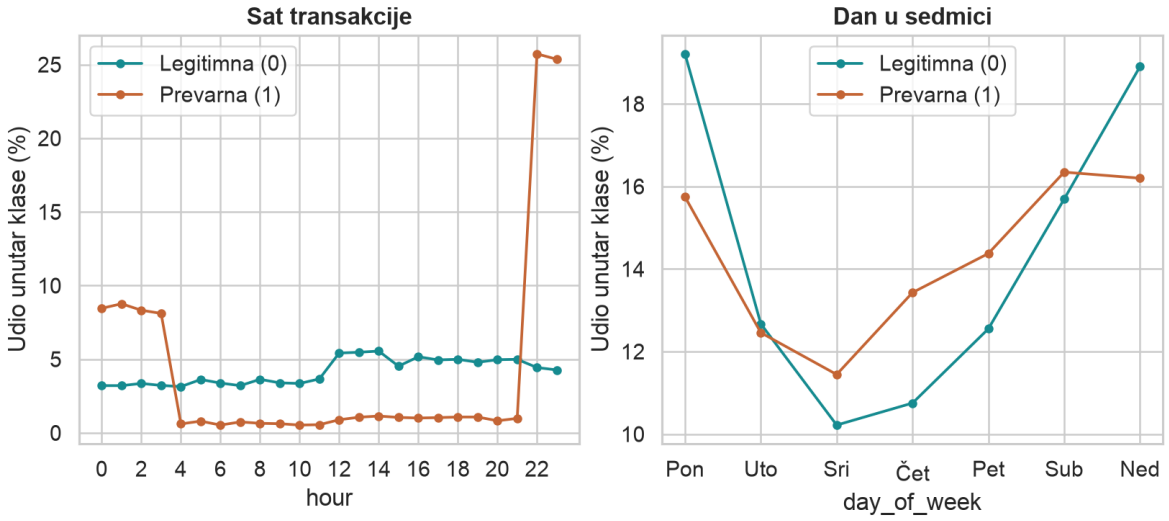
Slika 11: Kutijasti prikazi izvedenih veličina; iste granice opisa primjenjuju se prije odluke o transformacijama.

Sat i dan u sedmici: cikličnost i obrasci klasa

Sat (0–23) i dan u sedmici (0–6) su ciklični: 23 i 0 su vremenski susjedni, iako im je brojčana razlika velika. Zato u pripremi čuvamo njihov kružni odnos.

Između 22:00 i 03:59 dešava se 84,76 % prevara i 21,72 % legitimnih transakcija u balansiranom uzorku. To su udjeli unutar klase, a ne procjena rizika noćne kupovine; razlike po danima su manje izražene.

Mala ukupna asimetrija sata ne poništava noćni obrazac. Ista vrijednost asimetrije može nastati za različite rasporede vrhova, a kružna priroda sata nije sadržana u tom jednom koeficijentu. Za pripremu zato uvodimo sinus i kosinus sata i dana, uz periode 24 i 7. Mjesec ostaje u analizi zbog nepotpunog godišnjeg obuhvata.

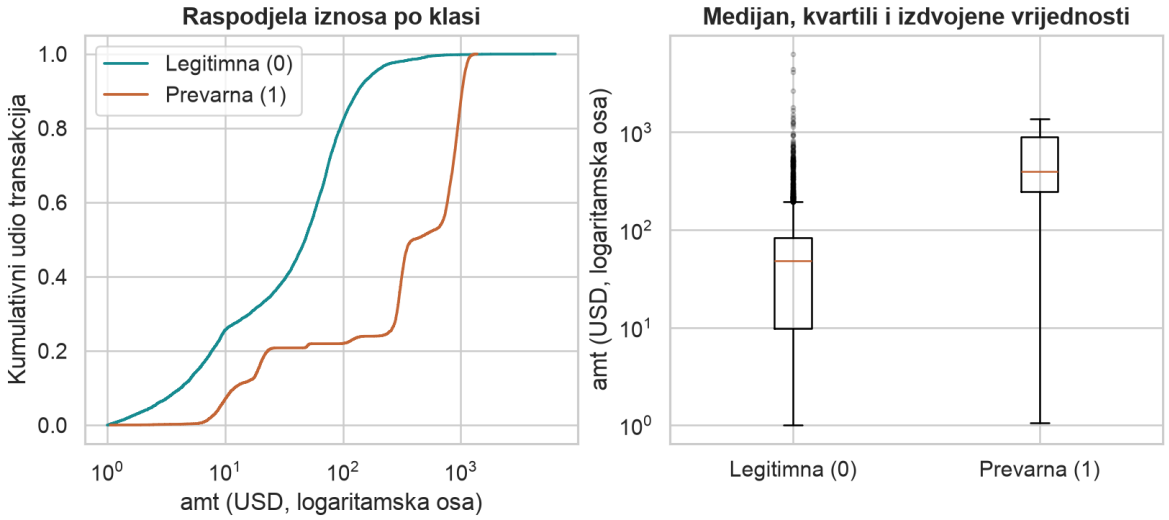


Slika 12: Sat i dan u sedmici: udjeli su normalizovani posebno unutar legitimnih i prevarnih transakcija.

Razlike u iznosima između klasa

Prosječni iznosi nisu dovoljni da opišu preklapanje klasa. Zato koristimo i empirijsku kumulativnu raspodjelu te box plot po klasi. Kumulativna kriva na odabranoj vrijednosti iznosa pokazuje udio transakcija koje imaju taj ili manji iznos. Na visini 0,5 može se očitati medijan bez pretpostavljanja određenog oblika raspodjele.

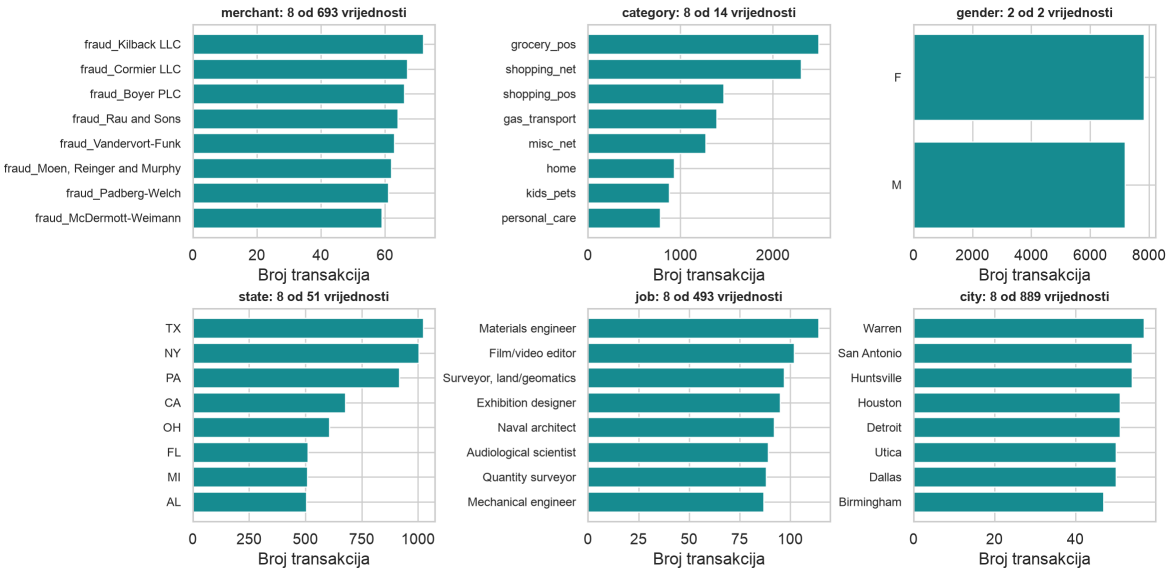
Medijan legitimnih iznosa je 47,92 USD, a prevarnih 396,50 USD. Veći iznosi su zastupljeniji među prevarama u ovom uzorku, ali postoje i male prevare i velike legitimne kupovine. Najveći iznos, 6 337,25 USD, pripada legitimnoj transakciji. Takav nalaz dodatno podržava očuvanje velikih vrijednosti i transformaciju skale umjesto jednostavnog uklanjanja repa raspodjele.



Slika 13: Empirijske kumulativne raspodjele i box plot iznosa po klasama; logaritamska osa čuva prikaz cijelog raspona.

Kategoričke varijable: zastupljenost i rijetke grupe

Za kategoričke atribute razlikujemo broj različitih oznaka i broj redova koji im pripada. Veliki broj kategorija može značiti mnogo rijetkih grupa, ali taj odnos treba izračunati. Zbog toga tabela prikazuje koliko kategorija ima manje od deset transakcija, koliko ukupno redova one obuhvataju i koliki dio uzorka zauzima deset najčešćih vrijednosti. Ovi pokazatelji služe opisu, bez korištenja cilja za izbor grupa.



Slika 14: Najčešće vrijednosti šest nominalnih atributa. Prikaz osam vrijednosti nije potpuna raspodjela svih kategorija.

Vrsta kupovine: svih četrnaest kategorija

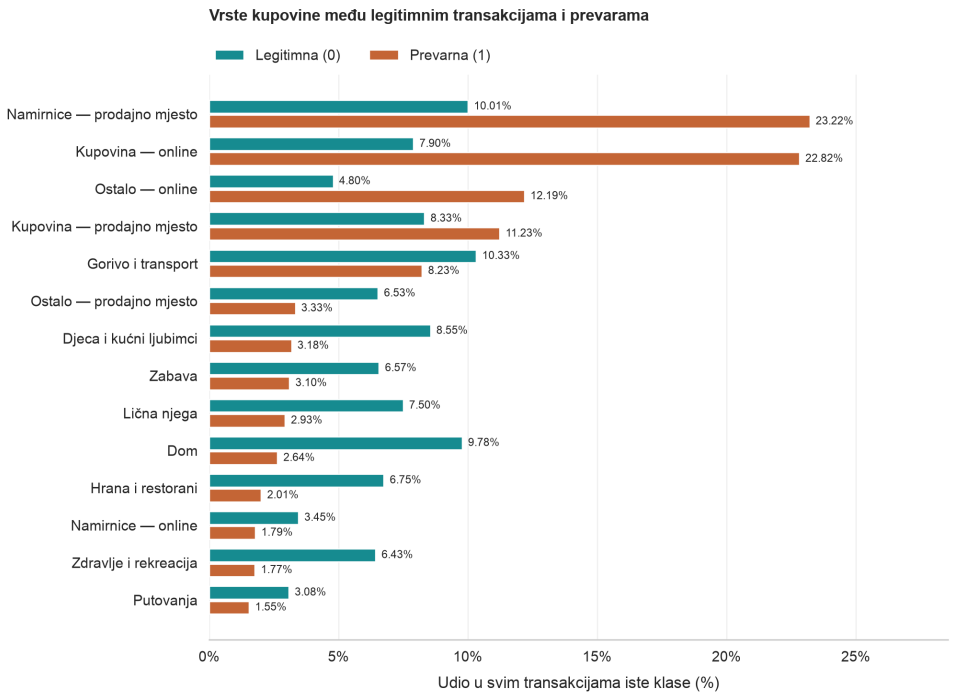
Atribut `category` opisuje vrstu transakcije i ima 14 vrijednosti. Kategorije online kupovine i kupovine na prodajnom mjestu predstavljaju različite vrste događaja, pa se njihove oznake čuvaju odvojeno. Ovaj atribut ima umjeren broj vrijednosti i jasnije sadržajno značenje od pojedinačnog naziva trgovca.

Najzastupljenija kategorija u balansiranom uzorku je `grocery_pos`. Među svim prevarama posebno su zastupljene `grocery_pos` i `shopping_net`. Međutim, kada se gleda udio prevare unutar određene kategorije, nazivnik je ukupan broj transakcija te kategorije. Zato se tabela i grafikon čitaju kao odgovori na dva različita pitanja.

Udio prevara po kategoriji prikazan u tabeli uslovljen je odnosom klasa u balansiranom uzorku. On je koristan za opis uzorka, ali se ne prenosi neposredno kao procjena rizika. Za pripremu se zadržavaju sve kategorije i kodiraju bez proizvoljnog poretka. U svakoj od njih ima dovoljno zapisa da se u ovom opisu ne primjenjuje grupisanje po odabranom pragu za trgovca i zanimanje.

Tabela 10: Struktura svih vrsta kupovine u balansiranom uzorku

Kategorija	Ukupno	Legitimne	Prevare	Udio prevara
grocery_pos	2 494	751	1 743	69,89 %
shopping_net	2 306	593	1 713	74,28 %
shopping_pos	1 468	625	843	57,43 %
gas_transport	1 393	775	618	44,36 %
misc_net	1 275	360	915	71,76 %
home	932	734	198	21,24 %
kids_pets	881	642	239	27,13 %
personal_care	783	563	220	28,10 %
misc_pos	740	490	250	33,78 %
entertainment	726	493	233	32,09 %
food_dining	658	507	151	22,95 %
health_fitness	616	483	133	21,59 %
grocery_net	393	259	134	34,10 %
travel	347	231	116	33,43 %



Slika 15: Vrste kupovine po klasi. Svaka klasa zasebno daje zbir 100 %, pa se poredi njen unutrašnji sastav.

Trgovac i zanimanje: veliki broj nominalnih oznaka

U balansiranom skupu postoji 693 različitih trgovaca i 493 zanimanja. Ove kolone ne treba tretirati potpuno jednako kao 14 vrsta kupovine. Kod trgovca prosječan broj zapisa po nazivu je mali, a kod zanimanja se ponavljaju transakcije istih korisnika. Pojedinačno zanimanje ili trgovac s nekoliko primjera daju ograničenu osnovu za opis razlika među klasama.

Svi nazivi trgovaca imaju prefiks `fraud_`, pa taj dio teksta ne donosi razliku između klasa. Ostatak naziva predstavlja nominalnu oznaku; abecedni redoslijed naziva nema mjerno značenje. Prikaz najčešćih trgovaca pokazuje i da najčešći naziv sam zauzima mali dio ukupnog uzorka.

Zanimanje opisuje korisnika, a ne neposredno svojstvo pojedinačne kupovine. Jedna osoba zato doprinosi više redova istoj kategoriji zanimanja. Frekvenciju transakcija ne poistovjećujemo s brojem ljudi zaposlenih u tom zanimanju. Za rijetke grupe procenat prevara može biti vrlo nestabilan, pa izbor praga grupisanja zasnivamo na broju zapisa, a ne na njihovom ciljnom ishodu.

Grad, savezna država i poštanski broj

Geografske oznake imaju različitu detaljnost. Savezna država opisuje šire područje, dok grad i poštanski broj često predstavljaju vrlo specifičnu lokaciju. U balansiranom skupu ima 889 gradova, 51 savezna država i 964 poštanska broja. Unija izvora sadrži još više gradova i poštanskih brojeva.

Sam naziv grada ne mora biti jedinstvena lokacija bez konteksta savezne države. Ni razlika između dva poštanska broja ne predstavlja fizičku udaljenost. Zato ove oznake nisu uključene u numeričke korelacije. Njihova veza s lokacijom ispituje se brojem različitih koordinata i kartica po oznaci, uz zadržavanje činjenice da nazivi i prostorne granice nisu savršeno jednoznačni.

Tabela 11: Geografske oznake i ponovljene lokacije u balansiranom skupu

Oznaka	Različitih	Medijan lokacija	Medijan kartica
city	889	1,00	1,00
zip	964	1,00	1,00
state	51	17,00	17,00

Spol i šira geografska zastupljenost

Spol ima dvije kategorije, F i M, bez ordinalnog značenja. Njihove frekvencije opisuju sastav simuliranih transakcija. One ne predstavljaju broj jedinstvenih osoba, niti dovoljan osnov za uzročno tumačenje razlika u ishodima. U pripremi se čuvaju dvije one-hot kolone kako bi prikaz bio neposredno čitljiv.

Savezna država ima 51 nominalnu oznaku u zajedničkom opisu. Za razliku od grada i poštanskog broja, broj kolona je znatno manji, a oznake pružaju lako tumačiv regionalni kontekst. Zadržava se cijela raspodjela, uključujući slabije zastupljena područja. Na malim grupama se ne izvode čvrsti zaključci iz procenta prevara.

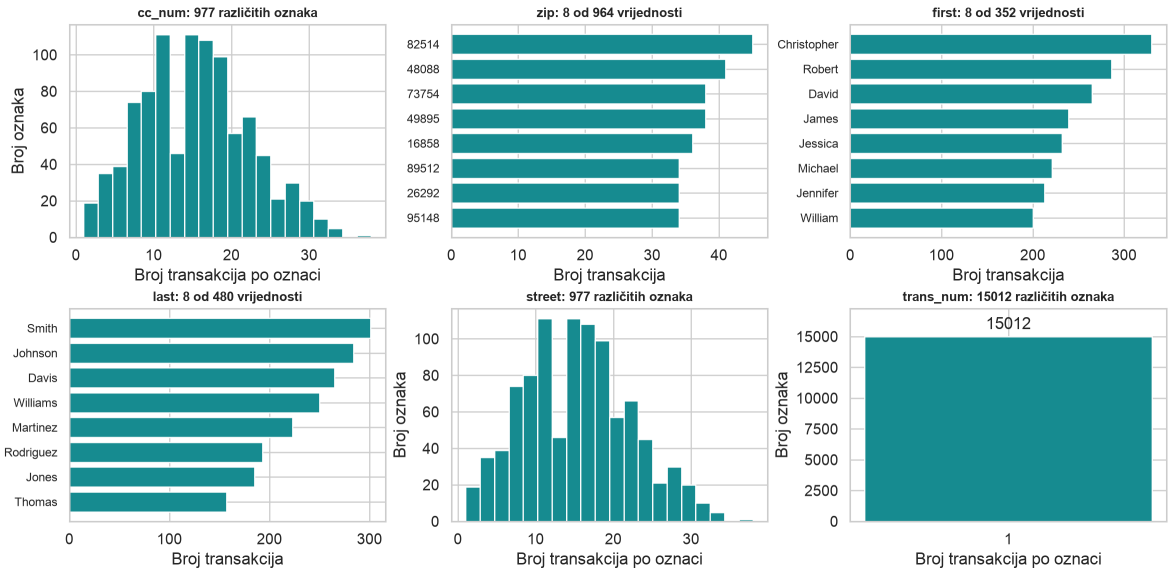
Identifikatori, imena i adrese

Broj kartice `cc_num` identifikator je koji povezuje više transakcija. U balansiranom uzorku postoje 977 kartica. Njegova numerička veličina ne opisuje iznos, redoslijed ponašanja ili udaljenost. Zato računanje prosjeka broja kartice ili standardizovanje njegovih cifara ne bi imalo korisno mjerno značenje.

Oznaka `trans_num` jedinstvena je za svaku transakciju. Njena uloga je provjera duplikata i preklapanja verzija, te održavanje veze između pripremljenog reda i izvornog zapisa. Ona se čuva u NPZ metapodacima, a izostavlja iz ulaza. U kasnijoj podjeli ove oznake omogućavaju provjeru odvojenosti transakcija.

Imena i prezimena nisu jedinstvene oznake osobe. Ista vrijednost može pripadati različitim korisnicima, dok ponovljene kupovine iste osobe povećavaju frekvenciju jedne oznake. U balansiranom uzorku najčešće ime je Christopher, a prezime Smith. Ove frekvencije opisuju sastav uzorka i ne pružaju sadržajno obrazloženje događaja prevare. Imena i prezimena zato se ne zadržavaju među ulazima.

Adresa `street` ponavlja se za istog korisnika i izostavlja se s brojem kartice, imenom i prezimenom. Iz pripreme se uklanjaju samo identifikacijske kolone; transakcije se ne brišu zbog ponovljenih oznaka.



Slika 16: Ponavljanje kartica i adresa, najčešći poštanski brojevi, imena i prezimena te jedinstvenost oznake transakcije.

Preklapanje izvora

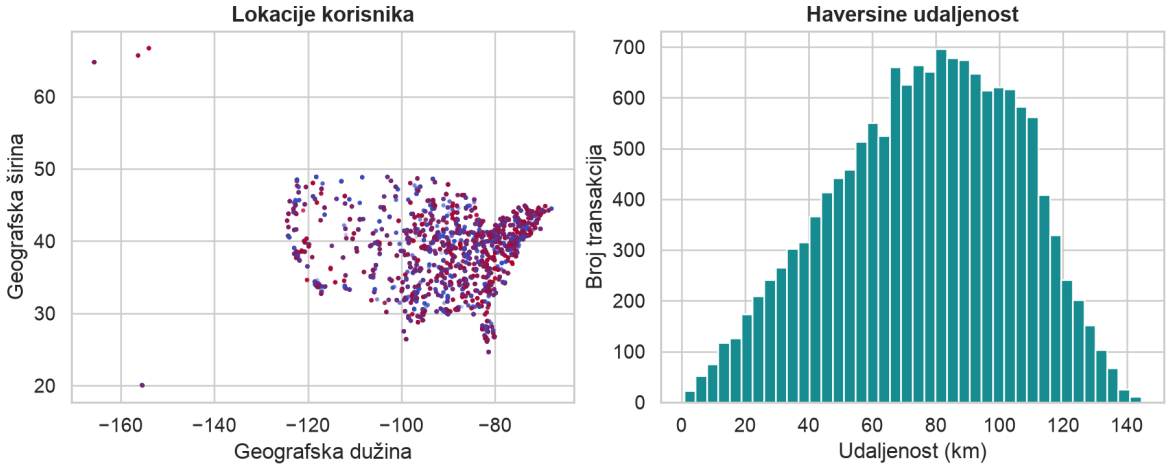
Poređenjem `trans_num` pronađene su 7 593 zajedničke transakcije. Unija dva izvora zato sadrži 22 419 jedinstvenih transakcija, umjesto zbira njihovih veličina. Zajednički opisni pretprocesor u 1.4 prilagođava se toj uniji bez ponovljenih oznaka, kako iste transakcije ne bi dobile dodatnu težinu.

Ponavljanje između dvije verzije je očekivano jer su obje izvedene iz istog originala. Ono se razlikuje od duplikata unutar jednog CSV-a, kojih nema. Kod kasnije podjele treba uvažiti zajedničke transakcije tako da izdvojene oznake za provjeru budu isključene iz odgovarajućih dijelova obje verzije. U ovoj fazi se ta podjela ne implementira i ne formiraju se dodatni izvozi.

Geografski odnosi i izvedena udaljenost

Raspored koordinata pokazuje koncentracije transakcija na ponovljenim lokacijama. Na slici su tačke obojene prema klasi samo radi opisa. Preklapanje tačaka i veća aktivnost pojedinih lokacija otežavaju neposredno poređenje sirovih gustina. Na osnovu takvog prikaza ne izvodi se zaključak da je određeno područje samo po sebi uzrok prevare.

Koordinate korisnika i trgovca snažno su povezane, ali male razlike između njih opisuju prostorni odnos. Haversine udaljenost koristi sve četiri koordinate i čuva tu razliku u jednoj veličini. Radi se o udaljenosti zračnom linijom na sferi, a ne dužini putovanja cestom. Zemljin poluprečnik u računu iznosi 6 371,0088 km.



Slika 17: Raspored lokacija u simuliranom uzorku i raspodjela udaljenosti korisnika od trgovca.

Pearsonova i Spearmanova povezanost

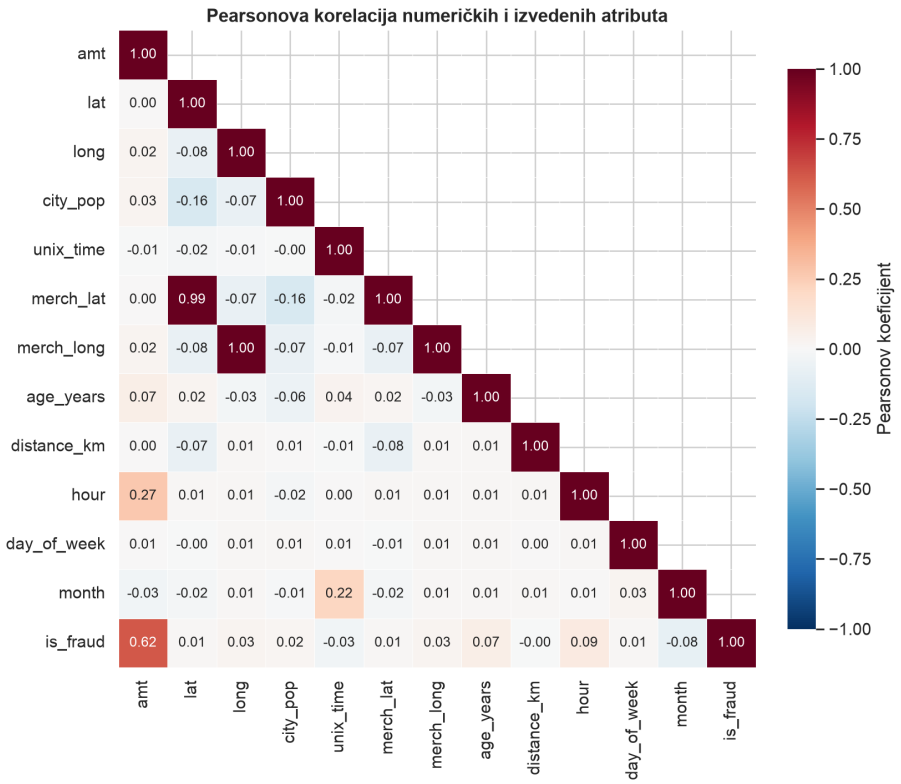
Pearsonov koeficijent opisuje linearnu povezanost numeričkih veličina, a Spearmanov povezanost njihovih rangova. Koristimo oba jer izraženi repovi i nelinearni odnosi mogu dati različitu sliku. Identifikatori i nominalni kodovi izostavljeni su iz ovih matrica: njihovo pretvaranje u proizvoljne brojeve proizvelo bi koeficijente bez opravdanog mjernog značenja.

Povezanost iznosa s ciljem je približno 0,62 po Pearsonu i 0,58 po Spearmanu. Razlika pokazuje da oba prikaza bilježe odnos u ovom uzorku, ali ne identično. Slabiji koeficijenti drugih pojedinačnih atributa ne dokazuju da su oni beskorisni: interakcije i ciklični obrasci nisu potpuno opisani pojedinačnom linearnom vezom.

Tabela 12: Pearsonova i Spearmanova povezanost s ciljem u balansiranom uzorku

Atribut	Pearson	Spearman
amt	0,620	0,578
lat	0,008	0,005
long	0,026	0,036
city_pop	0,022	0,009
unix_time	-0,032	-0,032
merch_lat	0,008	0,004
merch_long	0,025	0,035
age_years	0,068	0,063
distance_km	-0,004	-0,005
hour	0,088	0,158
day_of_week	0,011	0,008
month	-0,078	-0,087

Koeficijenti su opisni za balansirani uzorak i ne potvrđuju uzročnost.



Slika 18: Pearsonova matrica originalnih i izvedenih numeričkih veličina te ciljne klase.

1.4. Priprema i transformacija podataka

Pripremamo oba cijela skupa istim postupkom. Balansirani zadržava 15 012 redova, a nebalansirani 15 000. Čuvanje obje verzije omogućava rad s podjednako zastupljenim klasama i s približnim izvornim udjelom prevara. Razlika u njihovim raspodjelama ostaje očuvana; transformacije mijenjaju prikaz ulaza, a ne oznake klasa.

Sažetak postupaka po karakteristikama

Tabela 13 povezuje svaki atribut ili grupu atributa sa postupkom, razlogom i odjeljkom bilježnice. Oznake A–D predstavljaju odjeljke `1.4-A` do `1.4-D` u `projekat.ipynb`. Odjeljak `1.4-B` sadrži statističke i grafičke provjere promjena.

Tabela 13: Sažetak pripreme po karakteristikama i poveznica s kodom

Karakteristika	Postupak	Obrazloženje	Kod
`amt`	Zamjena sa `amt_log1p` i standardizacija	Sabijanje izraženog desnog repa bez gubitka redova.	A, C
`city_pop`	Zamjena sa `city_pop_log1p` i standardizacija	Veliki gradovi ostaju zastupljeni, uz manju razliku skala.	A, C
`lat`, `long`	Zadržavanje i standardizacija	Čuvanje lokacije korisnika; koordinate su dopuštene.	A, C
`merch_lat`, `merch_long`	Izvođenje `distance_km`, zatim izostavljanje	Sažimanje prostornog odnosa jako povezanih koordinata.	A
`trans_date_ trans_time`	Četiri ciklične komponente sata i dana	Čuvanje susjednosti početka i kraja perioda.	A
`dob`	Izvođenje `age_years`; izostavljanje sirovog datuma	Starost u trenutku konkretne transakcije.	A
`unix_time`	Izostavljanje	Neusklađenost s tekstualnim vremenom transakcije.	A
`cc_num`, `first`, `last`, `street`	Izostavljanje iz ulaza	Identifikatori i lični podaci sa mnogo ponavljanja.	A
`city`, `zip`	Izostavljanje iz ulaza	Mnogo detaljnih geografskih oznaka, uz već dostupne koordinate i državu.	A
`merchant`, `job`	Grupisanje vrijednosti s manje od 20 transakcija i one-hot	Smanjenje broja rijetkih oznaka uz očuvanje zasebnih kategorija za većinu redova.	C
`category`, `gender`, `state`	One-hot bez grupisanja	Nominalni atributi bez prirodnog poretka.	C
Numerički ulazi	Rezervna imputacija medijanom	Robusna središnja vrijednost za asimetrične raspodjele; sada nema praznina.	C

Karakteristika	Postupak	Obrazloženje	Kod
Nominalni ulazi	Rezervna imputacija najčešćom vrijednošću	Čuvanje postojeće kategorije; sada nema praznina.	C
`is_fraud`	Odvajanje cilja, bez transformacije	Ciljna oznaka se ne uključuje u ulaze.	A, D
`trans_num`	Odvajanje i čuvanje identifikatora	Veza sa izvornim redom i praćenje preklapanja skupova.	A, D

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.4-A Izbor i izvođenje atributa“*.

Izbor ulaza i izvođenje smislenih veličina

Identifikatori, imena, prezimena i adrese ne opisuju neposredno svojstvo kupovine, pa ih izostavljamo iz ulaza. `trans_num` čuvamo uz cilj kao metapodatak. Grad i poštanski broj izostavljamo zbog 894 i 970 različitih oznaka u uniji izvora i preklapanja s dostupnim lokacijskim opisom. Lokaciju zadržavaju `lat`, `long` i `state`. Time prihvatamo gubitak detaljnih administrativnih oznaka, uz očuvanje izvornog zapisa u CSV-u.

Iz datuma transakcije i rođenja računamo približnu starost u trenutku transakcije. Vremensku razliku u sekundama dijelimo sa $86400 \cdot 365{,}2425$, bez ranog zaokruživanja. Za sat i dan koristimo po dvije komponente, $\sin(2\pi x/P)$ i $\cos(2\pi x/P)$, sa periodima $P = 24$ i $P = 7$. Par komponenti čuva kružnu susjednost i razlikuje položaje koje sam sinus ne razlikuje. Mjesec ostaje u analizi zbog nepotpunog godišnjeg obuhvata.

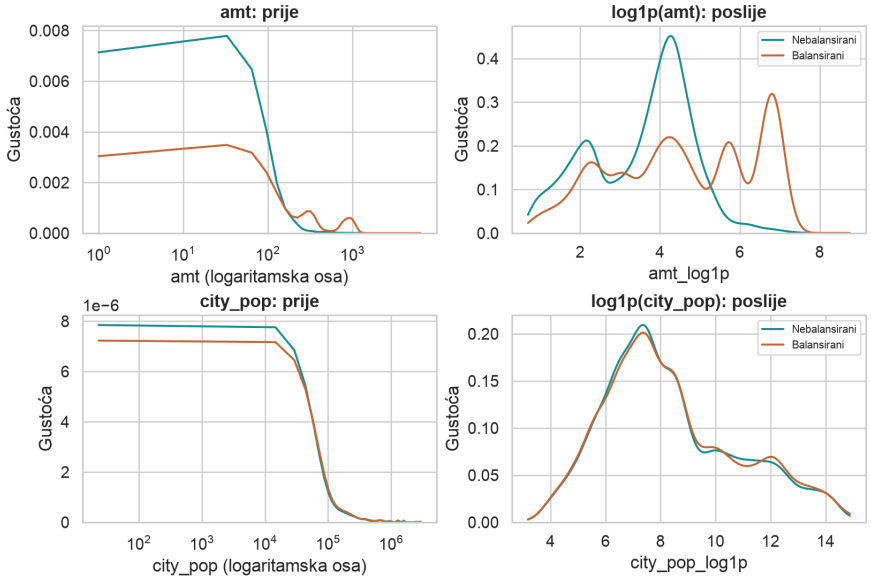
Haversine udaljenost računamo iz četiri izvorne koordinate u radijanima, sa poluprečnikom 6 371,0088 km. Ona opisuje udaljenost zračnom linijom. Nakon njenog izvođenja izostavljamo koordinate trgovca, a zadržavamo koordinate korisnika i udaljenost. Sirove datume i neusklađeni `unix_time` izostavljamo. Redoslijed je važan: izvedene veličine računamo prije izostavljanja datuma i prije standardizacije koordinata.

Asimetrija, transformacija i izdvojene vrijednosti

Za iznos i populaciju koristimo $x' = \ln(1 + x)$, odnosno `log1p`. Transformacija je monotona i jače sabija velike vrijednosti, pa čuva poredak uz smanjenje desnog repa. Izvorne kolone zamjenjujemo transformisanim ulazima. Geografske dužine ne logaritmujemo: negativne vrijednosti imaju dopušteno geografsko značenje, a asimetrija odražava raspored lokacija.

Tabela 14: Promjena asimetrije i IQR izdvajanja nakon log1p

Skup	Atribut	Skew prije	Poslije	IQR prije	Poslije
Nebalansirani	amt	16,60	-0,31	742	6
Nebalansirani	city_pop	5,52	0,60	2 758	0
Balansirani	amt	1,48	-0,21	118	0
Balansirani	city_pop	5,62	0,58	2 774	0



Slika 19: Gustoće iznosa i populacije prije i poslije log1p za oba skupa.

U oba skupa smanjuje se asimetrija iznosa i populacije. Preostala umjerena asimetrija populacije nije sama po sebi razlog za dodatnu transformaciju. IQR granice se ponovo računaju na transformisanoj skali; promjena broja izdvajanja ne znači da su redovi izbrisani. Nema potvrđenih neispravnih ekstrema, pa ne primjenjujemo automatsko brisanje niti ograničavanje velikih vrijednosti. Statistika, gustoće i box plotovi svih izvedenih ulaza za oba skupa dostupni su u kodu.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.4-B Provjera transformacija i outliera“*.

Nominalni atributi i rijetke kategorije

Trgovac, vrsta kupovine, spol, savezna država i zanimanje nemaju prirodan poredak. Zbog toga koristimo one-hot kodiranje, a ne proizvoljne ordinalne brojeve. Za `category`, `gender` i `state` čuvamo svih 14, 2 i 51 kategoriju. Za trgovca i zanimanje prvo grupišemo rijetke vrijednosti.

Prag biramo pregledom frekvencija u uniji 22 419 jedinstvenih transakcija. Prag 20 čuva zasebne oznake za približno 91,2 % transakcija po trgovcu i 94,3 % po zanimanju. Viši prag jače sažima prikaz, ali većem dijelu transakcija uklanja zaseban

naziv. Pregled pragova 10, 20, 30 i 50 nalazi se u bilježnici. Izbor se zasniva na broju pojavljivanja, bez korištenja cilja.

Postavka `min_frequency=20` spaja kategorije s manje od 20 redova u zajedničku rijetku grupu za svaki atribut. Nove trgovce i zanimanja usmjeravamo u tu grupu ako je prisutna; ostale nepoznate nominalne vrijednosti obrađujemo bez prekida transformacije. Svaka transakcija ostaje sačuvana.

Tabela 15: Broj kategorija prije i poslije grupisanja i one-hot kodiranja

Atribut	Izvornih	Grupisano	Izlaznih kolona
category	14	0	14
gender	2	0	2
state	51	0	51
merchant	693	142	552
job	494	98	397

Dobijamo 1 026 kolona: 10 numeričkih, 67 za vrstu kupovine, spol i državu, 552 za trgovca i 397 za zanimanje. Prikaz čuva zasebne kategorije za većinu transakcija, uz manje rijetkih one-hot kolona.

Standardizacija i nedostajuće vrijednosti

Numeričke ulaze standardizujemo izrazom $z = (x-\mu)/\sigma$ poslije logaritamskih transformacija; one-hot kolone ostaju 0/1. Nema praznih vrijednosti. Kao rezervu uključujemo medijan za numeričke i najčešću vrijednost za nominalne ulaze. Medijan je otporan na duge repove, za razliku od osjetljivije aritmetičke sredine.

Za prikaz pripreme oba cijela skupa koristimo jedan pretprocesor prilagođen uniji jedinstvenih transakcija. Tako imaju iste kategorije i skale, bez dvostrukog računanja zajedničkih redova. Pri primjeni na odvojene dijelove frekvencije, imputacija i skale određuju se isključivo iz trening podataka.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„1.4-C Kodiranje i standardizacija“*.

Pripremljeni skupovi za naredne korake

Svaki skup čuvamo u zasebnoj NPZ datoteci: `fraud_balanced_prepared.npz` i `fraud_15k_prepared.npz`. One sadrže cilj, oznake transakcija, nazive kolona, zajedničku kodiranu matricu i numeričke i kategoričke ulaze prije standardizacije i one-hot kodiranja. Datoteke čuvaju iste ulazne karakteristike uz različit broj i odnos klasa, pa se u kasnijem radu mogu pripremiti i podijeliti odvojeno.

Kodirane matrice daju zajednički prikaz karakteristika u ovom odjeljku. Za obuku modela koriste se sačuvani ulazi prije kodiranja: podaci se prvo dijele, a grupisanje kategorija, imputacija i skale određuju se samo na trening dijelu. Ulazni CSV-ovi

ostaju dostupni kao izvorni zapisi. Pripremljeni skupovi imaju 15 012 i 15 000 redova (kod: `projekat.ipynb`, odjeljak `1.4-D`).

2. Odabir klasifikacijskih algoritama

2.1. Odabir algoritama i raspodjela rada

Za binarni cilj `is_fraud` biramo pet pojedinačnih klasifikacijskih algoritama, po jedan za svakog člana tima. Izbor obuhvata različite načine opisivanja odnosa između ulaza i klase: pravila grananja, linearnu granicu, nelinearnu granicu s jezgrom, lokalno susjedstvo i neuronsku mrežu.

Tabela 16: Odabrani algoritmi i odgovorni članovi tima

Član tima	Algoritam	Veza s pripremljenim podacima
Aldin Velić	Stablo odlučivanja	Numerički pragovi, čitljiva pravila grananja i nelinearni odnosi.
Bakir Činjarević	Logistička regresija	Binarni ishod i linearni doprinos standardizovanih i one-hot ulaza.
Danijal Alibegović	SVM, radijalna jezgra	Nelinearna granica na standardizovanim numeričkim i kodiranim kategoričkim ulazima.
Haris Macić	k-najbližih susjeda	Lokalna sličnost transakcija; važnost skale i odabranih karakteristika.
Kerim Hajdar	Višeslojni perceptron	Nelinearne interakcije numeričkih i kategoričkih karakteristika.

Razlozi izbora

Stablo odlučivanja – Aldin Velić. Pravila grananja podržavaju čitljiv opis nelinearnih odnosa. Dubina i veličina listova određuju složenost. Implementacija: `DecisionTreeClassifier`.

Logistička regresija – Bakir Činjarević. Binarni cilj povezuje s linearnim doprinosima ulaza; priprema čuva različite skale i nominalne oznake. Implementacija: `LogisticRegression`.

SVM – Danijal Alibegović. Radijalna jezgra omogućava nelinearnu granicu; standardizacija usklađuje ulaze za računanje sličnosti. Implementacija: `SVC`.

k-NN – Haris Macić. Koristi lokalno susjedstvo transakcije. Važni su skala, dimenzionalnost i izbor rastojanja. Implementacija: `KNeighborsClassifier`.

Višeslojni perceptron – Kerim Hajdar. Skriveni slojevi opisuju nelinearne interakcije; standardizacija podržava numeričku optimizaciju. Implementacija: `MLPClassifier`.

Kod: GitHub repozitorij `bakir004/mu`, bilježnica `projekat.ipynb`, odjeljak *„2.1 Odabir algoritama i raspodjela rada“*.

Literatura

[1] kartik2112, "Credit card transactions fraud detection dataset." Kaggle, https://www.kaggle.com/datasets/kartik2112/fraud-detection. Pristupljeno: 29.10.2026.

[2] J. K. Afriyie, K. Tawiah, W. A. Pels, S. Addai-Henne, H. A. Dwamena, E. O. Owiredu, S. A. Ayeh, and J. Eshun, "A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions," *Decision Analytics Journal*, vol. 6, p. 100163, 2023. https://doi.org/10.1016/j.dajour.2023.100163.

[3] A. Al-Bulushi, A. K. Shaikh, and N. Adhikari, "Applying supervised machine learning algorithms and ensemble models to enhance credit card fraud detection," *Frontiers in Artificial Intelligence*, vol. 9, p. 1813728, 2026. https://doi.org/10.3389/frai.2026.1813728.

[4] D. Breskuvienė and G. Dzemyda, "Enhancing credit card fraud detection: highly imbalanced data case," *Journal of Big Data*, vol. 11, p. 182, 2024. https://doi.org/10.1186/s40537-024-01059-5.

[5] E. Ileberi, Y. Sun, and Z. Wang, "A machine learning based credit card fraud detection using the GA algorithm for feature selection," *Journal of Big Data*, vol. 9, p. 24, 2022. https://doi.org/10.1186/s40537-022-00573-8.

[6] S. S. Sulaiman, I. Nadher, and S. M. Hameed, "Credit card fraud detection using improved deep learning models," *Computers, Materials & Continua*, vol. 78, no. 1, pp. 1049–1069, 2024. https://doi.org/10.32604/cmc.2023.046051.