Univerzitet u Sarajevu
Elektrotehnički fakultet

Mašinsko učenje

Akademska godina 2026/2027.

Detekcija prevarnih finansijskih transakcija

Projektni zadatak – I dio

Članovi tima:

1. Aldin Velić
2. Bakir Činjarević
3. Danijal Alibegović
4. Haris Macić
5. Kerim Hajdar

Sarajevo, 18. decembar 2026.

Sadržaj

1 Odabir, analiza i priprema podataka **1**

1.1 Odabir teme i skupa podataka 1

1.2 Pregled naučnoistraživačkih radova 3

1.3 Istraživačka analiza podataka 15

1.4 Priprema i transformacija podataka 17

2 Izgradnja klasifikacijskih modela **17**

2.1 Odabir algoritama i raspodjela rada 17

2.2 Izgradnja i evaluacija pojedinačnih modela 18

2.2.1 Model 1: *[odabrati algoritam]*– Aldin Velić 18

2.2.2 Model 2: *[odabrati algoritam]*– Bakir Činjarević 18

2.2.3 Model 3: *[odabrati algoritam]*– Danijal Alibegović 19

2.2.4 Model 4: *[odabrati algoritam]*– Haris Macić 20

2.2.5 Model 5: *[odabrati algoritam]*– Kerim Hajdar 21

2.3 Poređenje i ansambl-model 21

Literatura **23**

1. Odabir, analiza i priprema podataka

1.1. Odabir teme i skupa podataka

Tema. Predmet projekta je prepoznavanje prevarnih finansijskih transakcija na osnovu karakteristika pojedinačnih transakcija. Zadatak se posmatra kao **nadzirana binarna klasifikacija**, jer je za treniranje poznata ciljna klasa.

Izvor. Kao polazni skup koristi se *Credit Card Transactions Fraud Detection Dataset* sa platforme Kaggle [1]. Skup je simuliran alatom *Sparkov Data Generation* i obuhvata transakcije približno 1 000 korisnika kod oko 800 trgovaca u periodu od 1. januara 2019. do 31. decembra 2020. godine. Objavljen je u dvije datoteke: `fraudTrain.csv` (1 296 675 transakcija) i `fraudTest.csv` (555 719 transakcija). Ciljni atribut je `is_fraud`: vrijednost 0 označava legitimnu, a 1 prevarnu transakciju.

Formiranje korištenog skupa. Originalni skup je izrazito nebalansiran – u `fraudTrain.csv` je samo 7 506 prevarnih transakcija (približno 0,58 %). Zbog veličine originalnih datoteka i potrebe da sve faze rada (analiza, više modela, unakrsna validacija i podešavanje hiperparametara) budu izvodive u Google Colabu, iz `fraudTrain.csv` su izvedene tri manje verzije skupa:

- `fraud_balanced.csv` – **osnovni radni skup**: sve 7 506 prevarnih transakcija i isto toliko nasumično odabranih legitimnih transakcija (*random undersampling*, `random_state=42`), odnos klasa 50/50;
- `fraud_15k.csv` i `fraud_50k.csv` – stratifikovani uzorci od 15 000 i 50 000 transakcija koji zadržavaju originalni udio prevara (0,58 %). Ovi skupovi služe za provjeru ponašanja modela u realističnom, nebalansiranom okruženju.

Sve tri verzije zadržavaju svih 22 kolone originalnog skupa (prva, indeksna kolona originalne datoteke je izostavljena).

Provjera uslova specifikacije. Radni skup ima 15 012 instanci (≥ 1000) i 21 ulazni atribut (≥ 15). Sadrži i numeričke atribute (npr. iznos, koordinate, broj stanovnika) i kategoričke atribute (npr. kategorija kupovine, spol, država, zanimanje), pa je mješovitog tipa. Ciljna varijabla `is_fraud` je unaprijed određena i binarna.

Ograničenja podataka. Podaci su simulirani, pa uočeni obrasci ne moraju u potpunosti odgovarati stvarnom finansijskom poslovanju. Dio kolona su identifikatori ili lični podaci (`trans_num`, `cc_num`, `first`, `last`, `street`) koji nemaju opštu prediktivnu vrijednost i mogu dovesti do pretjeranog prilagođavanja modela. Svi nazivi trgovaca imaju prefiks `fraud_` koji je artefakt generatora, a ne indikator prevare. Datumske kolone je potrebno transformisati (npr. sat transakcije, starost korisnika) da bi bile upotrebljive. Konačno, balansirani skup ne odražava stvarni udio prevara, pa se metrike poput preciznosti

Tabela 1: Osnovne karakteristike korištenog skupa podataka

Karakteristika	Podatak
Naziv datoteke	`fraud_balanced.csv` (dodatno `fraud_15k.csv` i `fraud_50k.csv`)
Broj instanci	15 012 (odnosno 15 000 i 50 000)
Broj atributa	21 ulazni atribut + ciljna varijabla `is_fraud` (ukupno 22 kolone)
Numerički atributi	9: `amt`, `lat`, `long`, `merch_lat`, `merch_long`, `city_pop`, `unix_time`, `cc_num`, `zip`
Kategorički i tekstualni atributi	12: `category`, `gender`, `state`, `city`, `job`, `merchant`, `first`, `last`, `street`, `trans_num`, te datumi `trans_date_trans_time` i `dob`
Ciljna varijabla	`is_fraud` (0 – legitimna; 1 – prevarna)
Udio klase 1	50,00 % u `fraud_balanced.csv`; 0,58 % u `fraud_15k.csv` (87 prevara) i `fraud_50k.csv` (289 prevara)
Nedostajuće vrijednosti / duplikati	nema / nema
Vremenski raspon (radni skup)	1. 1. 2019. – 21. 6. 2020.

Tabela 2: Opis atributa skupa podataka

Atribut	Tip	Značenje
`trans_date_trans_time`	datum/vrijeme	datum i vrijeme transakcije
`cc_num`	identifikator	broj kartice (977 različitih kartica)
`merchant`	kategorički	naziv trgovca (693 vrijednosti)
`category`	kategorički	kategorija kupovine (14 vrijednosti, npr. `grocery_pos`, `shopping_net`)
`amt`	numerički	iznos transakcije u USD
`first`, `last`	tekstualni	ime i prezime vlasnika kartice
`gender`	kategorički	spol vlasnika kartice (F/M)
`street`, `city`, `state`, `zip`	kategorički	adresa vlasnika kartice (51 savezna država)
`lat`, `long`	numerički	geografske koordinate vlasnika kartice
`city_pop`	numerički	broj stanovnika grada vlasnika kartice
`job`	kategorički	zanimanje vlasnika kartice (493 vrijednosti)
`dob`	datum	datum rođenja vlasnika kartice
`trans_num`	identifikator	jedinstveni identifikator transakcije
`unix_time`	numerički	vrijeme transakcije u UNIX formatu
`merch_lat`, `merch_long`	numerički	geografske koordinate trgovca
`is_fraud`	binarni (klasa)	0 – legitimna, 1 – prevarna transakcija

dobijene na njemu ne mogu direktno prenijeti na realističnu raspodjelu; zato se zadržavaju i stratifikovani uzorci s originalnim odnosom.

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„1.1 Odabir i učitavanje skupa podataka“*.

1.2. Pregled naučnoistraživačkih radova

Svaki od pet članova analizira najmanje jedan relevantan naučnoistraživački rad. Za svaki rad navode se **problem, skup podataka, metode, metrike i najbolji rezultat**. Tri rada ([2, 3, 4]) koriste isti Sparkov skup podataka kao naš projekat, a dva ([5, 6]) najčešće korišteni stvarni evropski skup transakcija, što omogućava poređenje nalaza na simuliranim i stvarnim podacima.

Naučnoistraživački rad – Aldin Velić

Naslov rada: *A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions.*

Autori: Jonathan Kwaku Afriyie, Kassim Tawiah, Wilhemina Adoma Pels, Sandra Addai-Henne, Harriet Achiaa Dwamena, Emmanuel Odame Owiredu, Samuel Amening Ayeh i John Eshun.

Izvor: *Decision Analytics Journal*, vol. 6, članak 100163, 2023. [2]

Tabela 3: Sažeti pregled naučnoistraživačkog rada Afriyie i saradnika (2023)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama kao problem binarne klasifikacije, pri čemu se razlikuju legitimne i prevarne transakcije.
Skup podataka	*Credit Card Transactions Fraud Detection Dataset* (Kaggle), simuliran pomoću alata Sparkov. U radu se navodi 555 719 transakcija i 23 kolone u početnom skupu podataka.
Korištene metode	Logistička regresija (Logistic Regression), stablo odlučivanja (Decision Tree) i slučajna šuma (Random Forest). Priprema podataka uključuje skaliranje i nasumično smanjivanje većinske klase (undersampling).
Metrike	Tačnost (accuracy), preciznost (precision), osjetljivost (recall/sensitivity), specifičnost, F1-mjera i ROC-AUC.
Najbolji rezultat	**Random Forest**: tačnost **96%**, ROC-AUC **98,9%**. Prijavljene vrijednosti: recall 0,97, precision 0,09 i F1-mjera 0,17.

Cilj i istraživački problem.

Autori istražuju koliko uspješno različiti algoritmi nadziranog mašinskog učenja razlikuju prevarne od legitimnih transakcija. Osnovni cilj jeste uporediti performanse tri klasifikacijska algoritma i utvrditi koji je najpogodniji za analizirani skup podataka.

Dodatno istražuju obrasce povezane s iznosom i vremenom transakcije, kategorijom trgovca te pojedinim karakteristikama korisnika.

Skup podataka i njegova nebalansiranost.

Rad koristi javno dostupan Kaggle skup simuliranih transakcija, obavljenih tokom 2020. godine u Sjedinjenim Američkim Državama.

Skup obuhvata numeričke i kategoričke atribute, a ciljna varijabla predstavlja status prevare.

Nakon postupaka obrade, u Tabeli 4 rada prikazano je 482 672 legitimnih i 2 135 prevarnih transakcija, odnosno približno 99,6% i 0,4%.

Takva raspodjela predstavlja izraženu nebalansiranost klasa, pa sama ukupna tačnost nije dovoljna za procjenu uspješnosti klasifikatora.

Priprema podataka i korištene metode.

Autori navode čišćenje podataka, transformaciju numeričkih atributa na raspon od 0 do 1 i primjenu metode *random undersampling*.

Ova metoda smanjuje broj primjera većinske klase kako bi se ublažila pristrasnost

modela prema legitimnim transakcijama.

Na Slici 1 rada prikazan je uravnotežen uzorak s 1 708 prevarnih i 1 707 legitimnih transakcija.

Za klasifikaciju se zatim koriste logistička regresija, jedno stablo odlučivanja i Random Forest, koji kombinuje veći broj stabala.

Poređenje eksperimentalnih rezultata.

U Tabeli 4 prikazane su vrijednosti koje su autori objavili u Tabeli 11 i uz ROC krive (Slika 16).

Tabela 4: Poređenje rezultata klasifikacijskih algoritama iz rada

Model	**Acc.**	**Prec.**	**Recall**	**F1**	**Spec.**	**AUC**
Decision Tree	0,92	0,05	0,93	0,09	0,92	0,945
Logistic Regression	0,92	0,04	0,76	0,08	0,92	0,872
Random Forest	**0,96**	**0,09**	**0,97**	**0,17**	**0,96**	**0,989**

Tumačenje rezultata.

Random Forest je postigao najveće vrijednosti svih prikazanih metrika.

Njegov ROC-AUC od 0,989 ukazuje na veoma dobru sposobnost razlikovanja klasa pri promjeni klasifikacijskog praga.

Međutim, precision od samo 0,09 znači da je tek približno 9% transakcija označenih kao prevarne zaista bilo prevarno.

Iz objavljene konfuzijske matrice (Tabela 7 rada) vidi se da je model prepoznao 409 prevara i propustio 18, ali je 4 052 legitimne transakcije pogrešno označio kao prevarne.

Zato visoka tačnost i ROC-AUC ne znače da model proizvodi malo lažnih alarma.

Niska F1-mjera (0,17) dodatno ukazuje na neravnotežu između preciznosti i osjetljivosti modela.

Dodatna zapažanja iz istraživačke analize.

Autori izvještavaju da se veći broj prevarnih transakcija u njihovom skupu javlja između 22:00 i 04:00 GMT te posebno razmatraju starosnu grupu korisnika iznad 60 godina i kategoriju kupovine.

Budući da su podaci simulirani, ova zapažanja predstavljaju obrasce uočene u posmatranom skupu, a ne dokazane zakonitosti stvarnog finansijskog poslovanja.

Zaključak i značaj za istraživanje.

Istraživanje upućuje na to da Random Forest može biti uspješan izbor za detekciju

prevarnih transakcija, posebno prema ROC-AUC i osjetljivosti.

Istovremeno pokazuje da izrazita nebalansiranost klasa zahtijeva pažljivu evaluaciju i praćenje lažnih alarma.

Nalazi rada predstavljaju osnovu za očekivanje da će metode zasnovane na stablima ostvarivati konkurentne rezultate, ali i da će precision, recall i F1-mjera biti važnije za praktičnu interpretaciju nego sama ukupna tačnost.

Naučnoistraživački rad – Bakir Činjarević

Naslov rada: *Applying supervised machine learning algorithms and ensemble models to enhance credit card fraud detection.*

Autori: Abrar Al-Bulushi, Abdul K. Shaikh i Naresh Adhikari.

Izvor: *Frontiers in Artificial Intelligence*, vol. 9, članak 1813728, 2026. [3]

Tabela 5: Sažeti pregled naučnoistraživačkog rada Al-Bulushi i saradnika (2026)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama kao binarna klasifikacija na izrazito nebalansiranim podacima, uz provjeru generalizacije modela na neviđenim skupovima podataka.
Skup podataka	Glavni skup za treniranje i testiranje je *isti Sparkov skup* koji koristi naš tim (približno 1,3 miliona transakcija, 0,5 % prevara, 22 atributa). Skup od 555 719 transakcija iz iste kolekcije i još četiri javna skupa (među njima evropski skup od 284 807 transakcija i PaySim) služe kao neviđeni skupovi.
Korištene metode	Logistička regresija, Naive Bayes, stablo odlučivanja, Random Forest, neuronska mreža (ANN) i XGBoost; uravnotežavanje metodama RUS, ROS i SMOTE; selekcija atributa (korelacija, ANOVA, RFE, unaprijedna selekcija); novi atributi ponašanja korisnika; pomjeranje praga odlučivanja; ansambli *bagging*, *boosting* i *stacking*.
Metrike	Tačnost, preciznost, osjetljivost (recall), F1-mjera i AUC, uz konfuzijsku matricu; 4-struka unakrsna validacija.
Najbolji rezultat	Pojedinačno: **XGBoost** bez uravnotežavanja, F1 **0,84** (AUC 0,99). Konačni model **Bagging 1** (10 modela): F1 **0,795**, recall 0,864, AUC 0,99; uz nove atribute ponašanja F1 raste na **0,83** (recall 0,89).

Cilj i istraživački problem. Autori razvijaju cjelovit okvir za detekciju prevara koji objedinjuje izbor algoritma, uravnotežavanje klasa, selekciju i konstrukciju atributa te ansambl modele. Posebno ih zanima da li model treniran na jednom skupu zadržava performanse na drugim, neviđenim skupovima podataka.

Skup podataka i priprema. Rad je za nas posebno relevantan jer kao glavni skup koristi upravo Sparkov podatke sa Kaggle platforme, sa 12 kategoričkih i 11 numeričkih atributa i bez nedostajućih vrijednosti. Podaci su standardizovani (*z-score*), a podjela je urađena 4-strukom unakrsnom validacijom (75 % podataka za treniranje). Autori su konstruisali i nove atribute ponašanja: oznaku da li je transakcija izvan uobičajenog vremenskog prozora korisnika (izvan 10.–90. percentila sati transakcija) i *anomaly score* dobijen metodom Isolation Forest.

Poređenje eksperimentalnih rezultata. Tabela 6 prikazuje izdvojene rezultate iz Tabela 1, 8 i 9 rada (pojedinačni modeli, pomjeranje praga i ansambli).

Tabela 6: Izdvojeni rezultati iz rada Al-Bulushi i saradnika (Sparkov skup)

Model	**Acc.**	**F1**	**Prec.**	**Recall**	**AUC**
Logistička regresija – RUS	0,87	0,06	0,03	0,76	0,96
Naive Bayes – bez uravnoteženja	0,90	0,07	0,04	0,68	0,82
Stablo odlučivanja – ROS	0,99	0,78	0,79	0,77	0,88
Random Forest – bez uravnoteženja	0,99	0,82	0,88	0,76	0,97
Random Forest – RUS	0,97	0,30	0,17	0,97	0,99
ANN – bez uravnoteženja	0,99	0,83	0,93	0,76	0,99
XGBoost – bez uravnoteženja	**0,99**	**0,84**	**0,91**	**0,79**	**0,99**
XGBoost – SMOTE, prag 0,7	0,99	0,70	0,67	0,85	0,99
Bagging 1 (10 modela)	0,99	0,79	0,73	0,86	0,99
Stacking 1 (RF baza, ANN meta)	0,99	0,80	0,79	0,80	0,93
Boosting 2 (LR + AdaBoost)	0,99	0,00	0,00	0,00	0,82

Tumačenje rezultata. Logistička regresija i Naive Bayes daju vrlo nisku F1-mjeru (ispod 0,1) bez obzira na metodu uravnotežavanja, dok modeli zasnovani na stablima (Random Forest, XGBoost) i neuronska mreža postižu F1 oko 0,8. Rezultati jasno pokazuju kompromis između preciznosti i osjetljivosti: *random undersampling* podiže recall Random Foresta na 0,97, ali preciznost pada na 0,17, jer model treniran na uravnoteženim podacima na realističnoj raspodjeli generiše mnogo lažnih alarma. Tačnost je za gotovo sve modele 0,99 i zato nije informativna. Ansambl Bagging 1 nije postigao najveći F1, ali su ga autori izabrali kao konačni model zbog stabilnosti i visokog recall-a, a na neviđenom Sparkov skupu postiže F1 0,61, odnosno 0,66 uz nove atribute ponašanja.

Zaključak i značaj za istraživanje. Rad potvrđuje da su na našem skupu podataka metode zasnovane na stablima i *boosting* najperspektivnije, a da su linearni modeli i Naive Bayes slabi. Za naš projekat su posebno korisna tri zapažanja: (1) uravnotežavanje treba primjenjivati samo na skupu za treniranje i pratiti njegov uticaj na preciznost, (2) pomjeranje praga odlučivanja je jednostavan način da se podesi odnos preciznosti i osjetljivosti, i (3) atributi izvedeni iz vremena transakcije i ponašanja korisnika mogu dodatno poboljšati detekciju.

Naučnoistraživački rad – Danijal Alibegović

Naslov rada: *Enhancing credit card fraud detection: highly imbalanced data case.*

Autori: Dalia Breskuvienė i Gintautas Dzemyda.

Izvor: *Journal of Big Data*, vol. 11, članak 182, 2024. [4]

Tabela 7: Sažeti pregled naučnoistraživačkog rada Breskuvienė i Dzemyde (2024)

Stavka	**Opis**
Problem	Selekcija atributa za detekciju prevara kreditnim karticama kada su podaci izrazito nebalansirani; uobičajene metode selekcije atributa zanemaruju manjinsku klasu.
Skup podataka	Tri skupa: sintetički skup transakcija (3 445 553 instanci, 0,14 % prevara), *Sparkov* skup – spojene datoteke `fraudTrain` i `fraudTest` (1 852 394 instanci, 0,52 % prevara) i stvarni evropski skup (284 807 instanci, 0,17 % prevara).
Korištene metode	Nova metoda selekcije atributa FID-SOM zasnovana na samoorganizujućim mapama (SOM), upoređena s univarijatnom selekcijom (F-test, χ^2, uzajamna informacija), RFE i važnošću atributa iz XGBoosta. Klasifikatori: Random Forest, XGBoost i CatBoost.
Metrike	F1-mjera, MCC, G-Mean, AUC-PR i AUC-ROC; svaki rezultat je prosjek pet ponavljanja s različitim *random seed* vrijednostima.
Najbolji rezultat	Na Sparkov skupu: **XGBoost + FID-SOM** (7 atributa), F1 **0,855**, AUC-PR 0,895, AUC-ROC 0,998, MCC 0,857 (bez selekcije atributa F1 je 0,543).

Cilj i istraživački problem. Autori polaze od toga da su podaci o prevarama nebalansirani, visoko dimenzionalni (posebno nakon kodiranja kategoričkih atributa) i podložni promjeni obrazaca kroz vrijeme (*concept drift*). Cilj rada je pokazati da

pažljivo odabran, manji skup atributa poboljšava klasifikaciju više nego dodatni atributi.

Skup podataka i priprema. Za nas je posebno važno što je drugi skup u radu isti Sparkov skup, pri čemu su autori spojili datoteke za treniranje i testiranje i koristili 11 atributa. Umjesto nasumične podjele, podaci su podijeljeni *hronološki*: najranijih 80 % transakcija čini skup za treniranje, a kasnijih 20 % skup za testiranje. Autori naglašavaju da nasumična podjela vremenski zavisnih podataka daje previše optimistične rezultate. Kategorički atributi su kodirani *James-Stein* enkoderom, a numerički normalizovani na raspon [0, 1]. Namjerno nije korišteno uravnotežavanje klasa ni podešavanje hiperparametara, kako bi se izolovao čist efekat selekcije atributa.

Poređenje eksperimentalnih rezultata. Tabela 8 prikazuje rezultate iz Tabele 6 rada za Sparkov skup, i to za model bez selekcije atributa (*baseline*) i za predloženu metodu FID-SOM.

Tabela 8: Rezultati na Sparkov skupu iz rada Breskuvienė i Dzemyde

Model	**F1**	**AUC-ROC**	**AUC-PR**	**MCC**	**G-Mean**
CatBoost – svi atributi	0,750	0,991	0,769	0,765	0,791
CatBoost – FID-SOM	0,828	0,997	0,866	0,831	0,870
Random Forest – svi atributi	0,622	0,967	0,767	0,660	0,682
Random Forest – FID-SOM	0,835	0,978	0,868	0,839	0,866
XGBoost – svi atributi	0,543	0,973	0,641	0,593	0,622
XGBoost – FID-SOM	**0,855**	**0,998**	**0,895**	**0,857**	**0,889**

Tumačenje rezultata. Na Sparkov skupu selekcija atributa ima veoma veliki efekat: F1-mjera XGBoosta raste s 0,543 na 0,855, a Random Foresta s 0,622 na 0,835. Istovremeno, AUC-ROC je visok (0,97–0,998) i za modele bez selekcije, što pokazuje da AUC-ROC na izrazito nebalansiranim podacima slabo razlikuje dobre i lošije modele. Zato autori stavljaju naglasak na AUC-PR, MCC i F1-mjeru. Na stvarnom evropskom skupu, čiji su atributi već dobijeni PCA transformacijom, efekat selekcije je mnogo manji (F1 0,796 naspram 0,801 za XGBoost). Ukupno je FID-SOM bio najbolja metoda u 32 od 45 poređenja (71 %).

Zaključak i značaj za istraživanje. Rad pokazuje da su na našem skupu ansambli stabala (XGBoost, CatBoost, Random Forest) uspješni, ali da njihove performanse snažno zavise od izbora atributa. To za naš projekat znači da treba ukloniti identifikatore i nebitne atribute, a kao metrike koristiti F1, AUC-PR i MCC, a ne samo tačnost i AUC-ROC. Rad upozorava i da nasumična podjela podataka može precijeniti performanse, pa je hronološka podjela vrijedna razmatranja.

Naučnoistraživački rad – Haris Macić

Naslov rada: *A machine learning based credit card fraud detection using the GA algorithm for feature selection.*

Autori: Emmanuel Ileberi, Yanxia Sun i Zenghui Wang.

Izvor: *Journal of Big Data*, vol. 9, članak 24, 2022. [5]

Tabela 9: Sažeti pregled naučnoistraživačkog rada Ileberija i saradnika (2022)

Stavka	**Opis**
Problem	Detekcija prevarnih transakcija kreditnim karticama uz izbor optimalnog podskupa atributa pomoću genetskog algoritma (GA).
Skup podataka	Evropski skup transakcija kreditnim karticama (Kaggle, septembar 2013.): 284 807 transakcija, 0,172 % prevara, 30 numeričkih atributa (V1–V28 dobijeni PCA transformacijom, `Time`, `Amount`). Dodatna provjera na sintetičkom skupu s oko 24,4 miliona transakcija.
Korištene metode	Genetski algoritam za selekciju atributa (funkcija prilagođenosti je tačnost Random Foresta); klasifikatori: stablo odlučivanja, Random Forest, logistička regresija, ANN i Naive Bayes; SMOTE za uravnotežavanje i *min-max* normalizacija.
Metrike	Tačnost (glavna metrika), osjetljivost (recall), preciznost, F1-mjera i AUC.
Najbolji rezultat	**GA-RF** s vektorom atributa v5 (13 atributa): tačnost **99,98 %**, preciznost 95,34 %, recall 72,56 %, F1-mjera 82,41 %.

Cilj i istraživački problem. Autori smatraju da veliki broj atributa može narušiti performanse klasifikatora i predlažu sistem u kojem genetski algoritam bira podskup atributa, a zatim se na tom podskupu trenira i upoređuje pet klasičnih algoritama mašinskog učenja.

Skup podataka i priprema. Korišten je najpoznatiji javni skup za ovaj problem: transakcije evropskih korisnika kartica tokom dva dana, sa samo 492 prevare. Za razliku od našeg skupa, svi atributi su numerički i anonimizovani. Klasna nebalansiranost je ublažena metodom SMOTE, a atributi su normalizovani *min-max* postupkom. Genetski algoritam je pronašao pet kandidatskih vektora atributa (v1–v5) dužine od 9 do 18 atributa, a atribut `Amount` se nalazi u svakom od njih.

Poređenje eksperimentalnih rezultata. Tabela 10 prikazuje rezultate za vektor v5 (Tabela 6 rada) i za vektor v1, na kojem je ostvarena najveća F1-mjera (Tabela 2 rada).

Tabela 10: Rezultati klasifikatora iz rada Ileberija i saradnika (u %)

Model (vektor atributa)	Acc.	Recall	Prec.	F1
Random Forest (v5)	**99,98**	**72,56**	**95,34**	**82,41**
Stablo odlučivanja (v5)	99,89	72,56	65,07	68,61
ANN (v5)	99,08	77,87	12,27	21,20
Naive Bayes (v5)	99,44	57,52	15,85	24,85
Logistička regresija (v5)	99,77	46,90	34,64	39,84
Random Forest (v1)	99,94	76,99	89,69	82,85
ANN (v1)	99,94	77,87	84,61	81,10
Naive Bayes (v1)	98,13	84,95	6,83	12,65

Tumačenje rezultata. Random Forest je najbolji ili među najboljima za svaki vektor atributa. Iako svi modeli imaju tačnost iznad 98 %, preciznost i F1-mjera se drastično razlikuju: Naive Bayes s vektorom v1 ima tačnost 98,13 %, a preciznost samo 6,83 %, što znači da je velika većina transakcija koje označi kao prevarne zapravo legitimna. Rezultati pokazuju i da izbor atributa snažno utiče na pojedine modele (npr. F1 ANN-a pada s 81,10 % na 21,20 % između vektora v1 i v5). Treba imati na umu da autori kao glavnu metriku koriste tačnost, koja je na skupu s 0,172 % prevara slabo informativna.

Zaključak i značaj za istraživanje. Rad potvrđuje da je Random Forest pouzdan izbor za detekciju prevara i da Naive Bayes ima najlošiji odnos preciznosti i osjetljivosti. Za naš projekat je važna i pouka o evaluaciji: kod nebalansiranih podataka rezultate treba prikazivati kroz preciznost, recall i F1-mjeru za klasu prevare, a ne samo kroz tačnost.

Naučnoistraživački rad – Kerim Hajdar

Naslov rada: *Credit Card Fraud Detection Using Improved Deep Learning Models.*

Autori: Sumaya S. Sulaiman, Ibraheem Nadher i Sarab M. Hameed.

Izvor: *Computers, Materials & Continua*, vol. 78, br. 1, str. 1049–1069, 2024. [6]

Tabela 11: Sažeti pregled naučnoistraživačkog rada Sulaiman i saradnika (2024)

Stavka	**Opis**
Problem	Detekcija prevara kreditnim karticama pomoću modela dubokog učenja i ispitivanje uticaja podešavanja hiperparametara i metoda uravnotežavanja na njihove performanse.
Skup podataka	Evropski skup transakcija kreditnim karticama (Kaggle, septembar 2013.): 284 807 transakcija, od kojih su 492 prevarne (0,172 %).
Korištene metode	Autoenkoder (AE), konvolucijska neuronska mreža (CNN) i LSTM mreža; podešavanje hiperparametara metodama *random search* i Bayesovom optimizacijom (cilj: F1-mjera); uravnotežavanje metodama RUS, SMOTE i ADASYN; stratifikovana unakrsna validacija.
Metrike	Tačnost, stopa detekcije (*detection rate*, tj. recall) i AUC; F1-mjera kao funkcija cilja pri podešavanju hiperparametara.
Najbolji rezultat	**LSTM + SMOTE** (*random search*): tačnost **99,2 %**, stopa detekcije **93,3 %**, AUC **96,3 %**.

Cilj i istraživački problem. Autori polaze od toga da uspješnost modela dubokog učenja u velikoj mjeri zavisi od izbora hiperparametara. Cilj je ispitati kako sistematsko podešavanje (broj neurona, *dropout*, aktivacijska funkcija, veličina *batch*-a, optimizator, funkcija gubitka i stopa učenja) u kombinaciji s različitim metodama uravnotežavanja utiče na detekciju prevara.

Skup podataka i priprema. Korišten je javni evropski skup sa 30 numeričkih atributa i izrazitom nebalansiranošću klasa. Podaci su podijeljeni na skup za treniranje, validaciju i testiranje stratifikovanom unakrsnom validacijom, a uravnotežavanje (RUS, SMOTE ili ADASYN) primijenjeno je *samo na skupu za treniranje*. Za svaki model izvedeno je osam pokretanja (četiri slučajnom pretragom i četiri Bayesovom optimizacijom), uz četiri scenarija: bez uravnotežavanja, RUS, SMOTE i ADASYN.

Poređenje eksperimentalnih rezultata. Tabela 12 prikazuje dio rezultata iz Tabele 3 rada (podešavanje hiperparametara slučajnom pretragom).

Tabela 12: Rezultati modela dubokog učenja iz rada Sulaiman i saradnika (u %)

Model – uravnotežavanje	**Acc.**	**Stopa detekcije**	**AUC**
AE – bez uravnotežavanja	95,0	90,0	92,7
AE – SMOTE	96,1	89,7	92,9
CNN – bez uravnotežavanja	99,7	83,0	91,4
CNN – SMOTE	99,8	89,7	94,7
LSTM – bez uravnotežavanja	99,9	80,8	90,4
LSTM – RUS	98,4	88,9	93,6
LSTM – SMOTE	**99,2**	**93,3**	**96,3**
LSTM – ADASYN	99,2	92,6	95,9

Tumačenje rezultata. Uravnotežavanje skupa za treniranje značajno povećava stopu detekcije: kod LSTM mreže ona raste s 80,8 % (bez uravnotežavanja) na 93,3 % uz SMOTE, uz mali pad tačnosti (s 99,9 % na 99,2 %). Metode koje generišu sintetičke primjere (SMOTE, ADASYN) bile su uspješnije od RUS-a, koji odbacuje dio podataka većinske klase. Autori LSTM i CNN modelima pripisuju prednost jer mogu naučiti sekvencijalne obrasce transakcija. Rad ne prikazuje preciznost, pa nije moguće procijeniti broj lažnih alarma koji prati visoku stopu detekcije.

Zaključak i značaj za istraživanje. Rad pokazuje da podešavanje hiperparametara i oversampling skupa za treniranje mogu značajno povećati osjetljivost modela, što je direktno povezano sa zadacima 2.2 našeg projekta (*tuning* i uravnotežavanje klasa). Istovremeno, potvrđuje važnost prikaza preciznosti uz recall: bez preciznosti visoka stopa detekcije ne govori koliko je model upotrebljiv u praksi.

Zbirni pregled radova

Tabela 13: Zbirni pregled analiziranih naučnoistraživačkih radova

Rad	Skup podataka	Metode	Metrike	Najbolji rezultat
Afriyie i sar. (2023) [2]	Sparkov	LR, DT, RF; RUS	Acc, Prec, Rec, F1, Spec, AUC	RF: AUC 0,989, recall 0,97, F1 0,17
Al-Bulushi i sar. (2026) [3]	Sparkov + 5 neviđenih skupova	LR, NB, DT, RF, ANN, XGBoost; RUS, ROS, SMOTE; ansambli	Acc, Prec, Rec, F1, AUC	XGBoost: F1 0,84; Bagging 1: F1 0,795, recall 0,864
Breskuvienė i Dzemyda (2024) [4]	Sparkov, sintetički i evropski skup	RF, XGBoost, CatBoost; selekcija atributa FID-SOM	F1, MCC, G-Mean, AUC-PR, AUC-ROC	XGBoost + FID-SOM (Sparkov): F1 0,855, AUC-PR 0,895
Ileberi i sar. (2022) [5]	Evropski skup	DT, RF, LR, ANN, NB; GA selekcija atributa; SMOTE	Acc, Prec, Rec, F1, AUC	GA-RF: Acc 99,98 %, F1 82,41 %
Sulaiman i sar. (2024) [6]	Evropski skup	AE, CNN, LSTM; tuning hiperparametara; RUS, SMOTE, ADASYN	Acc, stopa detekcije, AUC	LSTM + SMOTE: stopa detekcije 93,3 %, AUC 96,3 %

Očekivanja na osnovu literature

Algoritmi. U svim radovima koji ih porede najbolje rezultate daju ansambli zasnovani na stablima odlučivanja. Random Forest je najbolji model kod Afriyie i saradnika [2] i Ileberija i saradnika [5], a XGBoost i Random Forest kod Al-Bulushi i saradnika [3] i Breskuvienė i Dzemyde [4]. Ovi modeli dobro rade s mješovitim tipovima atributa, nelinearnim odnosima i atributima različitih skala. Neuronske mreže postižu konkurentne rezultate [3, 6], ali zahtijevaju pažljivo podešavanje hiperparametara. Logistička regresija i Naive Bayes dosljedno daju najslabije rezultate: na Sparkov skupu F1-mjera im je ispod 0,1 [3], a Naive Bayes ima preciznost svega 7–16 % i na evropskom skupu [5]. Ove modele zato očekujemo kao donju granicu (*baseline*) za poređenje. Kombinovanje modela u ansambl (*bagging*, *stacking*) daje stabilne rezultate i visok recall, ali ne nadmašuje uvijek najbolji pojedinačni model [3].

Uravnotežavanje klasa. Uravnotežavanje skupa za treniranje (RUS, ROS, SMOTE) povećava osjetljivost modela [6, 3], ali na realističnoj raspodjeli klasa značajno smanjuje preciznost [2, 3]. Primjer je Random Forest treniran na *undersampling* uzorku: recall 0,97 uz preciznost 0,09–0,17. Za naš projekat to znači da modele treniramo i na balansiranom skupu, ali ih provjeravamo i na stratifikovanim uzorcima s originalnim udjelom prevara (0,58 %), te da uravnotežavanje primjenjujemo isključivo na skupu za treniranje.

Metrike. Ukupna tačnost nije pouzdana mjera jer model koji sve transakcije proglasi legitimnim postiže tačnost od oko 99,4 %. Gotovo svi radovi koriste preciznost, osjetljivost (recall) i F1-mjeru za klasu prevare, te AUC-ROC. Breskuvienė i Dzemyda [4] pokazuju da je AUC-ROC na nebalansiranim podacima visok (0,97–0,998) i za osjetno slabije modele, pa preporučuju AUC-PR i MCC. Kao glavne metrike projekta zato koristimo **F1-mjeru, preciznost i recall za klasu prevare, AUC-PR i MCC**, a dodatno tačnost, specifičnost, kappa statistiku i AUC-ROC, u skladu sa specifikacijom zadatka 2.2.

Atributi. Na Sparkov skupu uočeni su obrasci prevara povezani s iznosom transakcije, dobom dana i kategorijom kupovine [2], dok selekcija atributa i atributi izvedeni iz ponašanja korisnika dodatno poboljšavaju rezultate [4, 3]. Očekujemo da će izvedeni atributi (sat transakcije, starost korisnika, udaljenost korisnika od trgovca) biti korisniji od identifikatora i ličnih podataka, koje treba ukloniti.

Istraživačka hipoteza

Radna hipoteza: *Na korištenom Sparkov skupu podataka modeli zasnovani na ansamblima stabala odlučivanja (Random Forest, gradient boosting) postići će veću F1-mjeru i AUC-PR za klasu prevare od linearnih i probabilističkih modela (logistička regresija, Naive Bayes). Uravnotežavanje skupa za treniranje i podešavanje hiperparametara povećaće osjetljivost modela, ali uz pad preciznosti na skupu s realističnim udjelom prevara. Ansambl koji kombinuje različite klasifikatore postići će F1-mjeru najmanje jednaku najboljem pojedinačnom modelu, uz stabilnije rezultate kroz unakrsnu validaciju.*

Hipoteza će se provjeriti u zadacima 2.2 i 2.3 poređenjem metrika svih modela na istom testnom skupu i kroz unakrsnu validaciju.

1.3. Istraživačka analiza podataka

Ovaj odjeljak obuhvata **svaki atribut iz korištenog skupa podataka**, uključujući ciljnu klasu. Za svaki je potrebno prikazati tip, distribuciju i primjeren opis (deskriptivnu statistiku ili frekvencije), a zatim **objasniti zaključak**.

Struktura skupa i kvalitet podataka

[Dopuniti: Navesti dimenzije skupa, tipove varijabli, nedostajuće vrijednosti, duplikate i eventualne neuobičajene vrijednosti.]

Analiza pojedinačnih varijabli

Tabela 14: Pregled svih atributa i zaključaka istraživačke analize

Atribut	Tip	Distribucija / statistika	Zapažanje
`is_fraud`	Binarni	*[Dopuniti: broj i udio klasa]*	*[Dopuniti: nebalansiranost]*
[Dopuniti: atribut 2]	*[Dopuniti: tip]*	*[Dopuniti: mjere ili kategorije]*	*[Dopuniti: zaključak]*
[Dopuniti: atribut 3]	*[Dopuniti: tip]*	*[Dopuniti: mjere ili kategorije]*	*[Dopuniti: zaključak]*
Dodati po jedan red za svaki preostali atribut iz stvarnog skupa.			

Za **numeričke** varijable analizirati, gdje je primjereno, srednju vrijednost, medijan, standardnu devijaciju, raspone, kvartile i izdvojene vrijednosti. Za **kategoričke** varijable prikazati broj kategorija i njihove učestalosti. Odgovarajuće grafikone navesti uz tekst i za svaki obrazložiti uočeni obrazac.

Mjesto za grafikon.
`slike/raspodjela_klasa.png`

Slika 1: Distribucija legitimnih i prevarnih transakcija.

Povezanost atributa

[Dopuniti: Prikazati i protumačiti korelacije među primjerenim parovima varijabli. Po potrebi upotrijebiti različite mjere povezanosti za numeričke i kategoričke atribute. Izdvojiti najznačajnije odnose sa ciljnom klasom.]

Mjesto za grafikon.
`slike/korelacije.png`

Slika 2: Povezanost odabranih numeričkih atributa.

Zaključci analize

[Dopuniti: Sažeti nalaze koji utiču na odluke o pripremi podataka: neravnomjeran odnos klasa, nedostajuće vrijednosti, problematični atributi i slično.]

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„1.3 Istraživačka analiza podataka“*.

1.4. Priprema i transformacija podataka

Opisati **koji atributi su obrađeni, na koji način i zašto**. Ne morate prikazivati Python kod, nego odluke i njihove posljedice.

Tabela 15: Primijenjeni postupci pripreme podataka

Atribut(i)	Postupak	Razlog / posljedica
[Dopuniti: atribut(i)]	*[Dopuniti: npr. obrada nedostajućih vrijednosti]*	*[Dopuniti: zašto]*
[Dopuniti: atribut(i)]	*[Dopuniti: npr. kodiranje kategorija]*	*[Dopuniti: zašto]*
[Dopuniti: atribut(i)]	*[Dopuniti: npr. uklanjanje ili zadržavanje]*	*[Dopuniti: zašto]*

Važna napomena. Pripremu razdvojiti na opšte korake i transformacije koje zavise od algoritma. Imputacija, skaliranje i kodiranje koji uče parametre iz podataka moraju se uklopiti u odgovarajući *pipeline* i učiti samo na trening skupu. Oversampling/undersampling se ne provodi na testnom skupu.

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„1.4 Priprema podataka“*.

2. Izgradnja klasifikacijskih modela

2.1. Odabir algoritama i raspodjela rada

Tim bira pet klasifikacijskih algoritama, po jedan za svakog člana. Konačni odabir i raspodjelu unijeti nakon zajedničkog dogovora.

Tabela 16: Raspodjela algoritama među članovima tima

Član tima	Algoritam	Zašto je odabran
Aldin Velić	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Bakir Činjarević	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Danijal Alibegović	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Haris Macić	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*
Kerim Hajdar	*[odabrati algoritam]*	*[Dopuniti: obrazloženje]*

Pri izboru se mogu razmotriti, naprimjer, stablo odlučivanja, Naivni Bayes, logistička regresija, SVM, k-NN ili neuronska mreža. To su samo primjeri; **u tabeli navedite algoritme koje zaista budete izabrali**.

2.2. Izgradnja i evaluacija pojedinačnih modela

Svaki član u svom dijelu dokumentuje dodatnu pripremu podataka, podjelu na trening, validacijski i testni skup, izgradnju *pipelinea*, evaluaciju (confusion matrix, tačnost, osjetljivost, specifičnost, kappa i druge opravdane metrike), unakrsnu validaciju, uticaj nebalansiranosti klasa, oversampling/undersampling i podešavanje hiperparametara.

2.2.1. Model 1: *[odabrati algoritam]*– Aldin Velić

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 17: Rezultati modela 1 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]*

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„2.2.1 Model 1: [odabrati algoritam]“*.

2.2.2. Model 2: *[odabrati algoritam]*– Bakir Činjarević

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test,*

stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 18: Rezultati modela 2 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]*

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„2.2.2 Model 2: [odabrati algoritam]“*.

2.2.3. Model 3: *[odabrati algoritam]*– Danijal Alibegović

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 19: Rezultati modela 3 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]*

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„2.2.3 Model 3: [odabrati algoritam]“*.

2.2.4. Model 4: *[odabrati algoritam]*– Haris Macić

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 20: Rezultati modela 4 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]*

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„2.2.4 Model 4: [odabrati algoritam]“*.

2.2.5. Model 5: *[odabrati algoritam]*– Kerim Hajdar

Priprema podataka za algoritam. *[Dopuniti: Opisati ima li ovaj algoritam posebne zahtjeve, npr. skaliranje, kodiranje ili odabir atributa; obrazložiti odluke.]*

Podjela podataka i pipeline. *[Dopuniti: Navesti omjere trening/validacija/test, stratifikaciju i postupak sprečavanja curenja informacija; opisati redoslijed koraka u pipelineu.]*

Treniranje, evaluacija i unakrsna validacija. *[Dopuniti: Opisati početni model, konfuzijsku matricu i metode unakrsne validacije. Navesti tačnost, osjetljivost, specifičnost, Cohenovu kappu, precision i F1 ili druge opravdane metrike.]*

Uticaj nebalansiranosti i balansiranje. *[Dopuniti: Uporediti model prije i poslije odabrane metode oversamplinga i/ili undersamplinga. Balansirati isključivo trening dio svakog folda.]*

Podešavanje hiperparametara. *[Dopuniti: Navesti raspon isprobanih hiperparametara, metodu pretrage, validacijski kriterij i najbolju konfiguraciju.]*

Tabela 21: Rezultati modela 5 na testnom skupu

Varijanta	Tačnost	Recall_1	Specifičnost	F1_1	Kappa
Osnovni model	–	–	–	–	–
Nakon balansiranja i podešavanja	–	–	–	–	–

Diskusija. *[Dopuniti: Protumačiti rezultate i karakteristične greške modela. Navesti šta je doprinijelo poboljšanju ili pogoršanju.]*

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„2.2.5 Model 5: [odabrati algoritam]“*.

2.3. Poređenje i ansambl-model

Poređenje pojedinačnih modela

Uporediti svih pet modela na **istom testnom skupu i po istim metrikama**. Obrazložiti razlike u performansama; naročito komentarisati koliko koji model prepoznaje prevarne transakcije i koliko često pogrešno obilježava legitimne transakcije kao prevarne.

[Dopuniti: Navesti konkretne rezultate i objasniti razloge različitih performansi, uzimajući u obzir pripremu, balansiranje i podešavanje modela.]

Tabela 22: Zajedničko poređenje pet klasifikacijskih modela

Model	Tačnost	Precision_1	Recall_1	F1_1	Kappa
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–
[odabrati algoritam]	–	–	–	–	–

Izbor i izgradnja ansambl-modela

[Dopuniti: Navesti odabranu metodu kombinovanja modela (npr. glasanje ili stacking), njeno obrazloženje, koje modele uključuje, način treniranja, validaciju i odgovarajući pipeline.]

Tabela 23: Poređenje ansambl-modela i najboljeg pojedinačnog modela

Model	Precision_1	Recall_1	F1_1
Najbolji pojedinačni model	–	–	–
Ansambl-model	–	–	–

Diskusija rezultata i zaključak

[Dopuniti: Objasniti je li ansambl postigao poboljšanje, prema kojoj metrici, koliko je pouzdan rezultat te da li je polazna hipoteza potvrđena. Navesti ograničenja rada i glavne zaključke bez dodavanja novog koda.]

Kod: *[Dopuniti: poveznica na Google Colab bilježnicu]*, odjeljak *„2.3 Poređenje modela i ansambl“*.

Literatura

[1] kartik2112, "Credit card transactions fraud detection dataset." Kaggle, https://www.kaggle.com/datasets/kartik2112/fraud-detection. Pristupljeno: 29.10.2026.

[2] J. K. Afriyie, K. Tawiah, W. A. Pels, S. Addai-Henne, H. A. Dwamena, E. O. Owiredu, S. A. Ayeh, and J. Eshun, "A supervised machine learning algorithm for detecting and predicting fraud in credit card transactions," *Decision Analytics Journal*, vol. 6, p. 100163, 2023. https://doi.org/10.1016/j.dajour.2023.100163.

[3] A. Al-Bulushi, A. K. Shaikh, and N. Adhikari, "Applying supervised machine learning algorithms and ensemble models to enhance credit card fraud detection," *Frontiers in Artificial Intelligence*, vol. 9, p. 1813728, 2026. https://doi.org/10.3389/frai.2026.1813728.

[4] D. Breskuvienė and G. Dzemyda, "Enhancing credit card fraud detection: highly imbalanced data case," *Journal of Big Data*, vol. 11, p. 182, 2024. https://doi.org/10.1186/s40537-024-01059-5.

[5] E. Ileberi, Y. Sun, and Z. Wang, "A machine learning based credit card fraud detection using the GA algorithm for feature selection," *Journal of Big Data*, vol. 9, p. 24, 2022. https://doi.org/10.1186/s40537-022-00573-8.

[6] S. S. Sulaiman, I. Nadher, and S. M. Hameed, "Credit card fraud detection using improved deep learning models," *Computers, Materials & Continua*, vol. 78, no. 1, pp. 1049–1069, 2024. https://doi.org/10.32604/cmc.2023.046051.